

Importazione dei dati da un file .csv

R è un programma per la **analisi statistica e grafica dei dati** e la cosa che accade con maggior frequenza è avere dei dati gestiti esternamente a **R**, in un database o in un foglio elettronico, e volerli importare in **R** per poterli analizzare.

Una struttura dati tipica, ed estesamente impiegata anche in **R** [1], è riportata in questa **tabella** (che è di fatto un minuscolo **database**)

id	sesso	anni	peso_kg	altezza_m
MT	M	69	76	1,78
GF	F	56	63	
MC	F	53	71	1,60
SB	M	28	73	1,78
FE	F	61	54	1,54
AB	M	46	92	1,84
RF	F	31	81	1,56

* se manca, R assegna automaticamente a ciascun caso un identificativo univoco numerico

nella quale le cose da notare in relazione a **R** sono abbastanza semplici:

- le **righe** corrispondono ai **casi** della statistica (e ai **record** del database);
- le **colonne** corrispondono alle **variabili** della statistica (e ai **campi** del database);
- i **nomi delle variabili** sono riportati nella prima riga (in **R** sono facoltativi ma fortemente raccomandati per mantenere ordine e chiarezza nel proprio lavoro);
- le **variabili** possono essere sia numeriche, sia qualitative (per esempio qui `Sesso` è una variabile qualitativa);
- un **identificativo univoco** di ciascuno dei **casi** può essere riportato nella prima colonna (è facoltativo). Se l'identificativo non è presente nei dati originali **R** numera automaticamente i **casi** in ordine crescente per identificare ciascun caso in modo univoco;
- dato che come separatore delle cifre decimali **R** al proprio interno impiega esclusivamente il punto (.) se nei dati da importare viene impiegata la virgola (,) questa verrà convertita da **R** in un punto (.);
- è possibile che si verifichi la **manca di dati**, per esempio qui manca il valore di `Altezza` nel caso `GF`, e il campo è quindi vuoto. **R** al momento di importare i dati riconoscerà automaticamente questi casi riportando nel campo del dato mancante la sigla `NA` ovvero `Not Available`;

Nota bene: in **R** le variabili qualitative, non numeriche, sono denominate **fattori** e sono importanti in quanto consentono di raggruppare i dati di una database in sottoinsiemi. Così i dati della nostra tabella potranno essere elaborati tutti insieme o suddivisi in due gruppi in base al valore assunto dalla variabile `Sesso`. Ovviamente è indispensabile che la variabile in base alla quale i dati possono essere raggruppati sia codificata in modo rigoroso, così il sesso maschile, poiché **R** riconosce lettere

maiuscole e lettere minuscole, deve essere espresso sempre con `M` (o con `m`) e non si possono usare `M` o `m` indifferentemente.

Il tema che si pone con **R** è ora questo: in quale formato salvare (e leggere) i dati?

Abbiamo visto altrove che il modo migliore per salvare uno script [2] è farlo in un file di testo (in genere con estensione `.txt` ma in **R** anche con estensione `.R`) nel quale i **caratteri** possono essere scritti (e successivamente essere riletti) in chiaro nello stesso modo in cui sono scritti su (e possono essere riletti da) un foglio di carta scritto con una macchina da scrivere [3], impiegando un set di caratteri limitato, ma universalmente riconosciuto, tipicamente il codice ASCII di base [4].

La stessa identica soluzione - salvarli in un file di testo nel quale sono scritti in chiaro - è raccomandata per i **dati** e impiega il formato `.csv` (l'acronimo `csv` sta per `comma separated values` cioè per valori separati dalla virgola (,) tuttavia come vedremo tra poco il separatore di campo può essere anche un altro carattere). Le modalità per salvare in formato `.csv` i dati dipendono dal programma sul quale risiedono e dal quale li volete esportare, ora invece vediamo come li possiamo leggere e importare in **R**.

Per continuare è necessario:

→ effettuare il download del file `importa_csv.csv`

→ salvare il file nella cartella `C:\Rdati\`

Per questo e gli altri file di dati impiegati nei post trovate link e modalità di download alla [pagina Dati](#).

Il file, aperto con un editor di testo come ad esempio il Blocco note di Windows, contiene i dati della tabella/database:

```
id;sezzo;anni;peso_kg;altezza_m
MT;M;69;76;1,78
GF;F;56;63;
MC;F;53;71;1,60
SB;M;28;73;1,78
FE;F;61;54;1,54
AB;M;46;92;1,84
RF;F;31;81;1,56
```

Come vedete un file `.csv` è, analogamente a un file `.txt`, un file di testo scritto **in chiaro** con caratteri standard e in cui i **dati** sono organizzati con regole molto semplici e **immediatamente riconoscibili** semplicemente aprendo il file con un qualsiasi editor di testo (ed è esattamente questo il punto di forza del formato `.csv`).

In un tipico file `.csv` come questo:

- nella prima riga sono riportati i nomi delle **variabili** ovvero dei **campi** che compongono i **record**;
- nelle righe successive alla prima sono riportati, uno per riga, i casi ovvero i **record** che compongono il **database**;
- il punto e virgola (;) è il **separatore di campo** che indica la fine di un campo e il passaggio al campo successivo;
- come **separatore delle cifre decimali** è impiegata la virgola (,);
- il fatto che la prima colonna/variabile debba essere interpretata come una variabile qualsiasi piuttosto che come un **identificativo univoco** di ciascun record/caso viene specificato nel momento in cui sono importati i dati (vedere qui sotto);
- nel caso `GF` abbiamo un **dato mancante**, quello dell'altezza.

L'impiego del punto e virgola (;) come separatore di campo e della virgola (,) come separatore delle cifre decimali non è casuale. Il file `importa_csv.csv` è stato generato salvando in formato `.csv` i dati

contenuti in un foglio elettronico



	A	B	C	D	E
1	id	sesso	anni	peso_kg	altezza_m
2	MT	M	69	76	1,78
3	GF	F	56	63	
4	MC	F	53	71	1,6
5	SB	M	28	73	1,78
6	FE	F	61	54	1,54
7	AB	M	46	92	1,84
8	RF	F	31	81	1,56

che è lo strumento più frequentemente impiegato per gestire i propri dati [53]. Il punto e virgola (;) come separatore di campo e la virgola (,) come separatore delle cifre decimali sono impostati di default in Windows nei paesi come Spagna, Italia e Francia, e il foglio elettronico nel nostro caso ha salvato il file `.csv` impiegando la configurazione di Windows [nei paesi anglosassoni in Windows sono impostati di default la virgola (,) come separatore di campo e il punto (.) come separatore delle cifre decimali].

Ora copiate e incollate nella `Console` di R questo script e premete `↵` Invio:

```
# IMPORTA I DATI DI UN FILE CSV
# notare / invece di \ su windows
mydata <- read.table("C:/Rdati/importa_csv.csv", header=TRUE, sep=";", dec=",")
#
```

All'oggetto **mydata** viene assegnato (`<-`) il contenuto importato dalla funzione **read.table()** [6]. Gli argomenti della funzione, racchiusi nella parentesi, specificano che:

- il file dal quale importare i dati è **C:/R/importa_csv.csv**;
- la prima riga nel file è una riga di intestazione con i nomi delle variabili (**header=TRUE**);
- nel file è impiegato come separatore di campo il punto e virgola (**sep=";"**);
- nel file è impiegato come separatore delle cifre decimali la virgola (**dec=","**).

Se ora nella `Console` di R digitate

mydata

vedete comparire i dati che avete appena importato:

```
> mydata
  id sesso anni peso_kg altezza_m
1 MT     M   69     76     1.78
2 GF     F   56     63        NA
3 MC     F   53     71     1.60
4 SB     M   28     73     1.78
5 FE     F   61     54     1.54
6 AB     M   46     92     1.84
7 RF     F   31     81     1.56
```

Notate che:

- dalla tabella/database `importa_csv.csv` sono stati importati 7 record/casi ciascuno contenente cinque campi/variabili (`id`, `sesso`, `anni`, `peso_kg`, `altezza_m`);
- **R** ha aggiunto a ciascuno dei casi un identificativo univoco sotto forma di un numero progressivo (1 per la prima riga/caso, 2 per la seconda riga/caso, e così via);

→ la virgola (,) presente come separatore delle cifre decimali nei dati originali è stata automaticamente trasformata da **R** in un punto (.).

Se avessimo deciso che nel campo "id" è contenuto l'**identificativo univoco** di ciascun caso avremmo dovuto eseguire quest'altro script:

```
# IMPORTA I DATI DI UN FILE CSV CON IDENTIFICATIVO UNIVOCO DEI CASI
# notare / invece di \ su windows
mydata <- read.table("C:/Rdati/importa_csv.csv", header=TRUE, sep=";", dec=".",
row.names="id")
#
```

Rispetto al precedente script, alla funzione **read.table()** è stato aggiunto l'argomento **row.names="id"** mediante il quale viene specificato che come identificativo di ciascuna riga/caso deve essere impiegato il campo **id**. In questo modo **R**:

→ dalla tabella/database **importa_csv.csv** importerà 7 record ciascuno contenente quattro campi/variabili (**sex**, **age**, **weight_kg**, **height_m**);
→ assocerà a ciascuno dei casi l'identificativo univoco contenuto nel campo **id**.

Se ora nella Console di R digitate

mydata

vedete che **R** non ha più assegnato ai casi l'identificativo numerico (1, 2, ...) previsto di default, ma che ciascuna riga/caso è stato identificato in modo univoco mediante il valore contenuto nel campo **id** (MT per il primo caso/record, GF per il secondo caso/record, e così via):

```
> mydata
  sesso anni peso_kg altezza_m
MT     M   69     76     1.78
GF     F   56     63        NA
MC     F   53     71     1.60
SB     M   28     73     1.78
FE     F   61     54     1.54
AB     M   46     92     1.84
RF     F   31     81     1.56
```

A questo punto ecco la domanda che sarà venuta in mente a tutti: cosa accade se due casi/record per errore hanno lo stesso identificativo, quindi se il campo specificato in realtà non contiene un identificativo univoco?

Supponiamo che tabella/database **importa_csv.csv** contenga questi dati (il primo e il terzo caso hanno ora lo stesso identificativo **MT**):

```
id;sex;age;weight_kg;height_m
MT;M;69;76;1,78
GF;F;56;63;
MT;F;53;71;1,60
SB;M;28;73;1,78
FE;F;61;54;1,54
AB;M;46;92;1,84
RF;F;31;81;1,56
```

In questo caso questa ecco la risposta che comparirebbe nella Console di R:

```
Error in read.table("C:/Rdati/importa_csv.csv", header = TRUE, sep = ";", dec = ",",
:
  duplicate 'row.names' are not allowed
```

Quindi **R** non importa i dati e ci viene in aiuto in modo che non possiamo sbagliare su un aspetto così critico.

Dato che l'importazione dei dati è un punto di svolta nell'apprendimento di **R**, si consiglia di familiarizzare adeguatamente con questo aspetto adattando gli script qui riportati a file `.csv` contenenti propri dati.

Chi desidera importare i dati direttamente da file `.xls` o `.xlsx` può consultare il post [Importazione dei dati da un file .xls o .xlsx](#).

[1] In alcuni pacchetti di **R** possono essere richieste strutture dati differenti, che sono peraltro specificate e illustrate nei manuali di riferimento dei pacchetti che le richiedono.

[2] Vedere il post [Salvare uno script](#).

[3] Macchina da scrivere oramai da tempo soppiantata, ma è da qui che è originato il concetto che, passando per la telescrivente, è stato applicato a PC e stampante.

[4] Vedere il post [Codifica dei caratteri ASCII, ANSI, Unicode \(UTF\)](#).

[3] Non mi dilungo ulteriormente su questo punto in quanto qualsiasi foglio elettronico e qualsiasi database consente con una voce del menù tipo `Esporta...` o tipo `Salva con nome...` di esportare i dati in formato `.csv`

[4] Digitate **help(read.table)** nella `Console` di **R** per la documentazione della funzione **read.table()**.
