

Importazione dei dati da un file .xls o .xlsx

Il formato dati raccomandato di **R** è il formato `.csv` e consente prima dell'importazione una ispezione preliminare dei dati, che sono accessibili in chiaro, semplicemente aprendo il file `.csv` con un editor di testo.

I formati `.xls` e `.xlsx` sono invece formati binari, nei quali i dati non sono accessibili in chiaro, e non sono formati standardizzati per cui la struttura dei file potrebbe cambiare senza preavviso nelle nuove versioni dei programmi che salvano in questi formati, causando errori imprevedibili e pertanto non gestibili nell'importazione dei dati in **R** [1]. Nonostante questo, data la larga diffusione dei dati salvati in questi formati, in **R** si trovano pacchetti che consentono di importare i dati direttamente da file `.xls` e `.xlsx` come ad esempio il pacchetto `xlsx` che si può scaricare dal **CRAN** (**C**omprehensive **R** **A**rchive **N**etwork) selezionando nel menù **Pacchetti di R** l'opzione **Installa pacchetti...** e quindi selezionando `xlsx` dall'elenco dei pacchetti disponibili.

Per la documentazione completa del pacchetto **xlsx** vedere il suo manuale di riferimento [2]. Se nel menù **Aiuto di R** selezionate **Guida Html** nella sezione **Reference** alla voce **Packages** trovate la documentazione dei pacchetti che avete installato sul vostro PC o notebook e che include, però in una versione meno completa, la documentazione del pacchetto **xlsx**.

Potete anche digitare **help(read.xlsx)** nella **Console di R** per una documentazione concisa ed essenziale della funzione **read.xlsx()**.

Per proseguire ora è necessario:

- effettuare il download del file `importa_xls.xls`
- effettuare il download del file `importa_xlsx.xlsx`
- salvare i file nella cartella `C:\Rdati\`

Per questo e gli altri file di dati impiegati nei post trovate link e modalità di download alla [pagina Dati](#).

Copiate e incollate nella **Console di R** questo script e premete ↵ **Invio**:

```
# IMPORTA I DATI DI UN FILE XLS
#
# carica il pacchetto xlsx
require(xlsx)
# carica nell'oggetto mydata i dati del file e del foglio specificati, notare / invece di \ su windows
mydata <- read.xlsx("C:/Rdati/importa_xls.xls", sheetName="peso_altezza")
#
```

La funzione **require()** carica in **R** il pacchetto **xlsx** contenente la funzione **read.xlsx()** che permette di importare i dati.

Gli unici argomenti richiesti dalla funzione **read.xlsx()** sono il nome del file con il percorso completo (**"C:/Rdati/importa_xls.xls"**) e il nome del foglio che contiene i dati (**sheetName="peso_altezza"**) all'interno del file. Quest'ultimo argomento è cruciale in quanto permette di gestire i molteplici fogli che possono essere presenti all'interno di un unico file `.xls` o `.xlsx`.

Se ora digitate **mydata** e premete ↵ **Invio** potete scorrere nella **Console di R** i dati che sono stati importati:

```
> mydata
  id sesso anni peso_kg altezza_m
1 MT     M   69     76     1.78
2 GF     F   56     63        NA
3 MC     F   53     71     1.60
4 SB     M   28     73     1.78
5 FE     F   61     54     1.54
6 AB     M   46     92     1.84
7 RF     F   31     81     1.56
```

Per avere la conferma del fatto che i dati sono stati importati correttamente confrontateli con l'originale aprendo il file con *Excel* o in alternativa con un programma appartenente alla categoria del software libero [3] come *OpenOffice calc* o *LibreOffice calc*. La sola differenza che riscontrerete risiederà nel separatore dei decimali, che nel foglio elettronico vedrete essere (nella configurazione italiana di Windows) la virgola (,) mentre nei dati importati trovate il punto (.) che è il separatore delle cifre decimali impiegato da **R**.

Notare che **R** assegna automaticamente un **identificativo univoco** numerico (**1**, **2**, eccetera) ai casi/righe.

Per importare un file `.xlsx` copiate e incollate nella `Console` di **R** questo script e premete ↵ `Invio`:

```
# IMPORTA I DATI DI UN FILE XLSX
#
# carica il pacchetto xlsx
require(xlsx)
# carica nell'oggetto mydata i dati del file e del foglio specificati, notare / invece di \ su windows
mydata <- read.xlsx("C:/Rdati/importa_xlsx.xlsx", sheetName="peso_altezza",
row.names="id")
#
```

Questa volta l'argomento `row.names="id"` specifica che gli identificativi univoci dei casi sono contenuti nel campo `id` del file. Se ora digitate **mydata** e premete ↵ `Invio` potete scorrere nella `Console` di **R** i dati che sono stati importati

```
> mydata
  sesso anni peso_kg altezza_m
MT     M   69     76     1.78
GF     F   56     63        NA
MC     F   53     71     1.60
SB     M   28     73     1.78
FE     F   61     54     1.54
AB     M   46     92     1.84
RF     F   31     81     1.56
```

nei quali l'identificativo univoco numerico di **R** non compare più, essendo stato sostituito da quello già presente nei dati importati.

Importare in **R** file `.xls` e `.xlsx` salvati con un foglio elettronico è quindi semplice. Tuttavia si ricorda che qualsiasi foglio elettronico è in grado di salvare i dati anche in formato `.csv` e che è questo il formato raccomandato da **R** (vedere il post [Importazione dei dati da un file .csv](#)).

[1] Il manuale ufficiale *R Data Import/Export* a pag. 29 così recita: "*The most common R data import/export question seems to be 'how do I read an Excel spreadsheet' ... The first piece of advice is to avoid doing so if possible!*".

<https://cran.r-project.org/doc/manuals/r-release/R-data.pdf>

[2] *xlsx: Read, Write, Format Excel 2007 and Excel 97/2000/XP/2003 Files.*

<https://cran.r-project.org/web/packages/xlsx/index.html>

[3] Per il significato di *Software libero*, di *Software open source* e di *Software di dominio pubblico* vedere: *The Free Software Foundation. GNU Operating System. Categories of free and nonfree software.*

<https://www.gnu.org/philosophy/categories.en.html>
