

Gestione dei dati mancanti

Per illustrare il tema, che è strettamente collegato all'ordinamento dei dati [1], vediamo tre cose:

→ come individuare i dati mancanti;

→ come i dati mancanti - identificati in **R** con la sigla `NA` (Not Available) - possono bloccare l'esecuzione di calcoli sulle variabili numeriche che li contengono e come in questo caso sia possibile omettere selettivamente dai calcoli i dati `NA`;

→ come al bisogno sia possibile eliminare per intero da un vettore o matrice o tabella [2] i casi con dati `NA`.

Per proseguire dovete, seguendo le istruzioni fornite alla [pagina Dati](#):

→ effettuare il download del file `importa_csv.csv`

→ salvare il file nella cartella `C:\Rdati\`

In alternativa copiate le otto righe riportate qui sotto, incollatele in un editor di file di testo aggiungendo un ↵ `Invio` al termine dell'ultima riga, e salvate il tutto in `C:\Rdati\` in un file di testo denominato `importa_csv.csv` (attenzione: assicuratevi che il file sia effettivamente salvato con l'estensione `.csv`):

```
id;sezzo;anni;peso_kg;altezza_m
MT;M;69;76;1,78
GF;F;56;63;
MC;F;53;71;1,60
SB;M;28;73;1,78
FE;F;61;54;1,54
AB;M;46;92;1,84
RF;F;31;81;1,56
```

Vediamo come individuare i dati mancanti. Copiate e incollate nella `Console` di **R** questo script e premete ↵ `Invio`:

```
# IDENTIFICA E CONTEGGIA I DATI MANCANTI
#
# importa i dati, notare / invece di \ su windows
mydata <- read.table("C:/Rdati/importa_csv.csv", header=TRUE, sep=";", dec=".",
row.names="id")
#
mydata # mostra i dati importati
#
is.na(mydata) # identifica i dati mancanti
#
colSums(is.na(mydata)) # conteggia i dati mancanti per colonna/variabile
#
which(is.na(mydata$altezza_m)) # identifica la posizione dei dati mancanti
#
```

Dopo avere importato i dati, richiamando il nome dell'oggetto **mydata** che li contiene questi sono mostrati con la sigla `NA` riportata automaticamente da **R** in corrispondenza di ciascuno dei dati mancanti.

```
> mydata # mostra i dati importati
  sesso anni peso_kg altezza_m
MT     M   69    76     1.78
GF     F   56    63      NA
```

MC	F	53	71	1.60
SB	M	28	73	1.78
FE	F	61	54	1.54
AB	M	46	92	1.84
RF	F	31	81	1.56

Nel caso di piccole tabelle come questa non serve altro: ma nel caso di estesi database ci servono funzioni che forniscano qualche soluzione più pratica e immediata.

Impieghiamo quindi la funzione **is.na()** che identifica nella tabella **mydata** i dati mancanti riportando **TRUE** in corrispondenza di ciascuno di essi

```
> is.na(mydata) # identifica i dati mancanti
      sesso  anni peso_kg altezza_m
MT FALSE FALSE  FALSE  FALSE
GF FALSE FALSE  FALSE  TRUE
MC FALSE FALSE  FALSE  FALSE
SB FALSE FALSE  FALSE  FALSE
FE FALSE FALSE  FALSE  FALSE
AB FALSE FALSE  FALSE  FALSE
RF FALSE FALSE  FALSE  FALSE
```

I dati della tabella **mydata** trasformati nei corrispettivi valori logici con la funzione **is.na()** possono allora essere impiegati come argomento della funzione **colSums()** che effettua il conteggio dei dati mancanti per ciascuna colonna/variabile

```
colSums(is.na(mydata)) # conteggia i dati mancanti per colonna/variabile
      sesso      anni  peso_kg altezza_m
      0         0         0         1
```

A questo punto abbiamo individuato in **altezza_m** la variabile con i dati mancanti e abbiamo conteggiato il loro numero.

Non ci resta quindi che impiegare i dati della variabile **mydata\$altezza_m** trasformati nei corrispettivi valori logici con **is.na()** come argomento della funzione **which()** per identificare la posizione dei dati mancanti

```
> which(is.na(mydata$altezza_m)) # identifica la posizione dei dati mancanti
[1] 2
```

che nel nostro caso risultano essere il dato della riga numero 2 della variabile **mydata\$altezza_m**.

Per l'effetto che i dati mancanti possono determinare sui calcoli copiate e incollate nella Console di R questo script e premete ↵ Invio:

```
# ESEMPIO DI MEDIA ARITMETICA NON COMPUTABILE A CAUSA DI DATI MANCANTI
#
# importa i dati, notare / invece di \ su windows
mydata <- read.table("C:/Rdati/importa_csv.csv", header=TRUE, sep=";", dec=".",
row.names="id")
#
mydata # mostra i dati importati
#
mean(mydata$peso_kg) # calcola la media aritmetica dei valori di peso
mean(mydata$altezza_m) # calcola la media aritmetica dei valori di altezza
#
```

Il risultato che compare nella Console di R è il seguente:

```
> mydata # mostra i dati importati
  sesso anni peso_kg altezza_m
MT     M   69     76     1.78
GF     F   56     63      NA
MC     F   53     71     1.60
SB     M   28     73     1.78
FE     F   61     54     1.54
AB     M   46     92     1.84
RF     F   31     81     1.56
> #
> mean(mydata$peso_kg) # calcola la media aritmetica dei valori di peso
[1] 72.85714
> mean(mydata$altezza_m) # calcola la media aritmetica dei valori di altezza
[1] NA
```

Come potete vedere il calcolo della media effettuato con la funzione **mean()** ha avuto successo solamente per il peso. Per l'altezza in luogo del valore della media è stata riportata la sigla **NA**, evidente conseguenza del valore mancante dell'altezza nel caso **GF**.

Copiate e incollate nella Console di R queste due ulteriori righe di codice e premete ↵ Invio:

```
# la corretta gestione dei dati mancanti consente di calcolare la media dei valori di altezza
#
mean(mydata$peso_kg) # ricalcola la media aritmetica dei valori di peso
mean(mydata$altezza_m, na.rm=TRUE) # ricalcola la media aritmetica dei valori di altezza
#
```

Il risultato dei calcoli della media che compare nella Console di R ora è questo:

```
> mean(mydata$peso_kg) # ricalcola la media aritmetica dei valori di peso
[1] 72.85714
> mean(mydata$altezza_m, na.rm=TRUE) # ricalcola la media aritmetica dei valori di
altezza
[1] 1.683333
```

Quindi con l'aggiunta nella funzione **mean()** dell'argomento **na.rm=TRUE**, che rimuove dal calcolo i dati mancanti (in questo caso uno solo, ma potrebbero essere anche molti), è stato reso possibile il calcolo della media anche per l'altezza.

Con la funzione **na.omit()** è infine possibile eliminare definitivamente i casi con dati mancanti: anche un solo dato mancante/campo vuoto comporta la cancellazione dell'intera riga/caso. Copiate e incollate nella Console di R questo script e premete ↵ Invio:

```
# ELIMINA I CASI CON DATI MANCANTI
#
# importa i dati, notare / invece di \ su windows
mydata <- read.table("C:/Rdati/importa_csv.csv", header=TRUE, sep=";", dec=","
row.names="id")
#
mydata # mostra i dati importati
#
newdata <- na.omit(mydata) # elimina da mydata i casi con dati mancanti
newdata # mostra i dati dopo eliminazione dei casi con dati mancanti
```

```
#
mean(newdata$peso_kg) # calcola la media aritmetica dei valori di peso
mean(newdata$altezza_m) # calcola la media aritmetica dei valori di altezza
#
```

Dai dati importati nella tabella **mydata** mediante la funzione **na.omit()** viene generata una nuova tabella denominata **newdata** dalla quale sono esclusi i casi con dati mancanti. Con l'eliminazione dalla tabella del caso **GF** i calcoli vanno subito a buon fine sia per il peso sia per l'altezza.

```
> mydata # mostra i dati importati
  sesso anni peso_kg altezza_m
MT     M   69     76     1.78
GF     F   56     63      NA
MC     F   53     71     1.60
SB     M   28     73     1.78
FE     F   61     54     1.54
AB     M   46     92     1.84
RF     F   31     81     1.56

> #
> newdata <- na.omit(mydata) # elimina da mydata i casi con dati mancanti
> newdata # mostra i dati dopo eliminazione dei casi con dati mancanti
  sesso anni peso_kg altezza_m
MT     M   69     76     1.78
MC     F   53     71     1.60
SB     M   28     73     1.78
FE     F   61     54     1.54
AB     M   46     92     1.84
RF     F   31     81     1.56

> #
> mean(newdata$peso_kg) # calcola la media aritmetica dei valori di peso
[1] 74.5
> mean(newdata$altezza_m) # calcola la media aritmetica dei valori di altezza
[1] 1.683333
```

Da notare che impiegando la funzione **na.omit()** la media dei valori di peso, che con lo script precedente era **72.85714** kg, ora è cambiata ed è diventata **74.5** kg in quanto in seguito all'eliminazione dell'intero caso **GF** è stato eliminato anche il suo valore di peso **63** kg che contribuiva a determinare la media di quest'ultimo.

[1] Vedere il post [Ordinamento dei dati](#).

[2] Parliamo di **array** o **vettore** nel caso di dati numerici monodimensionali, disposti su una sola riga,

8	6	11	7
---	---	----	---

di **matrice** nel caso di **dati numerici** disposti su più righe e più colonne

8	9	15	14
6	7	18	12

11	8	17	13
7	4	19	17

e di **tabella** nei casi in cui il contenuto, disposto su più righe e più colonne, è rappresentato oltre che da **dati numerici**, anche da **testo** e/o **operatori logici**

M	7	9	VERO
F	3	12	VERO
F	5	10	FALSO
