

Test chi-quadrato n righe · n colonne

Il **test chi-quadrato** può essere nella sua forma più generale esteso a **n righe · n colonne**. Il problema è che più sono le righe e le colonne e più è difficile individuare il valore (o i valori) che contribuiscono a rendere eventualmente significative le differenze. Per questa ragione in genere le tabelle con più righe e più colonne sono scomposte in tabelle più piccole al fine di valutare meglio i contributi dei valori osservati: per questo tipo di analisi, piuttosto delicata, si rimanda ai test di statistica.

Qui riporto un esempio di una tabella di 2 righe per 5 colonne tratto da Marubini [1] nella quale si riesce a individuare senza troppe complicazioni il risultato che contribuisce a rendere significativa la differenza tra le frequenze osservate.

Si trattava di valutare l'efficacia di cinque differenti vaccini influenzali. I vaccini vennero inoculati a novembre in 1080 soggetti sani volontari e nel mese di marzo dell'anno successivo vennero contati i casi di influenza tra i vaccinati.

Questi erano stati i risultati della sperimentazione. Da notare che viene riportato il numero dei casi cioè il conteggio dei soggetti affetti da influenza e non affetti da influenza, come richiesto dal test chi-quadrato, nel quale invece non devono mai essere riportati i dati espressi in percentuale:

Esito	Vaccino_1	Vaccino_2	Vaccino_3	Vaccino_4	Vaccino_5
Influenza_si	39	44	20	41	42
Influenza_no	177	166	200	183	168

Questo script prevede di inserire i dati manualmente. Copiatelo e incollatelo nella `Console di R` e premete ↵ Invio:

```
# TEST CHI-QUADRATO - n righe · n colonne
#
cells <- c(39, 44, 20, 41, 42, 177, 166, 200, 183, 168) # genera l'array cells con il numero dei
casi
rnames <- c("Influenza_si", "Influenza_no") # genera l'array rnames con i nomi delle righe
cnames <- c("Vaccino_1", "Vaccino_2", "Vaccino_3", "Vaccino_4", "Vaccino_5") # genera
l'array cnames con i nomi delle colonne
mydata <- matrix(cells, nrow=2, ncol=5, byrow=TRUE, dimnames=list(rnames,
cnames)) # genera la matrice dati
mydata # mostra i dati
chisq.test(mydata) # calcola il chi-quadrato
#
```

Nelle prime tre righe sono generati con la funzione **c()**:

- il vettore che contiene i quattro dati (che come si vede devono essere inseriti in sequenza leggendoli da sinistra a destra e dall'alto in basso) che sono salvati nell'oggetto **cells**;
- il vettore che contiene i nomi delle righe, salvato nell'oggetto **rnames**;
- il vettore che contiene i nomi delle colonne, salvato nell'oggetto **cnames**.

I tre vettori sono combinati a formare la matrice dei dati mediante la funzione **matrix()** che impiega gli argomenti che indicano:

- l'oggetto/vettore contenente i dati (**cells**);
- il numero di righe (**nrow**) e il numero di colonne (**ncol**) della matrice;
- la modalità di riempimento della matrice, che deve essere riempita per righe (**byrow=TRUE**) quindi da sinistra a destra e dall'alto in basso;

→ i nomi da assegnare alle righe e alle colonne (**dimnames=list(rnames, cnames)**).

La matrice viene salvata nell'oggetto **mydata**, che viene mostrato per un ovvio controllo della corretta immissione e strutturazione dei dati.

Infine con la funzione **chisq.test()** [2] viene effettuato il calcolo del test.

Questi sono i risultati:

```
> mydata # mostra i dati
      Vaccino_1 Vaccino_2 Vaccino_3 Vaccino_4 Vaccino_5
Influenza_si    39     44      20      41      42
Influenza_no   177    166     200     183     168
> chisq.test(mydata) # calcola il chi-quadrato
```

```
Pearson's Chi-squared test
```

```
data: mydata
X-squared = 13.678, df = 4, p-value = 0.008395
```

Il test chi-quadrato riporta un valore elevato della statistica chi-quadrato (**13.678**) cui corrisponde un valore di probabilità $p = 0.008395$ che conferma quindi la presenza di una differenza significativa nell'efficacia dei vaccini.

In alternativa potete anche copiare le tre righe riportate qui sotto aggiungendo un ↵ Invio al termine dell'ultima riga e salvarle in C:\Rdati\ nel file di testo denominato **chi_rxc.csv** (attenzione all'estensione al momento del salvataggio del file).

```
Esito;Vaccino_1;Vaccino_2;Vaccino_3;Vaccino_4;Vaccino_5
Influenza_si;39;44;20;41;42
Influenza_no;177;166;200;183;168
```

Questo script prevede di eseguire il test chi-quadrato sui dati letti dal file **chi_rxc.csv**. Copiatelo e incollatelo nella Console di R e premete ↵ Invio:

```
# TEST CHI-QUADRATO - n righe · n colonne
#
mydata <- read.table("C:/Rdati/chi_rxc.csv", header=TRUE, sep=";",
row.names="Esito") # importa i dati
mydata # mostra i dati
chisq.test(mydata) # calcola il chi-quadrato
#
```

Come vedete lo script è più compatto del precedente, le uniche cose da notare sono gli argomenti della funzione **read.table()**:

- **"C:/Rdati/chi_rxc.csv"** che specifica nome e posizione del file dal quale importare i dati;
- **header=TRUE** che indica che nella prima riga del file sono contenuti i nomi delle variabili;
- **sep=";"** che specifica il separatore di campo impiegato nel file;
- **row.names="Esito"** che indica che i nomi delle righe sono contenuti nel campo "Esito".

Anche se ovviamente i risultati sono sempre gli stessi, il senso di queste due alternative è semplice. Se vi va bene intervenire ogni volta sullo script per adattarlo a nuovi dati, potete impiegare la prima. Potete invece impiegare la seconda se volete evitare di mettere mano ogni volta allo script, e preferite intervenire solamente sul file di dati. A voi la scelta, magari dopo averle sperimentate entrambe.

Se riprendiamo i casi osservati (Influenza_si / Influenza_no) e li trasformiamo in percentuale

Esito	Vaccino_1	Vaccino_2	Vaccino_3	Vaccino_4	Vaccino_5
Influenza_si	18.1	21.0	9.1	18.3	20.0
Influenza_no	81.9	79.0	90.8	81.7	80.0

vediamo che l'eterogeneità dei risultati evidenziata dal test chi-quadrato è da attribuire al vaccino 3, con il quale si è avuto nei vaccinati un tasso di malattia del 9.1%, a fronte di un tasso di malattia omogeneo e praticamente doppio, che va dal 18.1% al 21.0%, che si è avuto nei soggetti vaccinati con gli altri quattro vaccini.

Un utile complemento all'analisi dei dati può essere realizzato mediante la loro rappresentazione grafica dei dati sotto forma di [grafico a barre affiancate](#) e [grafico a barre sovrapposte](#).

[1] Bossi A, Cortinovis I, Duca PG, Marubini E. *Introduzione alla statistica medica*. La Nuova Italia Scientifica, Roma, 1994, ISBN 88-430-0284-8, pp. 290-291.

[2] Digitate **help(chisq.test)** nella Console di R per la documentazione della funzione **chisq.test()**.

[3] Digitate **help(barplot)** nella Console di R per la documentazione della funzione **barplot()**.
