

Analisi esplorativa dei dati

Con l'espressione "analisi esplorativa dei dati" non si fa riferimento a una tecnica statistica specifica, bensì all'insieme delle valutazioni preliminari che è sempre necessario effettuare nell'ambito di un percorso logico che prevede, per il calcolo delle statistiche elementari di una singola variabile (analisi univariata), i seguenti passi:

→ **analisi esplorativa dei dati**;

→ esecuzione dei **test di normalità (gaussianità)**, per valutare se i dati seguono una distribuzione gaussiana;

→ calcolo delle **statistiche elementari parametriche** (media, deviazione standard, varianza, quantili parametrici) se i dati seguono una distribuzione gaussiana [1];

→ calcolo delle **statistiche elementari non parametriche** (mediana, deviazione assoluta mediana o MAD, quantili e altri quantili non parametrici) se i dati non seguono una distribuzione gaussiana.

In quanto si tratta di una prima fase, l'analisi esplorativa dei dati non prevede test di significatività, che sono riservati alla fasi successive, ma rappresenta piuttosto il momento di valutazione critica preliminare e globale dei dati raccolti, che deve includere quantomeno:

→ l'identificazione di eventuali *dati mancanti*;

→ un primo confronto orientativo tra i risultati di *statistiche parametriche* e di *statistiche non parametriche*;

→ l'individuazione di possibili *dati anomali* (outliers) cioè di dati che si discostano in modo inatteso dagli altri;

→ l'identificazione della possibile origine degli outliers (errori di digitazione? casi inclusi erroneamente? problemi strumentali? altro?) e la valutazione degli interventi correttivi (laddove possibili).

Vediamo ora alcune funzioni che possono aiutarci per le attività previste nei primi tre punti (ovviamente non per il quarto) utilizzando come esempio i dati ematologici e biometrici rilevati in 202 atleti australiani contenuti nella tabella **ais** del pacchetto **DAAG** - accertatevi di avere installato il pacchetto o in alternativa procedete come indicato in [2] dove trovate anche illustrati i dati contenuti nella tabella.

Copiate lo script, incollatelo nella `Console di R` e premete ↵ Invio:

```
# ANALISI ESPLORATIVA DEI DATI funzioni base
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
#
ais[!complete.cases(ais)] # verifica la presenza di NA (dati mancanti)
colSums(is.na(ais)) # conteggia gli eventuale dati mancanti per colonna
#
summary(ais) # statistiche elementari per tutte le variabili (numeriche e non) di ais
#
media <- mean(ais$ferr) # calcola la media della ferritina
mediana <- median(ais$ferr) # calcola la mediana
data.frame(media, mediana) # le mette a confronto
#
ds <- sd(ais$ferr) # calcola la deviazione standard della ferritina
mad <- mad(ais$ferr) # calcola la Median Absolute Deviation (about the median) o MAD
data.frame(ds, mad) # le mette a confronto
#
qpar <- round(qnorm(c(seq(0.025, 0.975, 0.025)), mean=mean(ais$ferr),
sd=sd(ais$ferr)), digits=2) # calcola i quantili parametrici della ferritina
qnon <- round(quantile(ais$ferr, probs=seq(0.025, 0.975, 0.025)), digits=2) # calcola i
quantili non parametrici
```

```
data.frame(qpar, qnon) # li mette a confronto
#
windows() # apre e inizializza una nuova finestra grafica
boxplot(ais$ferr, range=1.5, horizontal=FALSE, main="Valori oltre la mediana ± 1.5 ·
IQR", ylab="Ferritina in µg/L", notch=FALSE, col="yellow") # rappresenta graficamente i
valori della ferritina
boxplot.stats(ais$ferr, coef=1.5)$stats # mostra i 5 punti notevoli dei baffi e della scatola
boxplot.stats(ais$ferr, coef=1.5)$out # mostra i valori che si trovano oltre la mediana ± 1.5
volte il range interquartile (IQR)
#
```

Con la prima riga di codice viene caricato il pacchetto che contiene la tabella **ais** con i dati che ci servono.

Quindi con la funzione **complete.cases()** viene fatta la ricerca dei casi con dati non (!) completi, nei quali dovremmo avere i dati mancanti sostituiti con la sigla NA (Not Available).

```
> ais[!complete.cases(ais)] # verifica la presenza di NA (dati mancanti)
data frame con 0 colonne e 202 righe
```

Con la funzione **colSums()** sono ricercati i dati mancanti **is.na()** per ciascuna delle colonne/variabili della tabella:

```
> colSums(is.na(ais)) # conteggia gli eventuale dati mancanti per colonna
rcc      wcc      hc      hg      ferr      bmi      ssf pcBfat      lbm      ht      wt
0         0         0         0         0         0         0         0         0         0         0
sex  sport
0      0
```

Ora sappiamo che nella tabella i dati sono completi, non abbiamo dati mancanti.

Segue la funzione **summary()** che per ciascuna variabile della tabella riporta valore minimo (**Min.**), primo quartile (**1st Qu.**), mediana o secondo quartile (**Median**), media (**Mean**), terzo quartile (**3rd Qu.**), valore massimo (**Max.**).

```
> summary(ais) # statistiche elementari per tutte le variabili (numeriche e non) di
ais
```

rcc	wcc	hc	hg
Min. :3.800	Min. : 3.300	Min. :35.90	Min. :11.60
1st Qu.:4.372	1st Qu.: 5.900	1st Qu.:40.60	1st Qu.:13.50
Median :4.755	Median : 6.850	Median :43.50	Median :14.70
Mean :4.719	Mean : 7.109	Mean :43.09	Mean :14.57
3rd Qu.:5.030	3rd Qu.: 8.275	3rd Qu.:45.58	3rd Qu.:15.57
Max. :6.720	Max. :14.300	Max. :59.70	Max. :19.20

ferr	bmi	ssf	pcBfat
Min. : 8.00	Min. :16.75	Min. : 28.00	Min. : 5.630
1st Qu.: 41.25	1st Qu.:21.08	1st Qu.: 43.85	1st Qu.: 8.545
Median : 65.50	Median :22.72	Median : 58.60	Median :11.650
Mean : 76.88	Mean :22.96	Mean : 69.02	Mean :13.507
3rd Qu.: 97.00	3rd Qu.:24.46	3rd Qu.: 90.35	3rd Qu.:18.080
Max. :234.00	Max. :34.42	Max. :200.80	Max. :35.520

lbm	ht	wt	sex	sport
Min. : 34.36	Min. :148.9	Min. : 37.80	f:100	Row :37
1st Qu.: 54.67	1st Qu.:174.0	1st Qu.: 66.53	m:102	T_400m :29

Median : 63.03	Median :179.7	Median : 74.40	B_Ball :25
Mean : 64.87	Mean :180.1	Mean : 75.01	Netball:23
3rd Qu.: 74.75	3rd Qu.:186.2	3rd Qu.: 84.12	Swim :22
Max. :106.00	Max. :209.4	Max. :123.20	Field :19
			(Other):47

In una distribuzione gaussiana media e mediana sono identiche [1]. Qui si osservano tra le due in genere valori abbastanza simili, tranne che nel caso della ferritina (`ferr`), della somma dello spessore delle pliche cutanee (`ssf`) e della percentuale di grasso corporeo (`pcBfat`).

Continuiamo quindi con l'analisi esplorativa dei dati, che per semplicità è qui limitata alla ferritina, calcolando e confrontando media e mediana

```
> media <- mean(ais$ferr) # calcola la media della ferritina
> mediana <- median(ais$ferr) # calcola la mediana
> data.frame(media, mediana) # le mette a confronto
      media mediana
1 76.87624    65.5
```

calcolando e confrontando deviazione standard e MAD

```
> ds <- sd(ais$ferr) # calcola la deviazione standard della ferritina
> mad <- mad(ais$ferr) # calcola la Median Absolute Deviation (about the median) o
MAD
> data.frame(ds, mad) # le mette a confronto
      ds      mad
1 47.50124 37.8063
```


e infine calcolando e confrontando quantili parametrici e quantili non parametrici

```
> qpar <- round(qnorm(c(seq (0.025, 0.975, 0.025)), mean = mean(ais$ferr), sd =
sd(ais$ferr)), digits=2) # calcola i quantili parametrici della ferritina
> qnon <- round(quantile(ais$ferr, probs = seq (0.025, 0.975, 0.025)), digits=2) #
calcola i quantili non parametrici
> data.frame(qpar, qnon) # li mette a confronto
      qpar  qnon
2.5% -16.22 20.00
5%   -1.26 22.00
7.5%  8.50 27.15
10%  16.00 30.00
12.5% 22.23 33.12
15%  27.64 35.15
17.5% 32.48 37.18
20%  36.90 39.20
22.5% 40.99 41.00
25%  44.84 41.25
27.5% 48.48 43.00
30%  51.97 44.00
32.5% 55.32 48.00
35%  58.57 50.00
37.5% 61.74 53.00
40%  64.84 55.00
42.5% 67.89 58.00
45%  70.91 59.45
47.5% 73.90 62.48
50%  76.88 65.50
```

52.5%	79.85	68.53
55%	82.85	71.00
57.5%	85.86	73.00
60%	88.91	76.00
62.5%	92.01	80.00
65%	95.18	85.65
67.5%	98.43	87.68
70%	101.79	90.70
72.5%	105.27	93.73
75%	108.92	97.00
77.5%	112.76	102.00
80%	116.85	107.00
82.5%	121.27	114.13
85%	126.11	122.00
87.5%	131.52	125.88
90%	137.75	138.40
92.5%	145.26	155.93
95%	155.01	182.95
97.5%	169.98	212.00

Nel caso di una distribuzione gaussiana quantili parametrici e quantili non parametrici devono essere identici [1] e qui non lo sono.

Per l'identificazione degli outliers impieghiamo la funzione **boxplot()** realizzando un grafico a scatola con i baffi (boxplot) nel quale sono riportati come singoli punti separati i dati che si trovano oltre la $\text{mediana} \pm 1.5 \text{ volte il range interquartile}$ (argomento **range=1.5**) [4].



Con le due ultime righe dello script sono quindi presentati due risultati della funzione **boxplot.stats()**.

Con **\$stats** sono riportati i valori delle ferritina corrispondenti:

→ al baffo inferiore (8.0)

→ al margine inferiore della scatola (41.0)

→ alla mediana (65.5)
→ al margine superiore della scatola (97.0)
→ al baffo superiore (177.0)

```
> boxplot.stats(ais$ferr, coef=1.5)$stats # mostra i 5 punti notevoli dei baffi e della scatola  
[1] 8.0 41.0 65.5 97.0 177.0
```

Con **\$out** sono riportati i dati anomali (182 183 212 213 184 220 191 189 212 234 214 233), o outliers.

```
> boxplot.stats(ais$ferr, coef=1.5)$out # mostra i valori che si trovano oltre la mediana ± 1.5 volte il range interquartile (IQR)  
[1] 182 183 212 213 184 220 191 189 212 234 214 233
```

Si tratta dei dati che nel grafico si trovano oltre la mediana ± 1.5 volte il range interquartile (argomento **coef=1.5**), che non per questo devono essere esclusi dalle statistiche, ma sui quali sarebbe opportuno, dato il loro eccessivo scostamento dai dati rimanenti, effettuare una rivalutazione (cosa qui ovviamente impraticabile non avendo accesso alla complessa catena di eventi che ha portato alla produzione dei dati).

Oltre alla funzione **summary()** inclusa nel pacchetto base di **R** [5] altre funzioni [6] per l'analisi esplorativa dei dati sono disponibili nei pacchetti **Hmisc**, **pastecs**, **psych**.

Potete scaricare e installare i pacchetti aggiuntivi dal **CRAN** e trovate la loro documentazione completa, incluso il manuale di riferimento, sul repository della documentazione di **R** [7].

Copiate questo script, incollatelo nella Console di R e premete ↵ Invio:

```
# ANALISI ESPLORATIVA DEI DATI funzioni per una analisi globale  
#  
library(DAAG) # carica il pacchetto DAAG incluso il set di dati ais  
mydata <- ais[c(1,2,3,4,5,6,7,8,9,10,11)] # salva le colonne con le sole variabili numeriche in mydata  
#  
summary(mydata) # statistiche elementari per tutte le variabili  
#  
library(Hmisc) # carica il pacchetto  
describe(mydata) # statistiche del pacchetto Hmisc  
#  
library(pastecs) # carica il pacchetto  
stat.desc(mydata) # statistiche del pacchetto pastecs  
#  
library(psych) # carica il pacchetto  
describe(mydata) # statistiche del pacchetto psych  
describeBy(mydata, ais$sex) # statistiche del pacchetto psych separate per sesso  
describeBy(mydata, ais$sport) # statistiche del pacchetto psych separate per sport  
#
```

Le funzioni espongono, ciascuna a modo proprio, il quadro dei dati fornito dalla funzione **summary()** del pacchetto base di **R**, e sono state riportate perché ciascuno ne possa valutare i risultati e l'utilità per gli scopi che si propone.

L'aspetto forse più interessante è rappresentato dalla possibilità offerta dalla funzione **describeBy()** del pacchetto **psych** di riportare statistiche riepilogative riaggregando i dati in base ai fattori presenti nei record, e quindi, nel caso specifico, di riportare statistiche separate per

sesto (m,f), come pure statistiche separate per ciascuno degli sport praticati dagli atleti (B_Ball, Field, Gym, Netball, Row, Swim, T_400m, T_Sprnt, Tennis, W_Polo).

Conclusione: l'analisi esplorativa dei dati fornisce informazioni utili a evidenziare per la ferritina alcuni problemi che meritano di essere approfonditi, valutati e opportunamente gestiti continuando a seguire le fasi del percorso logico riportato all'inizio.

Potete riutilizzare facilmente lo script sostituendo all'oggetto **ais** l'oggetto contenente i vostri dati, opportunamente strutturati. Per una guida rapida all'importazione dei dati potete consultare i link:

- [importare i dati di un file .csv](#)
- [importare i dati di un file .xls o .xlsx](#)
- [gestione dei dati mancanti](#)

[1] Una tipica distribuzione gaussiana è riportata nel post: [La distribuzione gaussiana](#).

[2] Vedere il post [Il set di dati ais](#) nel quale trovate anche come caricare i dati della tabella senza impiegare il pacchetto **DAAG**. Per manuale di riferimento del pacchetto vedere nel repository della documentazione: *Package 'DAAG'*.

<https://cran.stat.unipd.it/web/packages/DAAG/DAAG.pdf>

[3] La “*Median Absolute Deviation (about median)*” o MAD ovvero la deviazione assoluta mediana (dalla mediana) è l'equivalente non parametrico della deviazione standard e in una distribuzione gaussiana ha lo stesso valore di questa. Vedere: Rousseeuw PJ, Croux C. *Alternatives to the Median Absolute Deviation*. Journal of the American Statistical Association 88 (424), 1273-1283, 1993.

https://www.jstor.org/stable/2291267?seq=1#page_scan_tab_contents

[4] Per i dettagli sulla funzione **boxplot()** digitare **help(boxplot)** nella Console di R e vedere il post [Grafici a scatola con i baffi](#).

[5] Vedere il manuale di riferimento del pacchetto base R: *A Language and Environment for Statistical Computing, Reference Index*.

<https://cran.r-project.org/doc/manuals/r-release/fullrefman.pdf>

[6] Per la loro documentazione digitate **help(nomedellafunzione)** nella Console di R.

[7] *Available CRAN Packages By Name*.

https://cran.r-project.org/web/packages/available_packages_by_name.html
