

Test di normalità (gaussianità)

Siamo al secondo passo delle valutazioni preliminari che è sempre necessario effettuare nell'ambito di un percorso logico che prevede, per il calcolo delle statistiche elementari di una singola variabile (analisi univariata), i seguenti passi:

→ [analisi esplorativa dei dati](#);

→ esecuzione dei **test di normalità (gaussianità)** per valutare se i dati seguono una distribuzione gaussiana [1];

→ calcolo delle [statistiche elementari parametriche](#) (media, deviazione standard, varianza, quantili parametrici) se i dati seguono una distribuzione gaussiana [2];

→ calcolo delle [statistiche elementari non parametriche](#) (mediana, deviazione assoluta mediana o MAD, quartili e altri quantili non parametrici) se i dati non seguono una distribuzione gaussiana.

I dati sono contenuti nella tabella **ais** del pacchetto **DAAG** - accertatevi di avere installato il pacchetto o in alternativa procedete come indicato in [3]. Dovete scaricare e installare anche i pacchetti **moments** e **nortest**. Trovate la loro documentazione completa, incluso il manuale di riferimento, sul repository della documentazione di **R** [4].

Copiate lo script, incollatelo nella Console di R e premete ↵ Invio:

```
# TEST DI NORMALITA' (GAUSSIANITA')
#
library(DAAG) # carica il pacchetto DAAG incluso il set di dati ais
library(moments) # carica il pacchetto per asimmetria e curtosi
library(nortest) # carica il pacchetto per ulteriori test di normalità
#
mydata <- as.matrix(ais[c(5)]) # ci interessa la sola colonna con la ferritina
#
options(scipen=999) # esprime i numeri in formato fisso
#
agostino.test(mydata) # test di D'Agostino per il coefficiente di asimmetria
anscombe.test(mydata) # test di Anscombe-Glynn per il coefficiente di curtosi
#
ad.test(mydata) # test di Anderson-Darling per la normalità
cvm.test(mydata) # test di Cramer-von Mises per la normalità
pearson.test(mydata) # test chi-quadrato di Pearson per la normalità
sf.test(mydata) # test di Shapiro-Francia per la normalità
#
options(scipen=0) # ripristina la notazione scientifica
#
```

Dopo avere installato i tre pacchetti necessari, selezionato la colonna **5** contenente i dati che ci interessano, imposto di riportare i numeri in formato fisso con **scipen=999**, sono eseguiti il test di asimmetria, il test di curtosi e altri quattro test di normalità per la variabile **ferritina** [5]:

```
> agostino.test(mydata) # test di D'Agostino per il coefficiente di asimmetria
```

```
      D'Agostino skewness test
```

```
data:  mydata
skew = 1.2806, z = 6.1376, p-value = 0.0000000008377
alternative hypothesis: data have a skewness
```

```
> anscombe.test(mydata) # test di Anscombe-Glynn per il coefficiente di curtosi
```

Anscombe-Glynn kurtosis test

```
data: mydata
kurt = 4.4202, z = 2.9449, p-value = 0.003231
alternative hypothesis: kurtosis is not equal to 3
```

```
> ad.test(mydata) # test di Anderson-Darling per la normalità
```

Anderson-Darling normality test

```
data: mydata
A = 6.097, p-value = 0.000000000000004904
```

```
> cvm.test(mydata) # test di Cramer-von Mises per la normalità
```

Cramer-von Mises normality test

```
data: mydata
W = 0.94473, p-value = 0.000000002495
```

```
> pearson.test(mydata) # test chi-quadrato di Pearson per la normalità
```

Pearson chi-square normality test

```
data: mydata
P = 63.772, p-value = 0.00000002531
```

```
> sf.test(mydata) # test di Shapiro-Francia per la normalità
```

Shapiro-Francia normality test

```
data: mydata
W = 0.89138, p-value = 0.000000001251
```

Tutti i test di normalità concordano - con valori di p sempre di molto inferiori al valore soglia tradizionalmente impiegato di $p=0.05$ - nell'attribuire ai valori della ferritina una distribuzione non gaussiana [6].

Se nello script sostituite **ais[c(5)]** con **ais[c(10)]** potete eseguire i test di normalità sulla variabile **altezza** (espressa in centimetri, cm), ottenendo questi risultati:

```
> agostino.test(mydata) # test di D'Agostino per il coefficiente di asimmetria
```

D'Agostino skewness test

```
data: mydata
skew = -0.1993, z = -1.1856, p-value = 0.2358
alternative hypothesis: data have a skewness
```

```
> anscombe.test(mydata) # test di Anscombe-Glynn per il coefficiente di curtosi
```

Anscombe-Glynn kurtosis test

```
data: mydata
kurt = 3.5281, z = 1.5412, p-value = 0.1233
alternative hypothesis: kurtosis is not equal to 3
```

```
> ad.test(mydata) # test di Anderson-Darling per la normalità
```

```
Anderson-Darling normality test
```

```
data: mydata
```

```
A = 0.4462, p-value = 0.2793
```

```
> cvm.test(mydata) # test di Cramer-von Mises per la normalità
```

```
Cramer-von Mises normality test
```

```
data: mydata
```

```
W = 0.058974, p-value = 0.3886
```

```
> pearson.test(mydata) # test chi-quadrato di Pearson per la normalità
```

```
Pearson chi-square normality test
```

```
data: mydata
```

```
P = 17.653, p-value = 0.223
```

```
> sf.test(mydata) # test di Shapiro-Francia per la normalità
```

```
Shapiro-Francia normality test
```

```
data: mydata
```

```
W = 0.98919, p-value = 0.1174
```

I risultati, con valori sempre abbondantemente superiori al $p=0.05$, ci dicono che questa volta siamo di fronte a dati distribuiti in modo gaussiano.

A conferma dei valori numerici forniti dai test di normalità aggiungiamo ora quattro grafici, partendo da quello della **ferritina**. Copiate questo script, incollatelo nella Console di R e premete ↵ Invio:

```
# VALUTAZIONE GRAFICA DELLA NORMALITA' (GAUSSIANITA')
```

```
#
```

```
library(DAAG) # carica il pacchetto DAAG incluso il set di dati ais
```

```
#
```

```
mydata <- as.matrix(ais[c(5)]) # ci interessa la sola colonna con la ferritina
```

```
#
```

```
windows() # apre una nuova finestra
```

```
par(mfrow=c(2,2)) # predispone la suddivisione della finestra in quattro quadranti, uno per grafico
```

```
#
```

```
# istogramma e kernel density plot
```

```
#
```

```
hist(mydata, xlim=c(0, 250), ylim=c(0, 0.020), freq=FALSE, breaks=25,
```

```
main="Istogramma\ne kernel density plot", xlab="Ferritina in µg/L", ylab="Densità di probabilità") # traccia l'istogramma dei dati
```

```
par(new=TRUE, ann=FALSE) # consente di sovrapporre il grafico successivo
```

```
plot(density(mydata, n=1000, from=0, to=250), xlim=c(0,250), ylim=c(0,
```

```
0.020), yaxt="n", col="black") # sovrappone il kernel density plot della distribuzione campionaria
```

```
#
```

```
# distribuzione campionaria vs. gaussiana teorica
```

```
#
```

```

plot(density(mydata, n=1024, from=0, to=250), xlim=c(0, 250), ylim=c(0, 0.012)) #
traccia il kernel density plot della distribuzione campionaria
par(new=TRUE, ann=FALSE) # consente di sovrapporre il grafico successivo
x <- seq(0, 250, length.out=1000) # calcola i valori in ascisse della gaussiana teorica
y <- dnorm(x, mean=mean(mydata), sd=sd(mydata)) # calcola i valori in ordinate della
gaussiana teorica
plot(x, y, xlim=c(0, 250), ylim=c(0, 0.012), yaxt="n", col="red", type="l") # sovrappone la
distribuzione gaussiana teorica in colore rosso
title(main="Distribuzione campionaria\nvs. gaussiana teorica", xlab="Ferritina in µg/L",
ylab="Densità di probabilità") # aggiunge titolo e legende degli assi
#
# distribuzione cumulativa campionaria vs. distribuzione cumulativa teorica
#
par(new=FALSE, ann=TRUE) # per mostrare titolo e legende degli assi
plot(ecdf(scale(mydata)), main="Cumulativa campionaria\nvs. cumulativa teorica",
xlab="Deviata normale standardizzata z", ylab="Frequenza cumulativa", xlog = FALSE,
ylog = FALSE, xlim=c(-4, 4), ylim=c(0, 1), xaxp=c(-4, 4, 5), yaxp=c(0, 1, 5)) # traccia il
grafico della distribuzione cumulativa campionaria
par(new=TRUE, ann=FALSE) # consente di sovrapporre il grafico successivo
plot(ecdf(rnorm(10000, mean=0, sd=1)), col="red", xlog=FALSE, ylog=FALSE, xlim=c(-4,
4), ylim=c(0, 1), xaxp=c(-4, 4, 5), yaxp=c(0, 1, 5)) # sovrappone la distribuzione cumulativa
teorica in colore rosso
#
# quantili campionari vs. quantili teorici
#
par(new=FALSE, ann=TRUE) # per mostrare titolo e legende degli assi
qqnorm(scale(mydata), main="Quantili campionari\nvs. quantili teorici", xlab="Quantili
teorici", ylab="Quantili campionari", xlim=c(-4, 4), ylim=c(-4, 4)) # traccia il grafico della
distribuzione dei quantili campionari
abline (0, 1, col="red") # sovrappone la distribuzione dei quantili teorica in colore rosso
#


```

Con la funzione **par(mfrow=c(2,2))** la finestra grafica viene suddivisa in quattro quadranti, che verranno riempiti da sinistra a destra e dall'alto verso il basso dai quattro grafici generati con i successivi blocchi di codice, migliorando la sintesi dei risultati.


Per le funzioni qui riportate [7] sono previsti molti altri possibili argomenti, per i quali si rimanda alla documentazione di **R**. Quelli che vi capiterà di utilizzare più frequentemente, a parte ovviamente la variabile da analizzare, che è sempre il primo argomento in ogni funzione, sono:

- **main**, il titolo del grafico, che compare in alto;
- **xlab**, l'etichetta dell'asse delle ascisse x;
- **ylab**, l'etichetta dell'asse delle ordinate y;
- **xlim**, che indica limite inferiore e limite superiore della scala da applicare all'asse delle ascisse x;
- **ylim**, che indica limite inferiore e limite superiore della scala da applicare all'asse delle ordinate y;
- **xaxp**, che specifica il limite inferiore, il limite superiore e il numero di intervalli da applicare alla scala dell'asse delle ascisse x;
- **yaxp**, che specifica il limite inferiore, il limite superiore e il numero di intervalli da applicare alla scala dell'asse delle ordinate y.

Questi sono i quattro grafici risultanti, con la distribuzione dei dati campionari (in colore nero) che si discosta dalla distribuzione gaussiana teorica prevista (in colore rosso) confermando anche visivamente che i valori di concentrazione delle ferritina nei 202 atleti australiani non sono distribuiti in modo gaussiano.



Se nello script sostituite **ais[c(5)]** con **ais[c(10)]** e aggiustate le scale degli assi potete visualizzare il grafico dei valori della variabile **altezza**.



Questi sono i quattro grafici risultanti, che mostrano come la distribuzione dei dati campionari (in colore nero) segue la distribuzione gaussiana teorica prevista (in colore rosso), illustrando graficamente quanto avevamo già visto con i test di normalità: i valori di altezza nei 202 atleti australiani sono distribuiti in modo gaussiano.

Conclusione:

→ nel caso della ferritina i dati non sono distribuiti in modo gaussiano, pertanto dovremo impiegare metodi non parametrici e calcoleremo la mediana, la deviazione assoluta mediana o MAD e i quantili non parametrici;
→ nel caso dell'altezza i dati sono distribuiti in modo gaussiano, pertanto potremo impiegare metodi parametrici e calcoleremo la media, la deviazione standard e i quantili parametrici.

[1] Ghasemi A, Zahediasl S. *Normality Tests for Statistical Analysis: A Guide for Non-Statisticians*. Int J Endocrinol Metab. 2012;10(2);486–489.

<https://pmc.ncbi.nlm.nih.gov/articles/PMC3693611/>

[2] Per il quadro tipico di una distribuzione gaussiana vedere il post: [La distribuzione gaussiana](#)

[3] Vedere i dati ematologici e i dati biometrici rilevati in 202 atleti australiani nel post [Il set di dati ais](#) nel quale trovate anche come caricare i dati della tabella senza impiegare il pacchetto **DAAG**.

[4] *Available CRAN Packages By Name*.

https://cran.r-project.org/web/packages/available_packages_by_name.html

[5] La ferritina è una proteina che, pur con alcune limitazioni, fornisce una misura dei depositi di ferro presenti nell'organismo, necessari per garantire una adeguata produzione di emoglobina. La concentrazione è espressa in µg/L.

[6] Se si vogliono avere i risultati di questi test di normalità sotto forma di una tabella compatta, vedere il post [Tabulare una serie di test di normalità \(gaussianità\)](#)

[7] Per la documentazione delle funzioni digitare **help(nomedellafunzione)** nella Console di R. Per gli argomenti **xlog**, **ylog**, **xlim**, **ylim**, **xaxp**, **yaxp** vedere anche la funzione **par()** con **help(par)**.
