

Statistiche elementari non parametriche

Siamo all'ultimo passo delle valutazioni preliminari che è sempre necessario effettuare nell'ambito di un percorso logico che prevede, per il calcolo delle statistiche elementari di una singola variabile (analisi univariata):


→ [analisi esplorativa dei dati](#);

→ esecuzione dei [test di normalità \(gaussianità\)](#) per valutare se i dati seguono una distribuzione gaussiana;

→ calcolo delle [statistiche elementari parametriche](#) (media, deviazione standard, varianza, quantili parametrici) se i dati seguono una distribuzione gaussiana;

→ calcolo delle **statistiche elementari non parametriche** (mediana, deviazione assoluta mediana o MAD, quartili e altri quantili non parametrici) se i dati non seguono una distribuzione gaussiana.

Si tratta del passo conclusivo per la variabile concentrazione della **ferritina** (espressa in $\mu\text{g/L}$) rilevata in 202 atleti australiani, in quanto con i test di normalità abbiamo stabilito che la variabile non è distribuita in modo gaussiano come risulta evidente anche dalla sintesi grafica dei risultati.



Copiate lo script, incollatelo nella Console di R e premete ↵ Invio:

```
# STATISTICHE ELEMENTARI NON PARAMETRICHE
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
mydata <- unlist(ais[c(5)]) # ci interessa la sola colonna con la ferritina
#
# statistiche elementari non parametriche
#
min(mydata) # valore minimo
median(mydata) # mediana
max(mydata) # valore massimo
range(mydata) # range
max(mydata)-min(mydata) # campo di variazione
```

```

mad(mydata) # deviazione assoluta mediana (MAD)
quantile(mydata) # quartili
#
# quartili, decili e percentili della distribuzione campionaria
#
quantile(mydata, probs=seq(0, 1, 0.25)) # con 0.25 calcola i quartili della ferritina
quantile(mydata, probs=seq(0, 1, 0.1)) # con 0.1 calcola i decili
quantile(mydata, probs=seq(0, 1, 0.01)) # con 0.01 calcola i percentili
#

```

Non avrebbe senso ripetere l'analisi esplorativa dei dati, i test di normalità e la sintesi grafica dei risultati - per questi si rimanda agli script riportati nel percorso logico indicato all'inizio. Per cui qui ci limitiamo a calcolare le usuali statistiche elementari non parametriche.

Dopo avere caricato il pacchetto **DAAG** [1] contenente la tabella **ais**, la variabile `ferr` contenuta nella colonna **5** della tabella **ais** viene assegnata (**<-**) all'oggetto **mydata**, sul quale sono calcolate le statistiche elementari non parametriche con le funzioni:

- **min()** per riportare il valore minimo osservato;
- **median()** per calcolare la media;
- **max()** per riportare il valore massimo osservato;
- **range()** per calcolare il range qui correttamente inteso come *"intervallo (di valori di una grandezza)";*
- **max(mydata)-min(mydata)** per calcolare il campo di variazione, talora indicato (impropriamente) con il termine "range";
- **mad()** per calcolare la deviazione assoluta mediana MAD [2];
- **quantile()** per calcolare i quartili.

```

> min(mydata) # valore minimo
[1] 8
> median(mydata) # mediana
[1] 65.5
> max(mydata) # valore massimo
[1] 234
> range(mydata) # range
[1] 8 234
> max(mydata)-min(mydata) # campo di variazione
[1] 226
> mad(mydata) # deviazione assoluta mediana (MAD)
[1] 37.8063
> quantile(mydata) # quartili
      0%      25%      50%      75%     100%
8.00  41.25  65.50  97.00 234.00

```

Da notare che la funzione **quantile()**, se impiegata specificando come unico argomento il nome della variabile, prevede di default il calcolo dei quartili. Se si aggiunge l'argomento **probs** e si impiega la funzione **seq()** per stabilire la sequenza di valori per i quali calcolarli [3] è possibile calcolare i quantili desiderati, che in questo caso sono

- i quantili impostando **seq(0, 1, 0.25)**
- i decili impostando **seq(0, 1, 0.1)**
- i percentili impostando **seq(0, 1, 0.01)**

essendo a loro volta gli argomenti della funzione **seq()** il quantile iniziale (**0** che corrisponde al valore minimo osservato), il quantile finale (**1** che corrisponde al valore massimo osservato) e l'incremento da applicare per il calcolo dei quantili intermedi. Modificando opportunamente questi tre argomenti è possibile calcolare qualsiasi altra sequenza di quantili.

```

> quantile(mydata, probs=seq (0, 1, 0.25)) # con 0.25 calcola i quartili della
ferritina
      0%      25%      50%      75%     100%
      8.00     41.25     65.50     97.00    234.00
> quantile(mydata, probs=seq (0, 1, 0.1)) # con 0.1 calcola i decili
      0%      10%      20%      30%      40%      50%      60%      70%      80%      90%     100%
      8.0     30.0     39.2     44.0     55.0     65.5     76.0     90.7    107.0    138.4    234.0
> quantile(mydata, probs=seq (0, 1, 0.01)) # con 0.01 calcola i percentili
      0%      1%      2%      3%      4%      5%      6%      7%      8%      9%      10%
      8.00     13.03     19.02     20.03     21.04     22.00     25.06     26.07     29.00     29.09     30.00
      11%      12%      13%      14%      15%      16%      17%      18%      19%      20%      21%
     30.22     32.12     34.00     34.14     35.15     36.00     36.17     38.00     39.00     39.20     40.00
      22%      23%      24%      25%      26%      27%      28%      29%      30%      31%      32%
     40.22     41.00     41.00     41.25     43.00     43.00     43.28     44.00     44.00     45.31     46.64
      33%      34%      35%      36%      37%      38%      39%      40%      41%      42%      43%
     48.33     50.00     50.00     51.00     52.37     53.00     53.39     55.00     56.41     58.00     58.00
      44%      45%      46%      47%      48%      49%      50%      51%      52%      53%      54%
     58.44     59.45     60.46     61.47     63.48     64.00     65.50     66.51     68.00     69.00     70.54
      55%      56%      57%      58%      59%      60%      61%      62%      63%      64%      65%
     71.00     72.00     72.57     73.00     73.59     76.00     77.61     79.24     81.26     83.28     85.65
      66%      67%      68%      69%      70%      71%      72%      73%      74%      75%      76%
     86.66     87.00     88.00     89.69     90.70     91.71     93.00     94.00     97.00     97.00    100.52
      77%      78%      79%      80%      81%      82%      83%      84%      85%      86%      87%
    101.77    102.00    105.37    107.00    109.00    109.82    115.00    117.84    122.00    124.00    124.87
      88%      89%      90%      91%      92%      93%      94%      95%      96%      97%      98%
    126.88    131.78    138.40    142.82    154.60    163.44    176.94    182.95    188.80    211.37    212.98
      99%      100%
    219.94    234.00

```

Come al solito lo script può essere riutilizzato molto facilmente, assegnando (<-) all'oggetto **mydata** i propri dati.

[1] Vedere il post [Il set di dati ais](#) nel quale trovate anche come caricare i dati della tabella senza impiegare il pacchetto **DAAG**.

[2] La *Median Absolute Deviation about median* o MAD ovvero la deviazione assoluta mediana (dalla mediana) è l'equivalente non parametrico della deviazione standard. Vedere: Rousseeuw PJ, Croux C. *Alternatives to the Median Absolute Deviation*. Journal of the American Statistical Association 88 (424), 1273-1283, 1993.

https://www.jstor.org/stable/2291267?seq=1#page_scan_tab_contents

[3] Per la documentazione della funzione **seq()** digitare **help(seq)** nella Console di R.