

Regressione lineare ordinaria

La **regressione lineare** tout court, quella illustrata in tutti i testi di statistica e qui sviluppata con **R**, è:

- una regressione lineare semplice (in contrapposizione alla regressione lineare multipla);
- parametrica (in contrapposizione alla regressione lineare non parametrica);
- x variabile indipendente (in contrapposizione ad alternative che non prevedono questo assunto).

Dato che la denominazione razionale, quella completa, diverrebbe chilometrica, e dato che l'espressione regressione lineare è però troppo generica, laddove è opportuno semplificare impiegherò la denominazione **regressione lineare ordinaria**, con riferimento al fatto che è quella non solo dovunque illustrata ma anche più ampiamente impiegata.

Gli assunti alla base del modello matematico-statistico implicano una serie di requisiti che devono essere soddisfatti dai dati, che sono ben chiariti ad esempio in Marubini [1] e in Snedecor [2], ma anche online [3]. Per il caso speciale, ma non infrequente, nel quale nessuna delle due variabili confrontate abbia i requisiti richiesti per essere considerata come variabile indipendente, vedere anche [4].

Qualora invece sia necessario l'impiego di "metodi robusti" di regressione - cioè di metodi che risentono poco della eventuale presenza di dati apparentemente anomali ma che non possono essere esclusi a priori dal calcolo della regressione - è possibile impiegare un metodo non parametrico [5].

Tornando alla nostra regressione lineare semplice parametrica x variabile indipendente, essendo x la variabile indipendente posta sull'asse delle ascisse, y la variabile dipendente posta sull'asse delle ordinate, ed essendo soddisfatti i requisiti previsti per i dati, il metodo dei minimi quadrati consente di calcolare l'intercetta a e il coefficiente angolare b della retta di regressione di equazione

$$y = a + b \cdot x$$

che meglio approssima la distribuzione dei dati sperimentali.

Il calcolo dell'equazione della retta di regressione viene effettuato mediante la funzione **lm()**, che può essere applicata anche al caso di più variabili indipendenti, consentendo quindi il calcolo della regressione lineare multipla [4]. Ma la cosa più interessante è che **R**, oltre al calcolo dell'equazione della retta di regressione, un calcolo di per sé semplice, fornisce una serie di strumenti che consentono di valutare quanto i dati soddisfano i requisiti richiesti, e se la regressione lineare descrive in modo adeguato la relazione tra le due variabili.

Qui impieghiamo come esempi due diversi set di dati, nel primo dei quali l'applicazione della regressione lineare fornisce risultati convincenti, mentre nel secondo presenta alcuni problemi.

Il primo è il set di dati **ais**, nel quale prendiamo in considerazione la concentrazione degli eritrociti (espressa in $10^{12}/L$) e il valore ematòcrito (espresso in %), due variabili che, analizzate mediante i coefficienti di correlazione parametrici e non parametrici, hanno mostrato di essere correlate, e che, all'ispezione visiva di una serie di grafici di dispersione (xy) realizzati mediante i correlogrammi, hanno mostrato valori ben allineati su una possibile retta.

Per procedere dovete scaricare e installare dal **CRAN** i pacchetti aggiuntivi **gvlma** e **car**, oltre al pacchetto aggiuntivo **DAAG** [6].

Copiate e incollate nella Console di R questo script e premete ↵ Invio:

```
# REGRESSIONE LINEARE SEMPLICE PARAMETRICA  $y = a + b \cdot x$ 
```

```

#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(gvlma) # carica il pacchetto per la funzione gvlma()
library(car) # carica il pacchetto per analisi outliers e analisi grafica
str(ais) # mostra la struttura dei dati
#
var_x <- ais$rcc # variabile eritrociti x in ascisse
var_y <- ais$hc # variabile ematòcrito y in ordinate
reglin <- lm(var_y ~ var_x) # calcola intercetta (a) e coefficiente angolare (b)
coefficients(reglin) # mostra i coefficienti dell'equazione  $hc = a + b \cdot rcc$ 
confint(reglin, level=0.95) # calcola gli intervalli di confidenza dell'intercetta e del coefficiente
angolare
#
# analisi statistica della adeguatezza della regressione lineare
#
summary(reglin) # mostra un riepilogo dei risultati
t.test(residuals(reglin)) # verifica che la media degli errori non sia significativamente diversa da
zero
shapiro.test(residuals(reglin)) # verifica la normalità della distribuzione degli errori
summary(gvlma(reglin)) # test globale per l'assunto di linearità
outlierTest(reglin) # valore p di Bonferonni per la presenza di dati anomali (outliers)
#
# analisi grafica della adeguatezza della regressione lineare
#
windows() # apre una nuova finestra
par(mfrow=c(2,2)) # predispone la suddivisione della finestra in quattro quadranti, uno per grafico
#
newx = seq(min(var_x), max(var_x), by = 0.01) # valori della x per i quali calcolare l'intervallo
di confidenza
conf_interval <- predict(reglin, newdata=data.frame(var_x=newx), interval="confidence",
level = 0.95) # calcola gli intervalli di confidenza
plot(var_x, var_y, xlab="Eritrociti (10^12/L)", ylab="Ematòcrito (%)",
main="Regressione lineare  $y = a + b \cdot x$ ") # grafico dei dati
abline(reglin, col="lightblue") # retta di regressione
lines(newx, conf_interval[,2], col="blue", lty=2) # limite di confidenza inferiore
lines(newx, conf_interval[,3], col="blue", lty=2) # limite di confidenza superiore
#
plot(var_y, residuals(reglin), xlab="Ematòcrito (%)", ylab="Ematòcrito osservato -
calcolato (%)", main="Analisi delle differenza residue") # grafico delle differenza tra
ematòcrito osservato e ematòcrito calcolato con l'equazione della retta
#
influencePlot(reglin, fill=FALSE, xlab="t-quantili (il diametro dei cerchi", sub="è
proporzionale alla distanza di Cook)", ylab="Residui studentizzati", main="Influenza dei
dati") # grafico dell'influenza dei dati sulle conclusioni
#
qqPlot(reglin, xlab="t-quantili", ylab="Residui studentizzati", main="Quantili vs.
residui") # mostra il grafico dei quantili per i residui studentizzati
#

```

Dopo avere caricato i pacchetti aggiuntivi e i dati, e dopo avere mostrato con **str(ais)** la struttura di questi ultimi, con **var_x <- ais\$rcc** e con **var_y <- ais\$hc** sono memorizzate negli oggetti **var_x** e **var_y** rispettivamente la variabile indipendente x, posta in ascisse, e la variabile dipendente y, posta in ordinate. In questo modo sarà possibile riutilizzare per intero lo script semplicemente sostituendo ad **ais\$rcc** e ad **ais\$hc** i vettori contenenti i propri dati.

Con **reglin <- lm(var_y ~ var_x)** l'equazione della retta di regressione che esprime la y in funzione della x viene calcolata e memorizzata nell'oggetto **reglin**, che a questo punto diventa l'argomento chiave, l'argomento contenente i dati in ingresso impiegati nelle funzioni successive [7].

Con le funzioni **coefficients()** e **confint()** sono infine mostrati i coefficienti della retta di regressione e i loro intervalli di confidenza al 95%

```
> coefficients(reglin) # mostra i coefficienti dell'equazione hc = a + b · rcc
(Intercept)      var_x
   8.183033    7.398052
> confint(reglin, level=0.95) # calcola gli intervalli di confidenza dell'intercetta
e del coefficiente angolare
              2.5 %    97.5 %
(Intercept) 6.173717 10.192350
var_x       6.974206  7.821898
```

e pertanto questa risulta essere l'equazione della retta di regressione:

$$hc = 8.183033 + 7.398052 \cdot rcc$$

A questo punto seguono due blocchi di codice, il primo per effettuare una analisi statistica, e il secondo per effettuare una analisi grafica della regressione, entrambe allo scopo di valutare, come già detto, se la regressione lineare descrive in modo adeguato la relazione tra le due variabili.

Per quanto concerne l'analisi statistica, le principali conclusioni sono quelle tratte con il **test globale per l'assunto di linearità** effettuato mediante la funzione **gvlma()**, che conferma il fatto che gli assunti che stanno alla base del modello di regressione lineare sono tutti soddisfatti:

```
ASSESSMENT OF THE LINEAR MODEL ASSUMPTIONS
USING THE GLOBAL TEST ON 4 DEGREES-OF-FREEDOM:
Level of Significance = 0.05
```


```
Call:
gvlma(x = reglin)
```

	Value	p-value	Decision
Global Stat	3.479904	0.4809	Assumptions acceptable.
Skewness	2.233166	0.1351	Assumptions acceptable.
Kurtosis	0.958154	0.3277	Assumptions acceptable.
Link Function	0.005239	0.9423	Assumptions acceptable.
Heteroscedasticity	0.283345	0.5945	Assumptions acceptable.

Il **test di Bonferroni** non evidenzia dati anomali, ma segnala il dato numero **68** come quello che maggiormente si discosta dai rimanenti:

```
> outlierTest(reglin) # valore p di Bonferonni per la presenza di dati anomali
(outliers)
No Studentized residuals with Bonferonni p < 0.05
Largest |rstudent|:
      rstudent unadjusted p-value Bonferonni p
68 -3.569525      0.00044828      0.090552
```

Le conclusioni dell'analisi grafica confermano, con valori delle **differenze residue** dispersi in modo casuale (aspetto che risulterà più chiaro confrontandolo con quanto accade nel prossimo set di dati), che la regressione lineare descrive in modo adeguato la relazione tra le due variabili



anche se si nota la presenza di possibili dati anomali con il **grafico delle distanze di Cook** e con il **grafico dei quantili**, dati che sono evidenziati sia direttamente nei grafici, sia nei rispettivi riepiloghi riportati nella Console di R:

```
> influencePlot(reglin, xlab="t-quantili (il diametro dei cerchi", sub="è
proporzionale alla distanza di Cook)", ylab="Residui studentizzati", main="Influenza
dei dati") # grafico dell'influenza dei dati sulle conclusioni

      StudRes      Hat      CookD
68  -3.569525 0.006301040 0.03815682
78   3.186317 0.009724284 0.04766681
161 -2.179789 0.039758811 0.09655642
166  1.363972 0.099962743 0.10287127
> #

> qqPlot(reglin, xlab="t-quantili", ylab="Residui studentizzati", main="Quantili vs.
residui") # mostra il grafico dei quantili per i residui studentizzati
[1] 68 78
```

I dati per i quali i metodi di identificazione meglio concordano sono il numero 68 e il numero 78, ma anche i dati numero 161 e numero 166 meritano di essere valutati. Si tratta di casi dei quali sarebbe importante controllare la validità, o che potrebbero essere situati in intervalli di valori per i quali potrebbe essere opportuno acquisire più dati.

Vediamo ora la stessa identica analisi applicata al set di dati galton [8]. I pacchetti aggiuntivi **psychTools**, **gvlma** e **car**, se non l'avete già fatto, devono essere preventivamente scaricati e installati dal **CRAN** [9].

Copiate e incollate nella Console di R questo script e premete ↵ Invio:

```
# REGRESSIONE LINEARE SEMPLICE PARAMETRICA  $y = a + b \cdot x$ 
#
library(psychTools) # carica il pacchetto che include il set di dati galton
library(gvlma) # carica il pacchetto per la funzione gvlma()
library(car) # carica il pacchetto per analisi outliers e analisi grafica
```

```

str(galton) # mostra la struttura dei dati
#
var_x <- galton$parent # variabile altezza dei padri x in ascisse
var_y <- galton$child # variabile altezza dei figli y in ordinate
reglin <- lm(var_y ~ var_x) # calcola intercetta (a) e coefficiente angolare (b)
coefficients(reglin) # mostra i coefficienti dell'equazione  $hc = a + b \cdot rcc$ 
confint(reglin, level=0.95) # calcola gli intervalli di confidenza dell'intercetta e del coefficiente
angolare
#
# analisi statistica della adeguatezza della regressione lineare
#
summary(reglin) # mostra un riepilogo dei risultati
t.test(residuals(reglin)) # verifica che la media degli errori non sia significativamente diversa da
zero
shapiro.test(residuals(reglin)) # verifica la normalità della distribuzione degli errori
summary(gvlma(reglin)) # test globale per l'assunto di linearità
outlierTest(reglin) # valore p di Bonferonni per la presenza di dati anomali (outliers)
#
# analisi grafica della adeguatezza della regressione lineare
#
windows() # apre una nuova finestra
par(mfrow=c(2,2)) # predispone la suddivisione della finestra in quattro quadranti, uno per grafico
#
newx = seq(min(var_x), max(var_x), by = 0.01) # valori della x per i quali calcolare l'intervallo
di confidenza
conf_interval <- predict(reglin, newdata=data.frame(var_x=newx), interval="confidence",
level = 0.95) # calcola gli intervalli di confidenza
plot(var_x, var_y, xlab="Altezza dei padri (pollici)", ylab="Altezza dei figli (pollici)",
main="Regressione lineare  $y = a + b \cdot x$ ") # grafico dei dati
abline(reglin, col="lightblue") # retta di regressione
lines(newx, conf_interval[,2], col="blue", lty=2) # limite di confidenza inferiore
lines(newx, conf_interval[,3], col="blue", lty=2) # limite di confidenza superiore
#
plot(var_y, residuals(reglin), xlab="Altezza dei figli (pollici)", ylab="Altezza osservata -
calcolata (pollici)", main="Analisi delle differenze residue") # grafico delle differenze tra
altezza osservata e altezza calcolata con l'equazione della retta
#
influencePlot(reglin, fill=FALSE, xlab="t-quantili (il diametro dei cerchi", sub="è
proporzionale alla distanza di Cook)", ylab="Residui studentizzati", main="Influenza dei
dati") # grafico dell'influenza dei dati sulle conclusioni
#
qqPlot(reglin, xlab="t-quantili", ylab="Residui studentizzati", main="Quantili vs.
residui") # mostra il grafico dei quantili per i residui studentizzati
#

```

Anche in questo caso, per quanto concerne l'analisi statistica, le principali conclusioni sono quelle tratte con il test globale per l'assunto di linearità effettuato mediante la funzione **gvlma()**, che però questa volta ci dice che gli assunti che stanno alla base del modello di regressione lineare, a parte la curiosità, non sono per niente soddisfatti:

```

ASSESSMENT OF THE LINEAR MODEL ASSUMPTIONS
USING THE GLOBAL TEST ON 4 DEGREES-OF-FREEDOM:
Level of Significance = 0.05

```

```

Call:
gvlma(x = reglin)


```

	Value	p-value	Decision
Global Stat	25.489	4.011e-05	Assumptions NOT satisfied!
Skewness	8.979	2.731e-03	Assumptions NOT satisfied!
Kurtosis	1.965	1.610e-01	Assumptions acceptable.
Link Function	4.632	3.138e-02	Assumptions NOT satisfied!
Heteroscedasticity	9.913	1.641e-03	Assumptions NOT satisfied!

Il **test di Bonferroni** non evidenzia dati anomali, ma segnala il dato numero 1 come quello che maggiormente si discosta dai rimanenti:

```
> outlierTest(reglin) # valore p di Bonferonni per la presenza di dati anomali
(outliers)
No Studentized residuals with Bonferonni p < 0.05
Largest |rstudent|:
      rstudent unadjusted p-value Bonferonni p
1 -3.512671      0.00046509      0.43161
```

Le conclusioni dell'analisi grafica confermano, con i valori delle **differenze residue** che mostrano una proporzionalità diretta con l'altezza, che i dati in questione violano uno degli assunti del modello di regressione lineare



e confermano anche la possibile presenza di dati anomali con il **grafico delle distanze di Cook** e con il **grafico dei quantili**, dati che sono evidenziati sia direttamente nei grafici, sia nei rispettivi riepiloghi riportati nella Console di R:

```
> influencePlot(lm(galton$child ~ galton$parent), xlab="t-quantili (il diametro dei
cerchi", sub="è proporzionale alla distanza di Cook)", ylab="Residui studentizzati",
main="Influenza dei dati") # grafico dell'influenza dei dati sulle conclusioni
```

	StudRes	Hat	CookD
1	-3.5126706	0.002699826	0.016499436
2	-2.9226403	0.001090010	0.004622768
857	0.4839886	0.008511029	0.001006222

```

897 2.6611087 0.003740530 0.013207269
898 0.9327550 0.008511029 0.003734739
> #
> qqPlot(lm(galton$child ~ galton$parent), xlab="t-quantili", ylab="Residui
studentizzati", main="Quantili vs. residui") # mostra il grafico dei quantili per i
residui studentizzati
[1] 1 2

```

I dati numero [1](#), [2](#), [857](#), [897](#), [898](#) forniti dalla funzione **influencePlot()** stanno di nuovo a indicare i casi che influenzano in modo importante la regressione, casi dei quali sarebbe importante controllare la validità, o che potrebbero essere situati in intervalli di valori per i quali potrebbe essere opportuno acquisire più dati. Anche la funzione **qqPlot()** fornisce, oltre al grafico, l'indicazione di due punti da controllare, che sono punti [1](#), [2](#) già indicati dalla funzione precedente.

Il set di dati galton, oltre a non soddisfare uno dei requisiti richiesti per l'applicazione della regressione lineare ordinaria, è anche un esempio di dati nei quali non è chiaro, a dispetto delle conclusioni tratte da Francis Galton di una "regressione verso la media" delle altezze dei figli rispetto a quelle dei padri, quale delle due variabili debba essere considerata la variabile indipendente. Le implicazioni di questo fatto, le conseguenze che esso determina nelle conclusioni tratte dalla regressione lineare, e il calcolo della regressione lineare con modelli alternativi, sono discussi a parte nel post [La regressione lineare: assunti e modelli](#).

Entrambi gli script sono stato realizzati in modo da rendere immediato il loro riutilizzo: è sufficiente assegnare alla variabile x (**var_x <-**) e alla variabile y (**var_y <-**) i vostri nuovi dati (e personalizzare opportunamente titoli e legende).

Per una guida rapida all'importazione dei dati potete consultare i link:

- [importazione dei dati da un file .csv](#)
- [importazione dei dati da un file .xls o .xlsx](#)
- [gestione dei dati mancanti](#)

[1] Bossi A, Cortinovis I, Duca PG, Marubini E. *Introduzione alla statistica medica*. La Nuova Italia Scientifica, Roma, 1994, ISBN 88-430-0284-8. *Il modello statistico nella regressione lineare*, pp. 305-308.

[2] Snedecor GW, Cochran WG. *Statistical Methods*. The Iowa State University Press, 1980, ISBN 0-8138-1560-6. *The matematical model in linear regression*, pp. 153-157.

[3] *Regressione lineare*.
https://it.wikipedia.org/wiki/Regressione_lineare

[4] Vedere il post [La regressione lineare: assunti e modelli](#).

[5] Vedere il post [Regressione lineare semplice non parametrica](#).

[6] Vedere il post [Il set di dati ais](#) nel quale trovate anche come caricare i dati della tabella senza impiegare il pacchetto **DAAG**.

[7] Digitate **help(lm)** nella Console di R per la documentazione della funzione **lm()**.

[8] Vedere il post [Il set di dati galton](#).

[9] Informazioni esaurienti sono contenute nei manuali di riferimento dei pacchetti aggiuntivi qui impiegati, che trovate alla pagina *Available CRAN Packages By Name*.

https://cran.r-project.org/web/packages/available_packages_by_name.html
