



Regressione lineare media geometrica

Per illustrare il tema, è opportuno ricordare gli assunti alla base della regressione lineare ordinaria cioè della **regressione lineare x variabile indipendente** con il metodo dei minimi quadrati [1] [2] che esprime la y in funzione della x :

- in corrispondenza di una serie di valori dati della x abbiamo altrettanti valori misurati della y ;
- in quanto misurati i valori della y sono affetti da un errore casuale che ha una distribuzione gaussiana;
- per tutti i valori della x la distribuzione dell'errore casuale della y ha la medesima varianza;
- la media delle distribuzioni gaussiane degli errori della y viene allineata su una retta avente equazione $y = a_1 + b_1 \cdot x$



Esprimendo la x in funzione della y e avendo per una serie di valori dati della y altrettanti valori misurati della x si ha la **regressione lineare y variabile indipendente**, mentre l'equazione della retta assume la forma $x = a_2 + b_2 \cdot y$



In condizioni usuali questo secondo modo di analizzare i dati non viene impiegato: per convenzione la variabile indipendente viene sempre riportata in ascisse e la variabile dipendente viene riportata in

ordinate, quindi si procede con il calcolo della regressione lineare x variabile indipendente, o regressione lineare ordinaria, quella cui di fatto ci si riferisce quando si parla semplicemente di **regressione lineare**.

Tuttavia i due modi di vedere riportati sopra diventano fondamentali quando entrambe le variabili sono il risultato di un processo di misura, e quindi non esiste una variabile indipendente. In questo caso la soluzione più semplice ma anche la più robusta, che assegna lo stesso peso agli errori di misura della x e a quelli della y , è rappresentata dalla regressione lineare che impiega come coefficiente angolare b la media geometrica dei due coefficienti angolari, x variabile indipendente e y variabile indipendente [3],[4].

Nel set di dati **ais** contenuto nel pacchetto **DAAG** [5] abbiamo 202 valori di concentrazione degli eritrociti, espressa in migliaia di miliardi per litro di sangue ($10^{12}/L$) – o milioni per microlitro di sangue ($10^6/\mu L$), le due espressioni sono numericamente equivalenti – e i corrispondenti valori di emoglobina, la cui concentrazione è espressa in grammi per decilitro di sangue (g/dL). Entrambe le grandezze sono misurate quindi nessuna delle due può essere assunta come variabile indipendente, e procediamo con il calcolo della **regressione lineare media geometrica**.

Innanzitutto calcoliamo la regressione lineare x variabile indipendente $y = a_1 + b_1 \cdot x$

```
# REGRESSIONE LINEARE media geometrica
#
library(DAAG) # carica il pacchetto che include il set di dati ais
x <- ais$rcc # eritrociti in ascisse
y <- ais$hg # emoglobina in ordinate
#
# regressione y = a + b·x (rcc ascisse, hg in ordinate)
regpar <- lm(y ~ x) # regressione lineare ordinaria
#
a_yx <- regpar$coefficients[1] # intercetta a
b_yx <- regpar$coefficients[2] # coefficiente angolare b
#
```

Dopo avere caricato il pacchetto che include il set di dati **ais** per chiarezza semantica gli eritrociti sono ridenominati **x** e l'emoglobina è ridenominata **y**.

Con la funzione **lm()** viene effettuato il calcolo della regressione lineare ordinaria con la y espressa in funzione della x ($y \sim x$) e sono memorizzati i valori così calcolati del coefficiente angolare (**a_yx**) e dell'intercetta (**b_yx**) della retta di regressione $y = a_1 + b_1 \cdot x$

Calcoliamo ora la regressione lineare y variabile indipendente $x = a_2 + b_2 \cdot y$ in due passaggi:

→ prima calcoliamo la regressione lineare ordinaria invertendo tra loro le due variabili;
→ poi ripristiniamo la x in ascisse e la y in ordinate in modo che il grafico possa essere sovrapposto a quello della regressione lineare x variabile indipendente.

```
#
# regressione x = a + b·y (hg in ascisse, rcc in ordinate)
regpar_1 <- lm(x ~ y) # regressione lineare ordinaria (con variabili invertite)
#
a_xy <- - regpar_1$coefficients[1] / regpar_1$coefficients[2] # intercetta a ripristinando rcc
in ascisse e hg in ordinate
b_xy <- 1 / regpar_1$coefficients[2] # coefficiente angolare b ripristinando rcc in ascisse e hg in
ordinate)
#
```

Con la funzione **lm()** viene effettuato il calcolo della regressione lineare ordinaria con la x espressa in funzione della y ($x \sim y$), quindi sono memorizzati i valori del coefficiente angolare **a_xy** = $-a_2/b_2$ e dell'intercetta **b_xy** = $1/b_2$ ricavati dalla retta di regressione $x = a_2 + b_2 \cdot y$ esplicitando quest'ultima rispetto alla y essendo quindi

$$x = a_2 + b_2 \cdot y \text{ ovvero } b_2 \cdot y = -a_2 + x \text{ ovvero } y = -a_2/b_2 + (1/b_2) \cdot x$$

A questo punto per la regressione lineare media geometrica con equazione $y = a_3 + b_3 \cdot x$ si calcola il coefficiente angolare b_3 come media geometrica dei due coefficienti angolari **b_yx** (b_1) e **b_xy** ($1/b_2$) ovvero come radice quadrata del loro prodotto (prima riga)

```
#
# regressione media geometrica
b_mg <- sqrt(b_yx*b_xy) # coefficiente angolare b media geometrica
a_mg <- mean(y) - (b_mg * (mean(x))) # intercetta a =  $\bar{y} - b \cdot \bar{x}$ 
#
```

quindi dal coefficiente angolare b_3 così calcolato si ricava (seconda riga) l'intercetta a_3 come media delle y meno b_3 volte la media delle x


$$a_3 = \bar{y} - b_3 \cdot \bar{x}$$

Per rappresentare il tutto riportiamo infine un grafico con le tre rette di regressione e aggiungiamo una tabella con i tre coefficienti angolari e le tre intercette calcolate.

```
# grafico
plot(x, y, xlim = c(0,8), ylim = c(0,20), xaxs="i", yaxs="i", xlab="rcc", ylab="hg",
cex.main = 0.9) # grafico dei dati
abline(a_yx, b_yx, col="blue", lty=4) # retta di regressione x variabile indipendente
abline(a_xy, b_xy, col="red", lty=4) # retta di regressione y variabile indipendente
abline(a_mg, b_mg, col="green", lty=1) # retta di regressione media geometrica
# legenda
legend(3.5, 7.5, legend=c("Regressione x variabile indipendente", "Regressione y variabile
indipendente", "Regressione media geometrica"), col=c("blue", "red", "green"),
lty=c(4,4,1), cex=0.8) # aggiunge al grafico la legenda
#
# genera la tabella con i risultati delle regressioni
interc_a <- c(a_yx, a_xy, a_mg) # array con le intercette
cofang_b <- c(b_yx, b_xy, b_mg) # array con i coefficienti angolari
tabris <- data.frame(interc_a, cofang_b) # combina gli array in una tabella
rownames(tabris) <- c("Regressione x variabile indipendente", "Regressione y variabile
indipendente", "Regressione media geometrica") # aggiunge i nomi delle righe
colnames(tabris) <- c("Intercetta a", "Coefficiente angolare b") # aggiunge i nomi delle
colonne
tabris # mostra la tabella con i risultati
#
```

Con la funzione **plot()** viene realizzato il grafico impiegando, accanto agli usuali argomenti, gli argomenti **xaxs="i"** e **yaxs="i"** che allineano inizio e fine delle scale al riquadro grafico (gli argomenti di default sono **xaxs="r"** e **yaxs="r"**, e lasciano il 6% di spazio aggiuntivo tra inizio e fine delle scale e riquadro grafico, si può fare una prova con questi valori per visualizzare la differenza).

Con la funzione **abline()** sono poi aggiunte al grafico le rette di regressione. e con la funzione **legend()** una legenda per identificarle.



Dai valori delle intercette **a_{yx}**, **a_{xy}** e **a_{mg}** e dai valori dei coefficienti angolari **b_{yx}**, **b_{xy}** e **b_{mg}** viene infine costruita la tabella con la sintesi dei risultati.

```
> tabris # mostra la tabella con i risultati
```

	Intercetta a	Coefficiente angolare b
Regressione x variabile indipendente	2.0897326	2.644125
Regressione y variabile indipendente	-1.2275298	3.347141
Regressione media geometrica	0.5287507	2.974938

Si può fare una verifica dei risultati impiegando il pacchetto **lmodel2** e, dopo averlo installato, eseguendo

```
#
# regressione lineare con più modelli
library(lmodel2)
lmodel2(y ~ x, nperm=1000)
#
```

che dopo alcune righe di commenti ci fornisce

```
Regression results
  Method Intercept      Slope Angle (degrees) P-perm (1-tailed)
1    OLS  2.0897326  2.644125      69.28353      0.000999001
2     MA -0.8840492  3.274348      73.01710      0.000999001
3    SMA  0.5287507  2.974938      71.42037              NA
```

```
Confidence intervals
  Method 2.5%-Intercept 97.5%-Intercept 2.5%-Slope 97.5%-Slope
1    OLS      1.1885079      2.9909574      2.454020      2.834229
2     MA     -2.0733368      0.1584401      3.053417      3.526390
3    SMA     -0.3969115      1.3971493      2.790902      3.171111
```

ovvero intercetta e coefficiente angolare della regressione lineare ordinaria (**OLS**) e della regressione lineare media geometrica (**SMA**) – identici a quelli ottenuti con il nostro codice (per inciso **MA** sta per Major Axis e indica la regressione ortogonale).

L'intervallo di confidenza al 95% dell'intercetta della regressione lineare media geometrica $-0.3969115 \div 1.3971493$ ci conferma che l'intercetta 0.5287507 non è significativamente diversa da 0 (zero) in quanto entrambi i valori sono inclusi nell'intervallo, mentre la regressione lineare ordinaria riporta un'intercetta che è significativa in quanto compresa nell'intervallo $1.1885079 \div 2.9909574$ che non include lo 0 (zero).

Domanda: ma perché non impiegare addirittura subito il pacchetto **lmodel2**?

Risposta: perché si sono voluti illustrare i concetti e i passaggi alla base della regressione lineare media geometrica. Una volta confermato che il pacchetto ci fornisce i risultati attesi, nulla osta che si proceda per vie brevi e si impieghino le sue funzioni, ma a questo punto con una maggior consapevolezza del tema.

Conclusione:

→ l'emoglobina, la proteina che trasporta l'ossigeno dai polmoni ai tessuti, è contenuta *esclusivamente* nei globuli rossi (o eritrociti) del sangue e pertanto ci si attende una relazione di proporzionalità lineare tra la concentrazione di questi e la concentrazione dell'emoglobina;

→ dati empirici inoppugnabili ci dicono che in assenza di eritrociti deve necessariamente essere assente l'emoglobina, quindi la retta di regressione dovrebbe passare per l'origine degli assi ($x, y = 0, 0$).

→ eritrociti ed emoglobina sono entrambi il risultato di misure quindi nessuna delle due grandezze può essere assunta come variabile indipendente;

→ la regressione media geometrica, che media tra regressione x variabile indipendente e regressione y variabile indipendente assegnando uguale peso all'errore di misura loro proprio, fornisce un valore dell'intercetta che non è significativamente diverso da 0 (il fatto che il valore non sia esattamente uguale a 0 dipende dall'informazione contenuta nei dati che, concentrati in un ambito di valori ristretto e lontani dallo 0, forniscono una informazione insufficiente per rendere accurata la stima dell'intercetta per estrapolazione);

→ se si traggono le conclusioni all'interno dei valori effettivamente osservati, in assenza di una variabile indipendente la regressione media geometrica è la tecnica più semplice e più robusta;

→ la possibile alternativa, la regressione ortogonale, prevede che i valori delle due variabili siano espressi nelle stesse scale e richiede stime accurate del loro errore di misura, due esigenze che ne rendono l'applicazione più delicata, senza che abbia sostanziali vantaggi rispetto alla regressione ortogonale – per queste ragioni non viene illustrata;

→ a fronte della granitica certezza che due variabili debbano raggiungere congiuntamente il valore 0 è possibile impiegare un modello di regressione alternativo avente equazione della retta $y = b \cdot x$ che non prevede una intercetta in quanto impone il passaggio della retta per l'origine degli assi [6].

[1] Bossi A, Cortinovis I, Duca PG, Marubini E. *Introduzione alla statistica medica*. La Nuova Italia Scientifica, Roma, 1994, ISBN 88-430-0284-8. *Il modello statistico nella regressione lineare*, pp. 305-308.

[2] Snedecor GW, Cochran WG. *Statistical Methods*. The Iowa State University Press, 1980, ISBN 0-8138-1560-6. *The mathematical model in linear regression*, pp. 153-157.

[3] Ling Leng et al. *Ordinary least square regression, orthogonal regression, geometric mean regression and their applications in aerosol science*. J. Phys. 2007;Conf. Ser. 78 012084. DOI:

10.1088/1742-6596/78/1/012084

<https://iopscience.iop.org/article/10.1088/1742-6596/78/1/012084>

[4] Shaoji Xu. *A Property of Geometric Mean Regression*. The American Statistician 2014;68(4);277-281. DOI: 10.1080/00031305.2014.962763

<https://www.tandfonline.com/doi/abs/10.1080/00031305.2014.962763>

[5] Vedere il post [Il set di dati ais](#) nel quale trovate anche come caricare i dati senza impiegare il pacchetto DAAG.

[6] Vedere il post [Regressione lineare passante per l'origine](#).
