

# Regressione lineare passante per l'origine

Ci sono dei casi nei quali dobbiamo riuscire a coniugare la razionalità statistica teorica con le *evidenze* imposte dai dati empirici, vediamo un esempio.

L'emoglobina, la proteina che trasporta l'ossigeno dai polmoni ai tessuti, è contenuta *esclusivamente* nei globuli rossi (o eritrociti) del sangue e ci si attende quindi una relazione di proporzionalità lineare tra la concentrazione dell'emoglobina e la concentrazione degli eritrociti. Inoltre nel caso limite di una concentrazione degli eritrociti ridotta a zero (0) anche l'emoglobina deve avere una concentrazione pari a zero e quindi la relazione di proporzionalità lineare tra le due grandezze dovrebbe essere rappresentata da una retta che passa per l'origine degli assi ( $x, y = 0, 0$ ).

Nel set di dati **ais** contenuto nel pacchetto **DAAG** [1] abbiamo 202 valori di concentrazione degli eritrociti, espressa in migliaia di miliardi per litro di sangue ( $10^{12}/L$ ) – o milioni per microlitro di sangue ( $10^6/\mu L$ ), le due espressioni sono numericamente equivalenti – e i corrispondenti valori di emoglobina, la cui concentrazione è espressa in grammi per decilitro di sangue (g/dL).

Per analizzare i dati impieghiamo inizialmente la regressione lineare ordinaria.

```
# REGRESSIONE LINEARE
#
library(DAAG) # carica il pacchetto che include il set di dati ais
#
x <- ais$rcc # riporta gli eritrociti in ascisse
y <- ais$hg # riporta l'emoglobina in ordinate
reglin <- lm(y ~ x) # calcola la regressione lineare ordinaria
#
summary(reglin) # risultati della regressione
#
```

Dopo avere caricato il pacchetto che include il set di dati **ais** per chiarezza semantica gli eritrociti sono ridenominati **x** e l'emoglobina è ridenominata **y**.

Quindi viene calcolata con la funzione **lm()** la retta di regressione che esprime la **y** in funzione della **x** (**y ~ x**), e con la funzione **summary()** sono riportate le statistiche della regressione.

```
> summary(reglin) # risultati della regressione
```

Call:

```
lm(formula = y ~ x, data = ais)
```

Residuals:

| Min      | 1Q       | Median  | 3Q      | Max     |
|----------|----------|---------|---------|---------|
| -1.66939 | -0.44231 | 0.03338 | 0.44605 | 1.50594 |

Coefficients:

|             | Estimate | Std. Error | t value | Pr(> t )     |
|-------------|----------|------------|---------|--------------|
| (Intercept) | 2.08973  | 0.45703    | 4.572   | 8.44e-06 *** |
| x           | 2.64412  | 0.09641    | 27.427  | < 2e-16 ***  |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.626 on 200 degrees of freedom

Multiple R-squared: 0.79, Adjusted R-squared: 0.7889

F-statistic: 752.2 on 1 and 200 DF, p-value: < 2.2e-16

Le cose che ci interessano principalmente in questa analisi numerica sono due:

→ la prima è che la retta di regressione  $y = 2.08973 + 2.64412 \cdot x$  quando poniamo  $x=0$  intercetta l'asse delle  $y$  al valore  $= 2.08973$  e quindi non passa per l'origine degli assi, un fatto che cozza contro quanto atteso in base all'evidenza empirica;

→ la seconda è che il valore di  $R^2$  – per definizione compreso tra 0 e 1 – che rappresenta la quota di varianza spiegata dalla retta di regressione, in questo caso è uguale a  $0.79$  (ci servirà tra poco come termine di paragone).

A questo punto aggiungiamo un grafico con i dati e con la retta di regressione.

#

```
plot(x, y, xlim=c(0,8), ylim=c(0,20), xaxs="i", yaxs="i", xlab="rcc", ylab="hg",  
main="Regressione lineare ordinaria e passante per l'origine degli assi", cex.main=0.9) #
```


grafico dei dati

```
abline(reglin, col="blue") # retta di regressione
```

#

Con la funzione **plot()** viene realizzato il grafico impiegando, accanto agli usuali argomenti, gli argomenti **xaxs="i"** e **yaxs="i"** che allineano inizio e fine delle scale al riquadro grafico (gli argomenti di default sono **xaxs="r"** e **yaxs="r"**, e lasciano il 6% di spazio aggiuntivo tra inizio e fine delle scale e riquadro grafico, si può fare una prova con questi valori per visualizzare la differenza).


Con la funzione **abline()** viene poi aggiunta al grafico la retta di regressione, che conferma il risultato nient'affatto soddisfacente.



A fronte della nostra certezza che in assenza di eritrociti deve essere assente anche l'emoglobina, ripetiamo i calcoli impiegando un modello di regressione che impone il passaggio della retta per l'origine degli assi.

```
#
reglin0 <- lm(y ~ 0 + x) # regressione lineare passante per x=0 e y=0
abline(reglin0, col="red") # retta di regressione passante per x=0 e y=0
summary(reglin0) # risultati della regressione
#
```

Per farlo impieghiamo nella funzione **lm()** l'argomento **y ~ 0 + x** quindi con la funzione **abline()** riportiamo sul grafico la corrispondente retta di regressione.



Infine validiamo dal punto di vista statistico i risultati della regressione impiegando la funzione **summary()**.

```
> summary(reglin0) # risultati della regressione
```

Call:

```
lm(formula = y ~ 0 + x, data = ais)
```

Residuals:

| Min      | 1Q       | Median  | 3Q      | Max     |
|----------|----------|---------|---------|---------|
| -2.18149 | -0.45742 | 0.05747 | 0.46888 | 1.60372 |

Coefficients:

|   | Estimate | Std. Error | t value | Pr(> t )   |
|---|----------|------------|---------|------------|
| x | 3.08288  | 0.00974    | 316.5   | <2e-16 *** |

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.6562 on 201 degrees of freedom

Multiple R-squared: 0.998, Adjusted R-squared: 0.998

F-statistic: 1.002e+05 on 1 and 201 DF, p-value: < 2.2e-16

**La conclusione?**

Impiegando un modello alternativo che, sulla base di un dato biologico certo, impone il passaggio della retta di regressione per l'origine degli assi:

→ le differenze residue tra i singoli punti e la retta di regressione ([Residuals](#)) diventano un poco superiori a quelle della regressione lineare ordinaria, ma si tratta di un fatto atteso in quanto questa, impiegando il metodo dei minimi quadrati, è per definizione quella che li minimizza;

→ il valore di  $R^2$  – che con la regressione ordinaria era, lo ricordiamo, [0.79](#) – migliora aumentando a [0.998](#);

→ la retta di regressione passante per l'origine degli assi spiega il 99.8% della varianza osservata, un risultato che sfiora il massimo teorico e che conferma la validità del razionale e del modello alternativo impiegato.

-----

[1] Vedere il post [Il set di dati ais](#) nel quale trovate anche come caricare i dati senza impiegare il pacchetto DAAG.

---