


Regressione lineare bayesiana

Il teorema di Bayes è in sostanza un motore inferenziale in grado di aggiornare la probabilità a priori di un evento con le evidenze empiriche per fornire la probabilità a posteriori dell'evento stesso (date le evidenze acquisite).



In questo senso l'approccio bayesiano può essere impiegato anche per calcolare una regressione lineare. Ed è possibile farlo a partire da un'ipotesi minima, assumendo ad esempio che per la retta di equazione $y = a + b \cdot x$ sia $a=0$ e sia $b=0$ e quindi aggiornando questa "credenza a priori" sulla base dei dati (le evidenze) che sono stati raccolti.

Vediamo a titolo di esempio come calcolare la **regressione lineare bayesiana** impiegando le funzioni predisposte in due pacchetti aggiuntivi.

Regressione lineare bayesiana con il pacchetto brms

Come ricordato anche nello script, oltre a installare il pacchetto **brms** in questo caso è necessario installare dal sito di **R** il software **Rtools** che contiene il compilatore **C++** che genera il codice eseguibile impiegato nei calcoli.

```
# REGRESSIONE LINEARE BAYESIANA  $y = a + b \cdot x$  (con il pacchetto brms)
#
# Richiede download e installazione della versione di Rtools appropriata da
# https://cran.r-project.org/bin/windows/Rtools/
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(brms) # carica il pacchetto per la regressione lineare bayesiana
#
apriori <- c(prior(normal(0, 10), class="Intercept"), prior(normal(0, 10), class="b"),
prior(student_t(3, 0, 10), class="sigma")) # definisce gli 'a priori'
#
bayes_reg <- brm(formula=hg~rcc, data=ais, prior=apriori, family=gaussian(), chains=4,
iter=4000, warmup=2000, seed=123) # calcola la regressione lineare bayesiana
#
summary(bayes_reg) # sommario dei risultati
#
```

Come dati di esempio impieghiamo i soliti 202 valori di concentrazione degli eritrociti, espressa in migliaia di miliardi per litro di sangue ($10^{12}/L$) – o milioni per microlitro di sangue ($10^6/\mu L$), le due

espressioni sono numericamente equivalenti – e i corrispondenti valori di emoglobina, la cui concentrazione è espressa in grammi per decilitro di sangue (g/dL), valori che sono contenuti nel set di dati **ais** del pacchetto **DAAG** [1] che al bisogno deve essere scaricato e installato insieme al pacchetto **brms**.

Per il calcolo della regressione bayesiana è necessario innanzitutto impiegare la funzione **priors()** per fissare la probabilità a priori delle grandezze da calcolare, in questo modo:

→ per l'intercetta **a** (**class="Intercept"**) della retta $y = a + b \cdot x$ assumiamo a priori una distribuzione gaussiana (**normal**) con media **0** e deviazione standard **10**;
→ lo stesso facciamo per il coefficiente angolare **b** (**class="b"**);
→ per la deviazione standard residua (**sigma**) assumiamo a priori una distribuzione t di Student (**student_t**) con 3 gradi di libertà, con una media di **0** e una deviazione standard di **10**.

Una media di **0** e una incertezza così ampia lasciano, nel calcolo dei risultati, completamente spazio all'informazione contenuta nei dati forniti, ovvero, se si preferisce, alle evidenze fornite dai dati.

Quindi con la funzione **brm()** viene calcolata la regressione bayesiana sui valori di emoglobina in funzione degli eritrociti (**hg~rcc**) contenuti nel set di dati **ais** impiegando i valori a priori (**apriori**) definiti alla riga precedente, mentre per gli altri parametri impiegati e per il metodo di calcolo (metodo Monte Carlo basato su catena di Markov) si rimanda al manuale del pacchetto [2].

Attenzione: il metodo impiegato richiede tempo, orientativamente con una macchina con processore Intel® Core™ i7 quasi due minuti, che potrebbero aumentare nel caso di processori meno potenti e RAM limitate.

Con la funzione **summary()** viene riportata una sintesi dei risultati.

```
> summary(bayes_reg) # sommario dei risultati
Family: gaussian
Links: mu = identity
Formula: hg ~ rcc
Data: ais (Number of observations: 202)
Draws: 4 chains, each with iter = 4000; warmup = 2000; thin = 1;
       total post-warmup draws = 8000

Regression Coefficients:
              Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
Intercept      2.10      0.46      1.20      2.99 1.00      8802      5734
rcc             2.64      0.10      2.45      2.83 1.00      8804      5739

Further Distributional Parameters:
              Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sigma         0.63      0.03      0.57      0.70 1.00      8965      6033
```

Draws were sampled using sampling(NUTS). For each parameter, Bulk_ESS and Tail_ESS are effective sample size measures, and Rhat is the potential scale reduction factor on split chains (at convergence, Rhat = 1).

Per giudicare il risultato ottenuto che è quindi $y = 2.10 + 2.64 \cdot x$ il metodo più semplice e immediato è confrontarlo con la regressione lineare ordinaria x variabile indipendente

```
#
lm(ais$hg ~ ais$rcc) # regressione lineare ordinaria
#
```

che ci riporta il risultato praticamente identico $y = 2.09 + 2.64 \cdot x$

```
> lm(ais$hg ~ ais$rcc)
```

Call:

```
lm(formula = ais$hg ~ ais$rcc)
```

Coefficients:


```
(Intercept)      ais$rcc  
      2.090      2.644
```

Il pacchetto consente anche di riportare un grafico con i dati (**points=TRUE**), con la retta di regressione calcolata e con i suoi limiti di confidenza

```
#
```

```
plot(conditional_effects(bayes_reg), points=TRUE) # grafico della regressione con i limiti di  
confidenza
```

```
#
```



Nota: il messaggio che compare dopo la generazione del grafico è determinato dalla particolare gestione dell'estetica da parte delle funzioni grafiche impiegate, e non ha rilevanza pratica.

Da ultimo con il codice che segue è possibile generare anche un grafico (qui non riportato) che illustra le distribuzioni calcolate a posteriori di **a**, **b** e **sigma** e l'andamento dei calcoli

```
#
```

```
windows()
```

```
plot(bayes_reg) # grafico delle distribuzioni 'a posteriori'
```

```
#
```

per i quali si rimanda nuovamente a quanto illustrato nella documentazione del pacchetto [2].

Regressione lineare bayesiana con il pacchetto BAS

Con il pacchetto **BAS** il codice che è necessario impiegare è ancora più semplice.

```
# REGRESSIONE LINEARE BAYESIANA  $y = a + b \cdot x$  (con il pacchetto BAS)
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(BAS) # carica il pacchetto per la regressione lineare bayesiana
#
bayes_model <- bas.lm(hg~rcc, data=ais) # calcola la regressione lineare bayesiana
#
a <- round(predict(bayes_model, newdata=data.frame(rcc=0))$fit[1], digits=2) #
intercetta a
b <- round(coef(bayes_model)$postmean[2], digits=2) # coefficiente angolare b
paste("y =", a, "+", b, "· x") # equazione della retta
#
plot(ais$rcc, ais$hg, pch = 19, col = "gray") # grafico dei dati
abline(a, b, col="blue", lwd=2) # retta di regressione
#
```

Dopo avere caricato i due pacchetti necessari il calcolo viene effettuato con la funzione **bas.lm()** che richiede solamente di specificare le variabili (**hg~rcc**) e il set di dati (**ais**) che le contiene.


Quindi:

- l'intercetta **a** viene calcolata con la funzione **predict()** come valore della y corrispondente al valore **0** della x (**data.frame(rcc=0)**) e questo artificio si rende necessario in quanto la funzione **coef(bayes_model)** fornisce come intercetta la media delle y – per chiarimenti vedere la documentazione del pacchetto [3];
- come valore del coefficiente angolare **b** viene riportato quello fornito dalla funzione **coef(bayes_model)**;
- **a** e **b** sono arrotondati a due cifre decimali con la funzione **round()**;
- con la funzione **paste()** intercetta e coefficiente angolare sono combinati nell'equazione della retta di regressione

```
> paste("y =", a, "+", b, "· x") # equazione della retta
[1] "y = 2.12 + 2.64 · x"
```

che nella sostanza non differisce da quelle riportate sopra per la regressione lineare bayesiana e per la regressione lineare ordinaria (senza la necessità di impiegare test di significatività: tutti e tre i coefficienti angolari sono uguali a 2.64 e se arrotondiamo i risultati a una cifra decimale abbiamo tutte e tre le intercette uguali a 2.1).

A questo punto non resta che impiegare la funzione **plot()** per rappresentare il grafico e tracciare la retta di regressione con la funzione **abline()**.



Conclusione: non bisogna stupirsi del fatto che la regressione lineare ordinaria, che impiega un *approccio analitico* – il metodo dei minimi quadrati, così denominato da Legendre che lo descrisse formalmente per la prima volta nel 1805 [4], mentre Gauss, che polemizzò con Legendre dicendo di essere stato lui a idearlo qualche anno prima, lo pubblicò solamente nel 1809 [5] – fornisca risultati identici ai due metodi bayesiani, che impiegano un *approccio probabilistico*. Infatti nella forma in cui sono stati presentati tutti e tre i metodi hanno in comune l'assunto che la x sia la variabile indipendente.

Piuttosto non bisogna dimenticare che:

→ quando l'informazione in ingresso è ridotta (perché i dati sono pochi o sono affetti da un consistente errore di misura o mal si prestano ad un modello lineare) i risultati sono molto influenzati dalle differenze negli assunti alla base dei modelli matematico-statistici impiegati [6];

→ tanto maggiore è l'informazione contenuta nei dati (cioè tanto più i dati sono numerosi, tanto più ridotto è il loro errore di misura e tanto più è deterministicamente fondata la legge di linearità loro sottostante) tanto meno gli assunti influiscono sui risultati, che finiscono per convergere.

Il che ci ricorda ancora una volta non solo che la numerosità campionaria, così come l'errore di misura, sono componenti fondamentali dell'informazione fornita dai dati (le evidenze), ma anche, alla luce del noto adagio "*garbage in, garbage out*", che la qualità dei risultati in uscita non può essere migliore della qualità dei dati in ingresso.

[1] Vedere il post [Il set di dati ais](#) nel quale trovate anche come caricare i dati senza impiegare il pacchetto **DAAG**.

[2] Vedere la documentazione del pacchetto **brms**:

<https://cran.r-project.org/web/packages/brms/brms.pdf>

https://cran.r-project.org/web/packages/brms/vignettes/brms_overview.pdf

[3] *BAS: Bayesian Variable Selection and Model Averaging using Bayesian Adaptive Sampling*.

<https://cran.r-project.org/web/packages/BAS/index.html>

[4] *Nouvelles méthodes pour la détermination des orbites des comètes*, par A.-M.

Legendre, 1805 ... "Nuovi metodi per la determinazione delle orbite delle comete"

<https://gallica.bnf.fr/ark:/12148/bpt6k15209372/>

"... la méthode qui me paroît la plus simple et la plus générale, consiste à rendre minimum la somme des quarrés des erreurs. On obtient ainsi autant d'équations qu'il y a de coefficients inconnus; ce qui achève de déterminer tous les élémens de l'orbite. Comme la méthode dont je viens de parler, et que j'appelle méthode des moindres quarrés, peut être d'une grande utilité dans toutes les questions de physique et d'astronomie où il s'agit de tirer de l'observation les résultats les plus exacts qu'elle peut offrir; j'ai ajouté, dans une appendice, des détails particuliers sur cette méthode ..."

"... il metodo che mi sembra più semplice e generale consiste nel minimizzare la somma dei quadrati degli errori. Questo fornisce tante equazioni quanti sono i coefficienti incogniti; ccosa che consente la determinazione di tutti gli elementi dell'orbita. Poiché il metodo che ho appena descritto, che chiamo metodo dei minimi quadrati, può essere di grande utilità in tutte le questioni di fisica e astronomia nelle quali si tratta di ricavare dalle osservazioni i risultati più accurati che questa possa offrire; ho aggiunto, in una appendice, dettagli specifici su questo metodo ..."

[5] *Theoria motus corporum coelestium in sectionibus conicis Solem ambientium*. Auctore Carolo Friderico Gauss, 1809, pp. 220-221 ... "Teoria del moto dei corpi celesti in sezioni coniche attorno al Sole"

https://archive.org/details/bub_gb_ORUOAAAAQAAJ

[6] Vedere ad esempio il post [La regressione lineare: assunti e modelli](#).