

Regressione lineare multipla

La regressione lineare semplice (regressione bivariata) costruita sul piano cartesiano

$$y = a + b \cdot x$$

può essere estesa a uno spazio n-dimensionale: abbiamo così la **regressione lineare multipla** nella quale la variabile dipendente y viene fatta dipendere non più da una, bensì da k variabili indipendenti, indicate come $x_1, x_2, x_3 \dots x_k$ secondo l'equazione

$$y = a + b_1 \cdot x_1 + b_2 \cdot x_2 + b_3 \cdot x_3 + \dots + b_k \cdot x_k$$

Il risultato è rappresentato quindi da una intercetta a e da tanti coefficienti angolari b (indicati con $b_1, b_2, b_3 \dots b_k$) quante sono le variabili indipendenti ($x_1, x_2, x_3 \dots x_k$) che contribuiscono a determinare il valore della variabile dipendente y .

Come esempio impieghiamo il set di dati **ais** nel quale, tra i dati ematologici rilevati in un gruppo di atleti australiani, abbiamo tre grandezze:

→ la *concentrazione degli eritrociti* (globuli rossi) espressa in milioni per microlitro di sangue ($10^6/\mu\text{L}$) e contenuta nella variabile `rcc`;

→ il *valore ematòcrito* cioè la frazione del volume del sangue occupata dagli eritrociti espressa in percentuale (%) e contenuta nella variabile `hc`;

→ la *concentrazione dell'emoglobina* espressa in grammi per decilitro di sangue (g/dL) e contenuta nella variabile `hg`.

Le tre grandezze sono strettamente legate tra loro dal punto di vista biologico, in quanto gli eritrociti hanno ciascuno un certo volume e contengono ciascuno una data quantità di emoglobina: pertanto all'aumentare del numero di eritrociti aumenta la frazione percentuale del volume del sangue occupata dagli eritrociti (il valore ematòcrito) e aumenta la quantità di emoglobina. Mentre la diminuzione dell'ematòcrito e la diminuzione dell'emoglobina sono indice della diminuzione del numero degli eritrociti.


L'esempio è stato scomposto in una serie di script indipendenti - onde facilitare il riutilizzo del codice per analizzare i propri dati - che impiegano i pacchetti aggiuntivi **gvlma**, **car** e **rgl**, che devono essere scaricati dal **CRAN**. Accertatevi di avere installato inoltre il pacchetto **DAAG** che contiene i dati impiegati nello script, o in alternativa procedete come indicato nel post [Il set di dati ais](#).

Iniziamo con una **analisi esplorativa preliminare** dei dati, copiate questo primo script, incollatelo nella `Console di R` e premete ↵ `Invio`:

```
# REGRESSIONE LINEARE MULTIPLA - analisi esplorativa preliminare dei dati
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(car)  # carica il pacchetto per la grafica
mydata <- ais[,c(1,3,4)] # le colonne 1, 3, 4 contengono le variabili rcc, hc, hg
windows() # apre e inizializza una nuova finestra grafica
#
scatterplotMatrix(~rcc+hc+hg, col="black", pch=20, regLine=list(method=lm, lty=1,
lwd=2, col="chartreuse3"), smooth=FALSE, diagonal=list(method="histogram",
breaks="FD"), main="Istogrammi e grafici xy con rette di regressione", data=mydata) #
istogrammi e grafici xy con rette di regressione
#
```

Dopo avere caricato i pacchetti necessari, copiato nell'oggetto **mydata** le tre variabili che ci interessano, aperto e inizializzato una nuova finestra grafica, l'analisi preliminare dei dati viene effettuata con la funzione **scatterplotMatrix()** nella quale:

- **~rcc+hc+hg** specifica le variabili da rappresentare, che sono la concentrazione degli eritrociti **rcc**, il valore ematòcrito **hc** e la concentrazione di emoglobina **hg**;
- **col="..."** specifica il colore dei grafici;
- **pch=...** specifica il tipo di simbolo da impiegare (un piccolo cerchio pieno);
- per la retta di regressione **regLine** sono impiegati il modello lineare (**lm**), una linea continua (**lty=1**) con uno spessore doppio (**lwd=2**) e un colore (**col="chartreuse3"**), mentre l'argomento **smooth=FALSE** fa sì che non venga aggiunta ai grafici la rappresentazione della funzione non lineare prevista di default nel pacchetto **car**;
- l'argomento **diagonal=list()** indica la rappresentazione della variabile riportata nella diagonale, che qui è l'istogramma (**method="histogram"**) con il numero di classi (**breaks="FD"**) calcolato mediante la regola di Freedman-Diaconis.



Da notare che le espressioni che è possibile impiegare per l'argomento **diagonal=...** sono:

- **list(method="boxplot");**
- **list(method="density", bw="nrd0", adjust=1, kernel="gaussian", na.rm=TRUE);**
- **list(method="histogram");**
- **list(method="oned");**
- **list(method="qqplot").**

Vista la relazione lineare molto buona che intercorre tra le variabili sembra ragionevole continuare ed effettuare il **calcolo della regressione lineare multipla**, copiate questo secondo script, incollatelo nella Console di R e premete **Invio**:

```
# REGRESSIONE LINEARE MULTIPLA - calcolo della regressione lineare multipla
#
library(DAAG) # carica il pacchetto che include il set di dati ais
mydata <- ais[,c(1,3,4)] # le colonne 1, 3, 4 contengono le variabili rcc, hc, hg
reglin <- lm(rcc~hg+hc, data=mydata) # calcolo della regressione
#
coefficients(reglin) # intercetta e coefficienti angolari
```

```
confint(reglin, level=0.95) # intervalli di confidenza al 95%
#
```

La funzione **lm(...)** viene impiegata per calcolare la regressione lineare multipla specificando con l'espressione **rcc~hg+hc** la variabile dipendente (**rcc**), le due variabili indipendenti (**hg** e **hc**) e l'equazione

$$rcc = a + b_1 \cdot hg + b_2 \cdot hc$$

quindi possiamo ricavare con la funzione **coefficients()** i valori dell'intercetta (**a**), del coefficiente angolare di **hg** (**b₁**) e del coefficiente angolare di **hc** (**b₂**):

```
(Intercept)      hg      hc
-0.24269563  0.03283747  0.10403395
```

e riportare l'equazione della regressione lineare multipla come

$$rcc = -0.24269563 + 0.03283747 \cdot hg + 0.10403395 \cdot hc$$

Successivamente con la funzione **confint()** sono riportati gli intervalli di confidenza al 95% dell'intercetta e dei due coefficienti angolari:

```
      2.5 %      97.5 %
(Intercept) -0.53163317  0.04624192
hg          -0.02459817  0.09027311
hc           0.08267073  0.12539718
```

Da notare che gli intervalli di confidenza forniscono un test di significatività per intercetta e coefficienti angolari:

→ dato un intervallo di confidenza al 95% che va da -0.53163317 a 0.04624192 (che quindi include il valore 0) l'intercetta non è significativamente diversa da 0, cosa molto logica in quanto al diminuire fino ad azzerarsi dei valori di emoglobina ed ematòcrito deve necessariamente diminuire e azzerarsi il numero degli eritrociti;

→ con un intervallo di confidenza al 95% che va da -0.02459817 a 0.09027311 (che quindi include il valore 0) il coefficiente angolare della concentrazione di emoglobina **hg** non è significativamente diversa da 0, cosa meno logica in quanto non solo dal punto di vista biologico deve esistere una proporzionalità tra numero degli eritrociti e concentrazione dell'emoglobina, ma anche nell'analisi esplorativa preliminare dei dati riportata con lo script precedente risulta evidente la proporzionalità tra numero degli eritrociti e concentrazione dell'emoglobina che è una dato di fatto dal punto di vista biologico;

→ con un intervallo di confidenza al 95% che va da 0.08267073 a 0.12539718 (che quindi non include il valore 0) il coefficiente angolare del valore ematòcrito **hc** risulta significativamente diverso da 0.

Come detto all'inizio, oltre ad effettuare una analisi esplorativa preliminare dei dati è opportuno sottoporre i risultati ad una valutazione critica a posteriori, che effettuiamo ora sotto forma di una **diagnostica numerica della regressione** lineare multipla, copiate il terzo script, incollatelo nella Console di R e premete ↵ Invio:

```
# REGRESSIONE LINEARE MULTIPLA - diagnostica numerica della regressione
#
library(gvlma) # carica il pacchetto per la diagnostica numerica
library(car)   # carica il pacchetto per la grafica
library(DAAG)  # carica il pacchetto che include il set di dati ais
mydata <- ais[,c(1,3,4)] # le colonne 1, 3, 4 contengono le variabili rcc, hc, hg
reglin <- lm(rcc~hg+hc, data=mydata) # calcolo della retta di regressione lineare multipla
```

```
#
summary(gvlma(reglin)) # test globale per l'assunto di linearità
outlierTest(reglin) # valore p di Bonferroni per la presenza di dati aberranti (outliers)
#
```

Ecco la prima parte del riepilogo dei risultati fornito dalla funzione **summary()**:

```
Call:
lm(formula = rcc ~ hg + hc, data = mydata)

Residuals:
    Min       1Q   Median       3Q      Max
-0.55791 -0.11284 -0.00699  0.09950  0.53595

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -0.24270     0.14652  -1.656   0.0992 .
hg           0.03284     0.02913   1.127   0.2609
hc           0.10403     0.01083   9.603  <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1744 on 199 degrees of freedom
Multiple R-squared:  0.8565,    Adjusted R-squared:  0.855
F-statistic: 593.8 on 2 and 199 DF,  p-value: < 2.2e-16
```

Il valore di probabilità $\Pr(>|t|)$ ottenuto con il test t di Student conferma (ovviamente) i risultati della significatività ricavati dagli intervalli di confidenza riportati sopra, per i quali valgono le considerazioni già fatte. E se la significatività statistica non è coerente con una realtà biologica assodata, dovrà ovviamente essere quest'ultima a prevalere: per cui assumiamo che l'equazione calcolata sia, fino a prova contraria, una descrizione sufficientemente adeguata della relazione di funzione che intercorre tra le tre variabili esaminate.

Che questo sia vero ce lo conferma la funzione **gvlma()**, acronimo di **g**lobal **v**alidation of **l**inear **m**odels **a**ssumptions, che fornisce questi risultati:

- i dati sono distribuiti in modo lineare (**Global Stat**), assunto accettabile;
- i dati non presentano asimmetria (**Skewness**), assunto accettabile;
- i dati non presentano curtosi (**Skewness**), assunto accettabile;
- nell'ambito dei valori osservati la varianza è costante (**Heteroscedasticity**), assunto accettabile.

```
ASSESSMENT OF THE LINEAR MODEL ASSUMPTIONS
USING THE GLOBAL TEST ON 4 DEGREES-OF-FREEDOM:
Level of Significance = 0.05
```

```
Call:
gvlma(x = reglin)

              Value p-value              Decision
Global Stat    6.5801 0.15981  Assumptions acceptable.
Skewness       0.5149 0.47304  Assumptions acceptable.
Kurtosis       0.7559 0.38461  Assumptions acceptable.
Link Function   3.9844 0.04592  Assumptions NOT satisfied!
Heteroscedasticity 1.3249 0.24972  Assumptions acceptable.
```

L'assenza nei dati di asimmetria e di curtosi, e la loro omoschedasticità, sono condizioni sufficienti per garantire la loro adeguata descrizione mediante una regressione lineare. Il primo test (**Global Stat**)

di valutazione globale degli assunti di linearità, che sostanzialmente comprende tutti e tre i test precedenti in forma compatta, li conferma. In questo contesto il test rimanente e l'unico discordante ([Link Function](#)) può essere ignorato.


Con la funzione **outlierTest()** viene effettuato il *test di Bonferroni*, che non evidenzia dati anomali (*outliers*) ma segnala il dato 78 come quello che si discosta maggiormente dagli altri:

```
No Studentized residuals with Bonferroni p < 0.05
Largest |rstudent|:
      rstudent unadjusted p-value Bonferroni p
78 -3.28855      0.0011917      0.24073
```


In tema di valutazione critica a posteriori, aggiungiamo ora alla diagnostica numerica anche una **diagnostica grafica della regressione** lineare multipla, per effettuarla copiate questo quarto script, incollatelo nella Console di R e premete ↵ Invio:

```
# REGRESSIONE LINEARE MULTIPLA - diagnostica grafica della regressione
#
library(car) # carica il pacchetto per la grafica
library(DAAG) # carica il pacchetto che include il set di dati ais
mydata <- ais[,c(1,3,4)] # le colonne 1, 3, 4 contengono le variabili rcc, hc, hg
reglin <- lm(rcc~hg+hc, data=mydata) # calcolo della retta di regressione lineare multipla
#
windows() # apre e inizializza una nuova finestra grafica
qqPlot(reglin, main="Grafico dei quantili per i residui", xlab="t-quantili", ylab="Residui
studentizzati") # grafico globale per linearità e dati aberranti
#
windows() # apre e inizializza una nuova finestra grafica
ceresPlots(reglin, ask=FALSE, main="Grafico di Ceres", ylab="Residui di Ceres (rcc)") #
grafico di Ceres per la valutazione separata della linearità di hg e hc vs. rcc
#
windows() # apre e inizializza una nuova finestra grafica
plot(mydata$rcc, reglin$fitted.values, xlim=c(4,7), ylim=c(4,7)) # grafico valori originari vs
valori stimati
abline(0, 1, lty=2) # linea di identità y = x
#
```


La funzione **qqPlot()** riporta una distribuzione dei residui lineare, evidenziando nel contempo i dati 78 e 161 come quelli che dei quali sarebbe utile controllare la validità, ovvero che sono situati in intervalli di valori per i quali potrebbe essere opportuno acquisire più dati.



La funzione **ceresPlot()** genera due grafici di Ceres separati per emoglobina ed ematòcrito, e consente di visualizzare una relazione lineare tra ematòcrito ed eritrociti migliore di quella che intercorre tra emoglobina ed eritrociti, confermando in un certo senso i valori di significatività riportati sopra.



La diagnostica grafica della regressione lineare multipla si conclude con questo grafico minimalista, ma che entra nell'essenza dei risultati.



Il grafico, generato con la funzione **plot()**, riporta in ascisse i valori originari della concentrazione degli eritrociti (**mydata\$rcc**) e in ordinate i corrispondenti valori **reglin\$fitted.values** ricalcolati da **hg** e **hc** impiegando l'equazione della regressione lineare multipla ove

$$\text{reglin}\$fitted.values = -0.24269563 + 0.03283747 \cdot hg + 0.10403395 \cdot hc$$

La linea di identità $y = x$ che viene riportata evidenzia, senza la necessità di ulteriori statistiche, che l'informazione acquisita misurando la concentrazione dell'emoglobina e l'ematòcrito può essere compressa in un unico valore, che fornisce una stima mediamente adeguata della concentrazione degli eritrociti.

Nota: con "*mediamente adeguata*" si intende che, data la misura diretta della concentrazione degli eritrociti riportata in ascisse, la sua misura indiretta - ottenuta misurando emoglobina ed ematòcrito ed applicando la regressione lineare multipla - comporta una perdita di informazione [aumento dell'incertezza della misura] che si riflette nella "*dispersione media*" dei valori sull'asse delle ordinate. Se non ci fosse perdita di informazione i punti sarebbero perfettamente allineati sulla retta $y = x$.

Ora, visto che con tre variabili la cosa è ancora fattibile, non resta che aggiungere un grafico tridimensionale (3D).

Copiate quest'ultimo script, incollatelo nella Console di R e premete ↵ Invio:


```
# GRAFICO 3D ANIMATO con il pacchetto rgl
#
library(rgl) # carica il pacchetto per la grafica 3D
library(DAAG) # carica il pacchetto che include il set di dati ais
mydata <- ais[,c(1,3,4)] # le colonne 1, 3, 4 contengono le variabili rcc, hc, hg
windows() # apre e inizializza una nuova finestra grafica
#
# grafico 3D animato
#
```

plot3d(mydata\$rcc, y=mydata\$hg, z=mydata\$hc, type="p", col="red", size=3) # realizza il grafico

play3d(spin3d(axis=c(0,0,1), rpm=10), duration=10) # anima il grafico
#

Dopo avere caricato il pacchetto necessario con il comando **library(rgl)** il grafico viene realizzato con la funzione **plot3d()**.

Quindi con la funzione **play3d()** viene realizzata una animazione della durata di 10 secondi (**duration=10**) con i parametri specificati dalla funzione **spin3d()** e cioè l'asse sul quale fare ruotare l'animazione, nel nostro caso l'asse delle **z** (**0,0,1**), e il numero di rotazioni al minuto (**rpm=10**).



Quando l'animazione che compare nella finestra "RGL device" aperta nella Console di R dallo script si ferma, se "afferrate" il grafico 3D facendo click con il tasto sinistro del mouse e tenendolo premuto senza rilasciarlo potete ruotarlo a vostro piacimento muovendo il mouse.

Anche se non aggiunge nulla di nuovo, il grafico [1] ci conforta documentando la linearità della relazione tra le tre variabili.

Conclusione: mettere in relazione tra di loro troppe variabili contemporaneamente può portare a risultati di difficile comprensione. Tuttavia una analisi esplorativa preliminare dei dati e una attenta valutazione critica a posteriori dei risultati possono aiutare a identificare i casi nei quali l'impiego della regressione lineare multipla può essere appropriato.

[1] Trovate altre modalità di rappresentazione sotto forma di grafici tridimensionali nel post [Grafici 3D](#).