

# Analisi dei gruppi (clustering)

L'obiettivo dell'**analisi dei gruppi** (*cluster analysis* o *clustering*) è concettualmente semplice: verificare la possibile esistenza, in un insieme di oggetti, di sottoinsiemi di oggetti particolarmente simili tra loro (gruppi/cluster).

L'analisi dei gruppi si applica a *dati multivariati* ed è un metodo statistico di tassonomia numerica che riveste un ruolo importante nella *analisi esplorativa dei dati*.

Nonostante alla base dell'analisi dei gruppi vi sia un'idea semplice e logica, vi sono numerosi modi per realizzarla, ed esistono:

- *metodi gerarchici*, che danno luogo a una suddivisione ad albero (dendrogramma) in base alla distanza tra i singoli oggetti dell'insieme;
- *metodi non gerarchici*, nei quali l'appartenenza di un oggetto (dell'insieme) ad uno specifico sottoinsieme/gruppo/cluster viene stabilita sulla base della sua distanza dal centro o dalla media dei dati o da un punto rappresentativo del cluster [1];
- *metodi agglomerativi* (o *metodi bottom-up*) nei quali all'inizio del processo di classificazione ad ogni oggetto viene fatto corrispondere un cluster. In questo stadio gli oggetti sono considerati tutti dissimili tra di loro. Al passaggio successivo i due oggetti più simili sono raggruppati nello stesso cluster. Il numero dei cluster risulta quindi pari al numero di oggetti diminuito di uno. Il procedimento viene ripetuto ciclicamente, fino ad ottenere (all'ultimo passaggio) un unico cluster;
- *metodi divisivi* (o *metodi top-down*) nei quali inizialmente tutti gli oggetti sono considerati come appartenenti ad un unico cluster, che viene via via suddiviso in cluster fino ad avere un numero di cluster uguale al numero degli oggetti;
- *metodi esclusivi*, che prevedono che un oggetto possa appartenere esclusivamente a un cluster;
- *metodi non esclusivi* (*fuzzy*) che prevedono che un oggetto possa appartenere, in modo quantitativamente diverso, a più di un cluster.

Da notare infine che non esiste una regola per stabilire il numero di cluster in cui sono aggregati gli oggetti, che va deciso caso per caso, cosa che complica ulteriormente lo scenario.

Per una trattazione completa dei diversi metodi di clustering, tutti metodi esclusivi tranne i metodi fuzzy, rimando ai post:

- [Analisi dei gruppi \(clustering gerarchico\)](#) [include il confronto tra dendrogrammi]
- [Analisi dei gruppi \(clustering non gerarchico\)](#) [include metodi agglomerativi e metodi divisivi]
- [Analisi dei gruppi \(clustering non esclusivo\)](#) [fuzzy clustering]

Qui riporto una breve sintesi con i due metodi più frequentemente impiegati, e capostipiti delle due alternative più tradizionali nel campo del clustering, entrambi *metodi esclusivi*:

- il **metodo di Ward**, un *metodo gerarchico* che misura la somiglianza di due oggetti/punti sulla base della loro *distanza euclidea*;
- il **metodo di MacQueen**, un *metodo non gerarchico* che misura l'appartenenza di un oggetto/punto ad uno specifico cluster con l'algoritmo delle *k-means*.

Come dati impieghiamo i valori di BMI (indice di massa corporea) rilevati a livello europeo alcuni anni fa e pubblicati dall'Istat [2].

Per proseguire è necessario:

- effettuare il download del file di dati `bmi.csv`
- salvare il file nella cartella `C:\Rdati\`

Per il file di dati trovate link e modalità di download alla [pagina Dati](#), ma potete anche semplicemente copiare i dati riportati qui sotto aggiungendo un `↵` Invio al termine dell'ultima riga e salvarli

in C:\Rdati\ in un file di testo denominato `bmi.csv` (assicuratevi che il file sia effettivamente salvato con l'estensione `.csv`).

Nazione;sottopeso;normale;sovrappeso;obeso

Austria;2.4;49.6;33.3;14.7

Belgio;2.7;48.0;35.3;14.0

Bulgaria;2.2;43.8;39.2;14.8

Cipro;3.9;47.8;33.8;14.5

Croazia;1.9;40.7;38.7;18.7

Danimarca;2.2;50.0;32.9;14.9

Estonia;2.2;43.9;33.5;20.4

Finlandia;1.2;44.1;36.4;18.3

Francia;3.2;49.6;31.9;15.3

Germania;1.8;46.1;35.2;16.9

Grecia;1.9;41.3;39.4;17.3

Irlanda;1.9;42.3;37.0;18.7

Lettonia;1.7;41.8;35.2;21.3

Lituania;1.9;42.5;38.3;17.3

Lussemburgo;2.8;49.3;32.4;15.6

Malta;2.0;37.0;35.0;26.0

Olanda;1.6;49.0;36.0;13.3

Polonia;2.4;42.9;37.5;17.2

Portogallo;1.8;44.6;36.9;16.6

Regno Unito;2.1;42.2;35.6;20.1

Repubblica Ceca;1.1;42.1;37.6;19.3

Romania;1.3;42.9;46.4;9.4

Slovacchia;2.1;43.6;38.0;16.3

Slovenia;1.6;41.8;37.4;19.2

Spagna;2.2;45.4;35.7;16.7

Svezia;1.8;48.3;35.9;14.0

Ungheria;2.9;41.9;34.0;21.2

Inoltre è necessario scaricare dal **CRAN** il pacchetto aggiuntivo **cluster** [3]. Copiate questo script, incollatelo nella Console di R e premete ↵ Invio:

```
# ANALISI DEI GRUPPI (CLUSTERING GERARCHICO E NON GERARCHICO)
```

```
#
```

```
mydata <- read.table("c:/Rdati/bmi.csv", header=TRUE, sep=";",  
row.names="Nazione") # importa i dati
```

```
z <- scale(mydata) # standardizza le variabili
```

```
cbind(mydata, z) # mostra i dati originali e i rispettivi valori z
```

```
#
```

```
# clustering gerarchico con il metodo di Ward (distanza euclidea)
```

```
#
```

```
mat <- hclust(dist(z, method="euclidean"), method="ward.D") # genera la matrice delle  
distanze euclidee e costruisce i cluster
```

```
plot(mat, main="Dendrogramma", xlab="BMI nei Paesi europei", sub="", ylab="Distanza  
nei valori di BMI dei cluster", cex=0.7) # traccia il dendrogramma
```

```
rect.hclust(mat, k=4, border=c("red","blue","green","goldenrod")) # evidenzia i 4  
gruppi/cluster
```

```
#
```

```
# clustering non gerarchico con il metodo di MacQueen (k-means )
```

```
#
```

```
library(cluster) # carica il pacchetto
```

```
windows() # apre e inizializza una nuova finestra grafica
```

```
myclust <- kmeans(z, 4, algorithm = c("MacQueen"), nstart=50) # genera i 4 gruppi/cluster
```

```
clusplot(z, myclust$cluster, color=TRUE, col.clus=c("blue", "goldenrod", "red", "green"),
shade=FALSE, labels=3, lines=0, sub="", main="Grafico dei cluster", xlab="Componente
principale 1", ylab="Componente principale 2", cex=0.6, col.txt="black", col.p="black") #
traccia il grafico dei cluster per le prime due componenti principali
#
```

Con la prima riga di codice sono importati i dati nell'oggetto **mydata**.

Con la funzione **scale()** della seconda riga per ciascun dato viene calcolata la *deviata normale standardizzata*  $z$ . In pratica questa funzione prima calcola per i dati di ciascuna colonna/variabile la *media* e la *deviazione standard*, poi calcola per ciascuno dato  $x$  la corrispondente devziata normale standardizzata  $z$  come

$$z = (x - \text{media}) / \text{deviazione standard}$$

I valori di  $z$  sono poi salvati nel nuovo oggetto qui denominato, per comodità mnemonica, **z**.


Nella terza riga infine i dati originali e i corrispondenti valori di devziata normale standardizzata  $z$  sono mostrati insieme, combinati con la funzione **cbind()**.

Dopo questi preliminari si passa al **clustering gerarchico con il metodo di Ward** con la funzione **hclust()** [5] e due soli argomenti:

→ il primo è costituito dalla matrice delle distanze calcolata con la funzione **dist()** sui dati standardizzati  $z$  impiegando per il calcolo delle distanze il metodo di euclideo (**method="euclidean"**), che prevede di misurare la distanza tra due punti con il teorema di Pitagora. I metodi che si possono impiegare in alternativa includono: "euclidean", "maximum", "manhattan", "canberra", "binary", "minkowski" [6];

→ il secondo è l'argomento **method=ward.D** che specifica come costruire i cluster, e può assumere in alternativa uno dei seguenti valori: "ward.D", "ward.D2", "single", "complete", "average" (= UPGMA), "mcquitty" (= WPGMA), "median" (= WPGMC), "centroid" (= UPGMC).

A partire dalla matrice delle distanze euclidee salvata nell'oggetto **mat**, con la funzione **plot()** viene tracciato il dendrogramma e con la funzione **rect.hclust()** e l'argomento **k=** viene stabilito in **4** il numero dei gruppi da evidenziare nel dendrogramma.



Per il **clustering non gerarchico con il metodo di MacQueen** dopo avere caricato il pacchetto **cluster** e aperto una nuova finestra grafica con **windows()**, impiegando la funzione **kmeans()** [7] viene generata la matrice delle distanze che viene salvata nell'oggetto **myclust**.

Viene poi impiegata per tracciare il grafico la funzione **clusplot()** nella quale si fanno notare i seguenti argomenti:

- **color=TRUE** consente l'impiego dei colori nei dati riportati sul grafico;
- **col.clus** nel quale la sequenza dei colori è stata adattata manualmente per avere gli stessi colori del dendrogramma;
- **shade** che se posto **=TRUE** riporta all'interni dei cluster un tratteggio con una densità uguale al numero di punti inclusi nel cluster diviso per l'area dell'ellisse;
- **labels=3** che è uno dei possibili valori per le etichette da riportare (vederli con **help(clusplot)**);
- **lines=0** che dice di non riportare le linee che collegano i cluster;
- **sub=""** che elimina il sottotitolo previsto di default dalla funzione;
- **cex=0.6** che riduce la dimensione dei caratteri dei nomi delle nazioni riportati all'interno dei cluster;
- **col.txt** che definisce il colore del testo che compare all'interno dei cluster;
- **col.p** che definisce il colore impiegato per rappresentare i punti all'interno dei cluster.

Da notare che se nella Console di R digitate


**myclust\$cluster**

viene mostrato il vettore con l'elenco delle nazioni, ciascuna con il cluster cui appartiene

```
> myclust$cluster
Austria      Belgio      Bulgaria      Cipro      Croazia
4             4             2             4             2
Danimarca     Estonia     Finlandia     Francia     Germania
4             3             2             4             2
Grecia        Irlanda     Lettonia     Lituania     Lussemburgo
2             2             3             2             4
```

|                 |          |            |            |             |
|-----------------|----------|------------|------------|-------------|
| Malta           | Olanda   | Polonia    | Portogallo | Regno Unito |
| 3               | 4        | 2          | 2          | 3           |
| Repubblica Ceca | Romania  | Slovacchia | Slovenia   | Spagna      |
| 2               | 1        | 2          | 2          | 2           |
| Svezia          | Ungheria |            |            |             |
| 4               | 3        |            |            |             |

Questo infine è il grafico dei cluster generati.



Per un confronto contenente anche il dettaglio numerico i dati originali forniti dall'Istat sono stati importati in un foglio elettronico nel quale sono stati ordinati e suddivisi manualmente impiegando i seguenti criteri:

- è stato identificato un paese che si discosta in modo significativo da tutti gli altri essendo l'unico con una quota di obesi inferiore al 10% e l'unico con una quota di soggetti sovrappeso superiore al 40%;
- sono stati raccolti in un unico gruppo i paesi con una percentuale di soggetti di peso normale superiore del 5% circa alla media dei restanti paesi, e precisamente superiore al 47%.
- sono stati raggruppati insieme tutti i paesi rimanenti, distinguendo tra quelli con una quota di obesi uguale o superiore al 10% e inferiore al 20% e quelli con una quota di obesi uguale o superiore al 20% e inferiore al 30%.

Dalla tabella così costruita, che riconduce i risultati del clustering ai dati originari, risulta evidente che nel cluster rosso predomina il peso normale, nel cluster blu è dominante la categoria obeso, nel cluster giallo è dominante la presenza di sovrappeso, mentre un caso a sé stante è quello della Romania, con valori estremi sia nel sovrappeso (percentuale di casi molto elevata) sia nell'obeso (percentuale di casi molto bassa).

|    | A               | B         | C       | D          | E     |
|----|-----------------|-----------|---------|------------|-------|
| 1  | Nazione         | sottopeso | normale | sovrappeso | obeso |
| 2  | Danimarca       | 2.2       | 50.0    | 32.9       | 14.9  |
| 3  | Austria         | 2.4       | 49.6    | 33.3       | 14.7  |
| 4  | Francia         | 3.2       | 49.6    | 31.9       | 15.3  |
| 5  | Lussemburgo     | 2.8       | 49.3    | 32.4       | 15.6  |
| 6  | Olanda          | 1.6       | 49.0    | 36.0       | 13.3  |
| 7  | Svezia          | 1.8       | 48.3    | 35.9       | 14.0  |
| 8  | Belgio          | 2.7       | 48.0    | 35.3       | 14.0  |
| 9  | Cipro           | 3.9       | 47.8    | 33.8       | 14.5  |
| 10 | Malta           | 2.0       | 37.0    | 35.0       | 26.0  |
| 11 | Lettonia        | 1.7       | 41.8    | 35.2       | 21.3  |
| 12 | Ungheria        | 2.9       | 41.9    | 34.0       | 21.2  |
| 13 | Estonia         | 2.2       | 43.9    | 33.5       | 20.4  |
| 14 | Regno Unito     | 2.1       | 42.2    | 35.6       | 20.1  |
| 15 | Repubblica Ceca | 1.1       | 42.1    | 37.6       | 19.3  |
| 16 | Slovenia        | 1.6       | 41.8    | 37.4       | 19.2  |
| 17 | Irlanda         | 1.9       | 42.3    | 37.0       | 18.7  |
| 18 | Croazia         | 1.9       | 40.7    | 38.7       | 18.7  |
| 19 | Finlandia       | 1.2       | 44.1    | 36.4       | 18.3  |
| 20 | Lituania        | 1.9       | 42.5    | 38.3       | 17.3  |
| 21 | Grecia          | 1.9       | 41.3    | 39.4       | 17.3  |
| 22 | Polonia         | 2.4       | 42.9    | 37.5       | 17.2  |
| 23 | Germania        | 1.8       | 46.1    | 35.2       | 16.9  |
| 24 | Spagna          | 2.2       | 45.4    | 35.7       | 16.7  |
| 25 | Portogallo      | 1.8       | 44.6    | 36.9       | 16.6  |
| 26 | Slovacchia      | 2.1       | 43.6    | 38.0       | 16.3  |
| 27 | Bulgaria        | 2.2       | 43.8    | 39.2       | 14.8  |
| 28 | Romania         | 1.3       | 42.9    | 46.4       | 9.4   |

Questa analisi, semplice ma di buon senso, coincide con quella fornita dai due metodi di clustering, a parte il fatto che il metodo di MacQueen include Svezia e Olanda nel cluster normale cerchiato in rosso mentre il metodo di Ward li include nel cluster sovrappeso cerchiato in giallo.

In conclusione vale la pena di notare alcune cose:

- la standardizzazione, intesa come trasformazione dei dati nelle corrispondenti deviate normali standardizzate è d'obbligo per i metodi non gerarchici mentre per i metodi gerarchici potrebbe non essere necessaria - ma lo potrebbe essere in alcuni casi. Questo però apre un tema che va al di là dei limiti di questo post: qui è stata impiegata la standardizzazione, che personalmente ritengo opportuno eseguire sempre;
- metodi di clustering che impiegano differenti criteri per il raggruppamento dei dati possono fornire risultati diversi;
- la presenza di oggetti a cavallo tra due cluster (come qui accade per Svezia e Olanda) potrebbe deporre a favore dell'impiego del clustering con metodi non esclusivi (fuzzy). [8] assegnando gli oggetti contemporaneamente a tutti i cluster in modo quantitativamente diverso;
- non esiste una "regola aurea" per stabilire il numero di cluster in cui aggregare gli oggetti;
- anche se matematicamente definito, quindi esente da arbitrarietà, qualsiasi metodo di classificazione risente degli assunti che inevitabilmente devono essere posti alla sua base;
- nel caso di dati non eccessivamente complessi una loro attenta disamina effettuata mediante strumenti tradizionali può essere di aiuto nella interpretazione dei risultati del clustering.

-----

[1] Massart DL, Vandeginste BGM, Deming SN, Michotte Y, Kaufman L. *Chemometrics: a textbook*. Elsevier, New York, 1988, ISBN 0-444-42660-4, pp. 371-384.

[2] Vedere il post [Indice di massa corporea \(BMI\)](#).

[3] Vedere il manuale di riferimento del pacchetto *Package 'cluster'*.  
<https://cran.r-project.org/web/packages/cluster/cluster.pdf>

[4] Digitate **help(scale)** nella Console di R per la documentazione della funzione **scale()**.

[5] Digitate **help(hclust)** nella Console di R per la documentazione della funzione **hclust()**.

[6] Digitate **help(dist)** nella Console di R per vedere la documentazione della funzione **dist()**.

[7] Digitate **help(kmeans)** nella Console di R per vedere il significato degli argomenti impiegati.

[8] Vedere il post [Analisi dei gruppi \(clustering non esclusivo\)](#).

---