

Analisi dei gruppi (clustering gerarchico)

L'analisi dei gruppi si applica a *dati multivariati* ed è un metodo statistico di tassonomia numerica che riveste un ruolo importante nella *analisi esplorativa dei dati*.

L'obiettivo dell'**analisi dei gruppi** (*cluster analysis* o *clustering*) è concettualmente semplice: verificare la possibile esistenza, in un insieme di oggetti, di sottoinsiemi di oggetti particolarmente simili tra loro (gruppi/cluster).

Nonostante alla base dell'analisi dei gruppi vi sia un'idea semplice e logica, vi sono numerosi modi per realizzarla [1], qui ci occupiamo dell'implementazione del *clustering gerarchico* con *metodi esclusivi* nelle due versioni:

→ **clustering agglomerativo** o *bottom-up* (con il metodo di Ward e con AGglomerative NESTing, AGNES);

→ **clustering divisivo** o *top-down* (con DIvisive ANALysis, DIANA).

Come dati impieghiamo i valori di BMI (indice di massa corporea) rilevati a livello europeo alcuni anni fa e pubblicati dall'Istat [2].

Per proseguire è necessario:

→ effettuare il download del file di dati `bmi.csv`

→ salvare il file nella cartella `C:\Rdati\`

Per il file di dati trovate link e modalità di download alla [pagina Dati](#), ma potete anche semplicemente copiare i dati riportati qui sotto aggiungendo un ↵ Invio al termine dell'ultima riga e salvarli in `C:\Rdati\` in un file di testo denominato `bmi.csv` (assicuratevi che il file sia effettivamente salvato con l'estensione `.csv`).

Nazione;sottopeso;normale;sovrappeso;obeso

Austria;2.4;49.6;33.3;14.7

Belgio;2.7;48.0;35.3;14.0

Bulgaria;2.2;43.8;39.2;14.8

Cipro;3.9;47.8;33.8;14.5

Croazia;1.9;40.7;38.7;18.7

Danimarca;2.2;50.0;32.9;14.9

Estonia;2.2;43.9;33.5;20.4

Finlandia;1.2;44.1;36.4;18.3

Francia;3.2;49.6;31.9;15.3

Germania;1.8;46.1;35.2;16.9

Grecia;1.9;41.3;39.4;17.3

Irlanda;1.9;42.3;37.0;18.7

Lettonia;1.7;41.8;35.2;21.3

Lituania;1.9;42.5;38.3;17.3

Lussemburgo;2.8;49.3;32.4;15.6

Malta;2.0;37.0;35.0;26.0

Olanda;1.6;49.0;36.0;13.3

Polonia;2.4;42.9;37.5;17.2

Portogallo;1.8;44.6;36.9;16.6

Regno Unito;2.1;42.2;35.6;20.1

Repubblica Ceca;1.1;42.1;37.6;19.3

Romania;1.3;42.9;46.4;9.4

Slovacchia;2.1;43.6;38.0;16.3

Slovenia;1.6;41.8;37.4;19.2

Spagna;2.2;45.4;35.7;16.7

Svezia;1.8;48.3;35.9;14.0
Ungheria;2.9;41.9;34.0;21.2

Inoltre è necessario scaricare dal **CRAN** il pacchetto aggiuntivo **cluster** [3] e il pacchetto aggiuntivo **dendextend** [4].

Iniziamo con un esempio di clustering gerarchico che impiega esclusivamente i valori di default. Copiate questo script, incollatelo nella Console di R e premete ↵ Invio:

```
# CLUSTERING GERARCHICO con i valori di default
#
mydata <- read.table("c:/Rdati/bmi.csv", header=TRUE, sep=";",
row.names="Nazione") # importa i dati
z <- scale(mydata) # calcola la deviana normale standardizzata dei dati
windows() # apre e inizializza una nuova finestra grafica
#
mat <- dist(z) # calcola la matrice delle distanze
clus <- hclust(mat) # effettua il clustering gerarchico
plot(clus) # traccia il dendrogramma
#
```

Con la prima riga di codice i dati sono importati nell'oggetto **mydata**.

Con la funzione **scale()** della seconda riga per ciascun dato viene calcolata la *deviana normale standardizzata* **z**. In pratica questa funzione prima calcola per i dati di ciascuna colonna/variabile la media e la deviazione standard, poi calcola per ciascuno dato **x** la corrispondente deviana normale standardizzata **z** come

$$z = (x - \text{media}) / \text{deviazione standard}$$

I valori di **z** sono salvati nel nuovo oggetto qui denominato per comodità mnemonica **z**. Se nella Console di R digitate **z**

```
> z
```

sono mostrati i dati standardizzati, in coda ai quali sono riportate la media

```
attr(,"scaled:center")
sottopeso    normale sovrappeso    obeso
 2.103704   44.537037   36.240741   17.111111
```


e la deviazione standard

```
attr(,"scaled:scale")
sottopeso    normale sovrappeso    obeso
0.6111033   3.3717318   2.8989732   3.2322097
```

impiegate per effettuare la standardizzazione dei dati.

Dopo aver aperto e inizializzato una nuova finestra grafica con **windows()**, si passa al clustering gerarchico, realizzato in modo molto semplice, con tre sole funzioni, che impiegano per i loro argomenti i valori di default:

- la funzione **dist()** che, sui valori standardizzati **z**, calcola la matrice delle distanze;
- la funzione **hclust()** che dalla matrice delle distanze genera il clustering gerarchico;
- la funzione **plot()** che dal clustering gerarchico traccia il dendrogramma.



I principali argomenti delle tre funzioni sono evidenziati negli script successivi e al bisogno sono illustrati nella documentazione che si può richiamare con **help(nomedellafunzione)**.

In questo secondo esempio viene illustrato il metodo agglomerativo forse più estesamente impiegato nella pratica, e cioè il clustering gerarchico con il **metodo di Ward**.

Copiate questo script, incollatelo nella Console di R e premete ↵ Invio:

```
# CLUSTERING GERARCHICO con distanza euclidea e metodo di Ward
#
mydata <- read.table("c:/Rdati/bmi.csv", header=TRUE, sep=";",
row.names="Nazione") # importa i dati
z <- scale(mydata) # calcola la deviana normale standardizzata dei dati
windows() # apre e inizializza una nuova finestra grafica
#
mat <- dist(z, method="euclidean") # calcola la matrice delle distanze
clus <- hclust(mat, method="ward.D2") # effettua il clustering gerarchico
plot(clus, cex=0.8, hang=-1, main="Dendrogramma - metodo di Ward", xlab="BMI nei
Paesi europei", sub="", ylab="Distanza nei valori di BMI dei cluster") # traccia il
dendrogramma
#
rect.hclust(clus, k=4, border=c("goldenrod", "red", "green", "blue")) # evidenzia 4
gruppi/cluster
#
```

Qui le funzioni necessarie diventano quattro:

→ la matrice delle distanze **mat** è calcolata con la funzione **dist()** sui dati standardizzati **z** impiegando l'argomento **method="euclidean"** che prevede di misurare la distanza tra due punti con il teorema di Pitagora e può assumere in alternativa uno dei seguenti valori: "euclidean", "maximum", "manhattan", "canberra", "binary", "minkowski";


→ il clustering gerarchico **clus** è effettuato con la funzione **hclust()** sulla matrice delle distanze **mat** impiegando l'argomento **method=ward.D2** che specifica come costruire i cluster, e

può assumere in alternativa uno dei seguenti valori: "ward.D", "ward.D2", "single", "complete", "average" (= UPGMA), "mcquitty" (= WPGMA), "median" (= WPGMC), "centroid" (= UPGMC), il valore di default per l'argomento **method** è "complete";

→ a partire dal clustering gerarchico contenuto nell'oggetto **clus** con la funzione **plot()** viene tracciato il dendrogramma. L'argomento **hang=-1** fa sì che rami del dendrogramma ed etichette risultino allineati in basso. Potete togliere questo argomento se preferite il posizionamento dei rami del dendrogramma e delle etichette previsto di default (vedere il dendrogramma precedente);

→ con la funzione **rect.hclust()** e l'argomento **k=4** viene stabilito il numero dei gruppi da evidenziare nel dendrogramma, mentre i riquadri che li delimitano sono tracciati con i colori definiti nell'argomento **border=c(...)**.

Questo è il dendrogramma ottenuto con il metodo di Ward:



Ora vediamo come il clustering agglomerativo può essere realizzato anche con il metodo di **AGglomerative NESTing** sostituendo la funzione **hclust()** dello script precedente con la funzione **agnes()**.


Copiate questo nuovo script, incollatelo nella Console di R e premete ↵ Invio:

```
# CLUSTERING GERARCHICO agglomerativo (AGglomerative NESTing)
#
library(cluster) # carica il pacchetto
mydata <- read.table("c:/Rdati/bmi.csv", header=TRUE, sep=";",
row.names="Nazione") # importa i dati
z <- scale(mydata) # calcola la deviato normale standardizzata dei dati
windows() # apre e inizializza una nuova finestra grafica
#
mat <- dist(z, method="euclidean") # calcola la matrice delle distanze
clus <- agnes(mat, method="ward") # effettua il clustering gerarchico agglomerativo (AGNES)
plot(clus, which.plots=2, cex=0.8, hang=-1, main="Dendrogramma - clustering con
AGglomerative NESTing", xlab="BMI nei Paesi europei", sub="", ylab="Distanza nei valori
di BMI dei cluster") # traccia il dendrogramma
#
```

```
rect.hclust(clus, k=4, border=c("goldenrod","blue","green","red")) # evidenza 4
gruppi/cluster
#
```

Le differenze di codice necessarie per realizzare il clustering agglomerativo in questo script rispetto al precedente sono poche, ma ovviamente determinanti:

- è richiesto il pacchetto **cluster**;
- per il clustering gerarchico agglomerativo, viene impiegata la funzione **agnes()** che prevede per l'argomento **method** i valori "average", "single", "complete", "ward", "weighted", "gaverage";
- nella funzione **plot()** l'argomento **which.plot=2** serve per rappresentare solamente il dendrogramma, mentre l'argomento **hang=-1** di nuovo allinea rami del dendrogramma ed etichette in basso.




In effetti come vedete impiegando l'argomento **method="ward"** i cluster sono uguali a quelli ottenuti con il metodo di Ward dello script precedente.

Per realizzare il clustering divisivo (top-down) con la **DIVISive ANALYSIS** impieghiamo quest'altro script, incollatelo nella Console di R e premete ↵ Invio:

```
# CLUSTERING GERARCHICO divisivo (DIVISive ANALYSIS)
#
library(cluster) # carica il pacchetto
mydata <- read.table("c:/Rdati/bmi.csv", header=TRUE, sep=";",
row.names="Nazione") # importa i dati
z <- scale(mydata) # calcola la deviato normale standardizzata dei dati
windows() # apre e inizializza una nuova finestra grafica
#
mat <- dist(z, method="euclidean") # calcola la matrice delle distanze
clus <- diana(mat) # effettua il clustering gerarchico divisivo (DIANA)
plot(clus, which.plots=2, cex=0.8, hang=-1, main="Dendrogramma - clustering con
DIVISive ANALYSIS", xlab="BMI nei Paesi europei", sub="", ylab="Distanza nei valori di
BMI dei cluster") # traccia il dendrogramma
#
```

```
rect.hclust(clus, k=4, border=c("goldenrod","blue","green","red")) # evidenza 4
gruppi/cluster
#
```

Nella documentazione della funzione **diana()** per il clustering con la DIvisive ANALysis si legge che questo metodo "... is probably unique in computing a divisive hierarchy, whereas most other software for hierarchical clustering is agglomerative".



La funzione prevede un unico algoritmo di clusterizzazione, per cui si riduce all'espressione **diana(mat)** mentre il resto del codice, a parte naturalmente titolo ed etichette, resta identico a quello dello script precedente.

Per evidenziare le differenze tra i risultati ottenuti con il clustering divisivo e quelli ottenuti con il precedente clustering agglomerativo, impieghiamo la possibilità piuttosto interessante di effettuare il **confronto tra due dendrogrammi**, sia graficamente sia calcolando un indice numerico di corrispondenza.

Copiate questo script, incollatelo nella Console di R e premete ↵ Invio:


```
# CLUSTERING GERARCHICO confronto tra i dendrogrammi AGNES e DIANA
#
library(dendextend) # carica il pacchetto
library(cluster) # carica il pacchetto
mydata <- read.table("c:/Rdati/bmi.csv", header=TRUE, sep=";",
row.names="Nazione") # importa i dati
z <- scale(mydata) # calcola la deviato normale standardizzata dei dati
windows() # apre e inizializza una nuova finestra grafica
#
mat <- dist(z, method="euclidean") # calcola la matrice delle distanze
clusAgnes <- agnes(mat, method="ward") # effettua il clustering gerarchico agglomerativo
(AGNES)
clusDiana <- diana(mat) # effettua il clustering gerarchico divisivo (DIANA)
dendAgnes <- as.dendrogram(clusAgnes) # predispone il dendrogramma
```

```
dendDiana <- as.dendrogram(clusDiana) # predisporre il dendrogramma
tanglegram(dendAgnes, dendDiana, main_left="AGNES", main_right="DIANA") # traccia il
grafico di confronto tra i due dendrogrammi
entanglement(dendAgnes, dendDiana) # calcola la differenza tra i due dendrogrammi
#
```

Dopo avere caricato anche il pacchetto **dendextend**, i passaggi prevedono di:

- calcolare come sempre la matrice delle distanze con la funzione **dist()**;
- effettuare il clustering gerarchico con i due algoritmi che vogliamo confrontare, che sono rispettivamente **agnes()** per il clustering agglomerativo e **diana()** per il clustering divisivo;
- con la funzione **as.dendrogram()** estrarre e salvare i due dendrogrammi che vogliamo confrontare;
- impiegare la funzione **tanglegram()** per tracciare il grafico che confronta visivamente i due dendrogrammi;
- impiegare la funzione **entanglement()** per calcolare l'indice numerico che misura la differenza tra due dendrogrammi.

Il grafico risultante



mette a confronto i due dendrogrammi.

L'indice numerico che misura la differenza tra i due dendrogrammi, che nella documentazione del pacchetto è denominato "*entanglement*", ha un valore compreso tra 0 e 1, dove:

- 0 indica che non vi è alcuna differenza tra i due dendrogrammi;
- 1 indica che i due dendrogrammi non hanno nulla in comune e sono totalmente differenti.

Nel nostro caso abbiamo

```
> entanglement(dendAgnes, dendDiana) # calcola la differenza tra i due dendrogrammi
[1] 0.09419058
```

quindi il valore ottenuto `0.09419058` conferma che i due dendrogrammi sono molto simili, anche se determinano un raggruppamento in cluster lievemente diverso.

Trovate il seguito e le strategie alternative di clustering e di analisi dei dati multivariati nei post:

- [Analisi delle componenti principali](#)
- [Analisi dei gruppi \(clustering non gerarchico\)](#)
- [Analisi dei gruppi \(clustering non esclusivo\)](#)

[1] Nonostante alla base dell'analisi dei gruppi vi sia un'idea semplice e logica, vi sono numerosi modi per realizzarla, infatti esistono:

- *metodi gerarchici*, che danno luogo a una suddivisione ad albero (dendrogramma) in base alla distanza tra i singoli oggetti dell'insieme;
- *metodi non gerarchici*, nei quali l'appartenenza di un oggetto (dell'insieme) ad uno specifico sottoinsieme/gruppo/cluster viene stabilita sulla base della sua distanza dal centro o dalla media dei dati o da un punto rappresentativo del cluster;
- *metodi bottom-up* noti anche come *metodi agglomerativi* nei quali all'inizio del processo di classificazione ad ogni oggetto viene fatto corrispondere un cluster. In questo stadio gli oggetti sono considerati tutti dissimili tra di loro. Al passaggio successivo i due oggetti più simili sono raggruppati nello stesso cluster. Il numero dei cluster risulta quindi pari al numero di oggetti diminuito di uno. Il procedimento viene ripetuto ciclicamente, fino ad ottenere (all'ultimo passaggio) un unico cluster;
- *metodi top-down* noti anche come *metodi divisivi* nei quali inizialmente tutti gli oggetti sono considerati come appartenenti ad un unico cluster, che viene via via suddiviso in cluster fino ad avere un numero di cluster uguale al numero degli oggetti;
- *metodi esclusivi*, che prevedono che un oggetto possa appartenere esclusivamente a un cluster;
- *metodi non esclusivi (fuzzy)* che prevedono che un oggetto possa appartenere, in modo quantitativamente diverso, a più di un cluster.

[2] Vedere il post [Indice di massa corporea \(BMI\)](#).

[3] Trovate la documentazione nel manuale di riferimento del pacchetto: *Package 'cluster'*.
<https://cran.r-project.org/web/packages/cluster/cluster.pdf>

[4] Trovate la documentazione nel manuale di riferimento del pacchetto: *Package 'dendextend'*.
<https://cran.r-project.org/web/packages/dendextend/dendextend.pdf>
