

Analisi dei gruppi (clustering non gerarchico)

L'analisi dei gruppi si applica a *dati multivariati* ed è un metodo statistico di *tassonomia numerica* che riveste un ruolo importante nella *analisi esplorativa dei dati*.

L'obiettivo dell'**analisi dei gruppi** (*cluster analysis* o *clustering*) è concettualmente semplice: verificare la possibile esistenza, in un insieme di oggetti, di sottoinsiemi di oggetti particolarmente simili tra loro (gruppi/cluster).

Nonostante alla base dell'analisi dei gruppi vi sia un'idea semplice e logica, vi sono numerosi modi per realizzarla [1], qui ci occupiamo dell'implementazione del *clustering non gerarchico* con *metodi esclusivi* nelle due versioni:

- clustering con il **metodo di MacQueen** (*k-means*);
- clustering con il **metodo di Rousseeuw** (*k-medoids*).

Come dati impieghiamo i valori di BMI (indice di massa corporea) rilevati a livello europeo alcuni anni fa e pubblicati dall'Istat [2].

Per proseguire è necessario:

- effettuare il download del file di dati `bmi.csv`
- salvare il file nella cartella `C:\Rdati\`

Per il file di dati trovate link e modalità di download alla [pagina Dati](#), ma potete anche semplicemente copiare i dati riportati qui sotto aggiungendo un `↵` Invio al termine dell'ultima riga e salvarli in `C:\Rdati\` in un file di testo denominato `bmi.csv` (assicuratevi che il file sia effettivamente salvato con l'estensione `.csv`).

```
Nazione;sottopeso;normale;sovrappeso;obeso
Austria;2.4;49.6;33.3;14.7
Belgio;2.7;48.0;35.3;14.0
Bulgaria;2.2;43.8;39.2;14.8
Cipro;3.9;47.8;33.8;14.5
Croazia;1.9;40.7;38.7;18.7
Danimarca;2.2;50.0;32.9;14.9
Estonia;2.2;43.9;33.5;20.4
Finlandia;1.2;44.1;36.4;18.3
Francia;3.2;49.6;31.9;15.3
Germania;1.8;46.1;35.2;16.9
Grecia;1.9;41.3;39.4;17.3
Irlanda;1.9;42.3;37.0;18.7
Lettonia;1.7;41.8;35.2;21.3
Lituania;1.9;42.5;38.3;17.3
Lussemburgo;2.8;49.3;32.4;15.6
Malta;2.0;37.0;35.0;26.0
Olanda;1.6;49.0;36.0;13.3
Polonia;2.4;42.9;37.5;17.2
Portogallo;1.8;44.6;36.9;16.6
Regno Unito;2.1;42.2;35.6;20.1
Repubblica Ceca;1.1;42.1;37.6;19.3
Romania;1.3;42.9;46.4;9.4
Slovacchia;2.1;43.6;38.0;16.3
Slovenia;1.6;41.8;37.4;19.2
Spagna;2.2;45.4;35.7;16.7
Svezia;1.8;48.3;35.9;14.0
```

Ungheria;2.9;41.9;34.0;21.2

Inoltre è necessario scaricare dal **CRAN** il pacchetto aggiuntivo **cluster** [3], il pacchetto aggiuntivo **factoextra** [4] e il pacchetto aggiuntivo **ggplot2** [5].

Iniziamo con il clustering con il metodo di MacQueen che impiega l'algoritmo *k-means*.

Copiate questo script, incollatelo nella Console di R e premete ↵ Invio:

```
# CLUSTERING (NON GERARCHICO) con il metodo di MacQueen (k-means)
#
library(cluster) # carica il pacchetto
mydata <- read.table("c:/Rdati/bmi.csv", header=TRUE, sep=";",
row.names="Nazione") # importa i dati
z <- scale(mydata) # standardizza le variabili
windows() # apre e inizializza una nuova finestra grafica
#
myclust <- kmeans(z, 4, algorithm="MacQueen", nstart=50) # genera i 4 gruppi/cluster
clusplot(z, myclust$cluster, color=TRUE, labels=2, lines=0, main="Grafico dei cluster -
metodo di MacQueen (k.means)", xlab="Componente principale 1", sub="",
ylab="Componente principale 2", cex=0.6, col.txt="black", col.p="black") # traccia il grafico
dei cluster
#
```

Con prima cosa viene caricato il pacchetto **cluster**, quindi i dati sono importati in **mydata**.

Con la funzione **scale()** della terza riga per ciascun dato viene calcolata la *deviata normale standardizzata* *z*. Questa funzione calcola per i dati di ciascuna colonna/variabile la *media* e la *deviazione standard*, poi calcola per ciascun dato *x* la corrispondente *deviata normale standardizzata z* come

$$z = (x - \text{media}) / \text{deviazione standard}$$

I valori di *z* sono salvati nel nuovo oggetto qui denominato per comodità mnemonica **z**.

Se nella Console di R digitate **z**

```
> z
```

sono mostrati i dati standardizzati, in coda ai quali sono riportate la *media*

```
attr(,"scaled:center")
sottopeso    normale sovrappeso    obeso
 2.103704   44.537037  36.240741  17.111111
```

e la *deviazione standard*

```
attr(,"scaled:scale")
sottopeso    normale sovrappeso    obeso
0.6111033   3.3717318  2.8989732  3.2322097
```


impiegate per effettuare la standardizzazione dei dati.

Quindi viene aperta e inizializzata una nuova finestra grafica con **windows()**.

La funzione **kmeans()** impiega i dati standardizzati **z** per generare **4** cluster, impiegando l'algoritmo "**MacQueen**" e 50 iterazioni (**nstart=50**) dell'algoritmo di scelta iniziale dei cluster. I risultati sono salvati in **myclust**.

I risultati del clustering salvati in **myclust** sono quindi impiegati per tracciare il grafico con la funzione **clusplot()** e i seguenti argomenti:

- l'oggetto **z** contenente i dati standardizzati;
- l'oggetto **myclust\$cluster** contenente i cluster generati con **kmeans()**;
- **color=TRUE** per riportare i cluster in colore;
- **labels=2** per riportare la numerazione assegnata ai cluster;
- **lines=0** per non riportare le linee che collegano i cluster;
- **sub=""** che elimina il sottotitolo previsto di default dalla funzione;
- **cex=0.6** per rimpicciolire i caratteri del testo applicato;
- **col.txt** che definisce il colore del testo che compare all'interno del grafico;
- **col.p** che definisce il colore impiegato per rappresentare i punti all'interno del grafico.



Per semplicità nella funzione **clusplot()** sono stati lasciati i valori di default per numerosi altri argomenti, digitate **help(clusplot)** nella Console di R per un approfondimento del tema.

Se nella Console di R digitate **mydata[order(-mydata\$normale),]**

```
> mydata[order(-mydata$normale),]
```

sono mostrati i dati ordinati in ordine decrescente per la colonna che contiene la percentuale di soggetti con peso normale

	sottopeso	normale	sovrappeso	obeso
Danimarca	2.2	50.0	32.9	14.9
Austria	2.4	49.6	33.3	14.7
Francia	3.2	49.6	31.9	15.3
Lussemburgo	2.8	49.3	32.4	15.6
Olanda	1.6	49.0	36.0	13.3
Svezia	1.8	48.3	35.9	14.0

Belgio	2.7	48.0	35.3	14.0
Cipro	3.9	47.8	33.8	14.5
Germania	1.8	46.1	35.2	16.9
Spagna	2.2	45.4	35.7	16.7
Portogallo	1.8	44.6	36.9	16.6
Finlandia	1.2	44.1	36.4	18.3
Estonia	2.2	43.9	33.5	20.4
Bulgaria	2.2	43.8	39.2	14.8
Slovacchia	2.1	43.6	38.0	16.3
Polonia	2.4	42.9	37.5	17.2
Romania	1.3	42.9	46.4	9.4
Lituania	1.9	42.5	38.3	17.3
Irlanda	1.9	42.3	37.0	18.7
Regno Unito	2.1	42.2	35.6	20.1
Repubblica Ceca	1.1	42.1	37.6	19.3
Ungheria	2.9	41.9	34.0	21.2
Lettonia	1.7	41.8	35.2	21.3
Slovenia	1.6	41.8	37.4	19.2
Grecia	1.9	41.3	39.4	17.3
Croazia	1.9	40.7	38.7	18.7
Malta	2.0	37.0	35.0	26.0

e potete vedere subito come - giusto per chiarire con un esempio - Danimarca, Austria, Francia, Lussemburgo, Olanda, Svezia, Belgio e Cipro, graficamente incluse nello stesso cluster, numericamente si distinguono dalle altre nazione per avere la maggior percentuale di soggetti con peso normale e contemporaneamente una ridotta percentuale di soggetti obesi.

Vediamo ora il clustering con il metodo di Rousseeuw che impiega l'algoritmo *k-medoids*.


```
# CLUSTERING NON GERARCHICO con il metodo di Rousseeuw (k-medoids)
#
library(factoextra) # carica il pacchetto
library(cluster) # carica il pacchetto
mydata <- read.table("c:/Rdati/bmi.csv", header=TRUE, sep=";",
row.names="Nazione") # importa i dati
windows() # apre e inizializza una nuova finestra grafica
#
myclust <- pam(mydata, 4, metric=c("euclidean"), stand=TRUE) # genera un oggetto pam
che contiene i dati dei cluster
fviz_cluster(myclust, myclust$cluster, labels=7, main = "Grafico dei cluster - metodo di
Rousseeuw (k-medoids)") # grafico dei cluster per le prime due componenti principali
#
windows() # apre e inizializza una nuova finestra grafica
distance <- get_dist(mydata, method="euclidean", stand=TRUE) # genera la matrice delle
distanze
fviz_dist(distance, order=TRUE, show_labels=TRUE, gradient = list(low="#00AFBB",
mid="white", high="#FC4E07")) + theme(axis.text.x=element_text(angle=90,
vjust=0.3))+ theme(axis.text.y=element_text(angle=0, vjust=0.3)) # grafico della matrice
delle distanze
#
windows() # apre e inizializza una nuova finestra grafica
fviz_nbclust(mydata, FUNcluster=cluster::pam, method="wss") # calcola il numero ottimale
di cluster
#
```

I preliminari sono gli stessi dello script precedente a parte il fatto che in questo caso viene impiegato anche il pacchetto **factoextra** che a sua volta si basa sul pacchetto **ggplot2** che deve anch'esso essere stato installato.

La prima funzione utilizzata è **pam()** che deriva il suo nome da "*Partitioning Around Medoids*", impiega l'algoritmo di clustering dei dati *k-medoids* (un versione robusta dell'algoritmo *k-means*) e prevede come argomenti:

- i dati **mydata** da impiegare;
- il numero di cluster, in questo caso **4**, in cui classificare i dati;
- la metrica da impiegare che può essere "**euclidean**" o "**manhattan**";
- **stand=TRUE** che impone la standardizzazione dei dati, che nel caso del clustering con il metodo di MacQueen che abbiamo visto sopra deve invece essere eseguita in via preliminare con la funzione **scale()**.


Con la successiva funzione **fviz_cluster()** è generato il grafico dei cluster (**myclust\$cluster**) ottenuti con l'algoritmo *k-medoids* e contenuti nell'oggetto **myclust**.




La matrice delle distanze **distance** generata con la funzione **get_dist()** sui dati (**mydata**), previa la loro standardizzazione (**stand=TRUE**), viene impiegata dalla funzione **fviz_dist()** per generare il grafico delle distanze tra gli oggetti clusterizzati, un grafico facoltativo e accessorio rispetto al precedente, ma che potrebbe interessare.

In diagonale compare in azzurro la distanza 0 della relazione di identità degli oggetti con se stessi. Il colore azzurro si va attenuando via via che inizia la dissimilarità tra gli oggetti, fino a trasformarsi in un rosso sempre più intenso al suo progressivo aumentare.

Il colore rosso, ad esempio, diventa la dominante nell'incrocio della Romania con tutte le altre Nazioni, a conferma della sua peculiarità: se guardate i dati, ha la percentuale in assoluto più elevata di sovrappeso (46.4%) e la percentuale in assoluto più bassa di obesi (9.4%). In termini di dissimilarità dalle restanti Nazioni, la Romania è immediatamente seguita da Malta, come risulta evidente anche nel grafico dei cluster.



Infine con la funzione **fviz_nbclust()** viene generato il grafico che in teoria consentirebbe di valutare il numero ottimale di cluster da imporre nella funzione **pam()**.



Il numero ottimale di cluster dovrebbe corrispondere ad un punto in cui cambia la curvatura: qui vediamo il primo in corrispondenza di 2 cluster, e il secondo in corrispondenza di 4 cluster. Personalmente non ho mai trovato particolarmente utili gli automatismi di questo genere, preferisco ragionare sul quadro generale, ma lascio al lettore le valutazioni del caso.

Trovate il seguito e le strategie alternative di clustering e di analisi dei dati multivariati nei post:

→ [Analisi delle componenti principali](#)

- [Analisi dei gruppi \(clustering gerarchico\)](#)
- [Analisi dei gruppi \(clustering non esclusivo\)](#)

[1] Nonostante alla base dell'analisi dei gruppi vi sia un'idea semplice e logica, vi sono numerosi modi per realizzarla, infatti esistono:

- *metodi gerarchici*, che danno luogo a una suddivisione ad albero (dendrogramma) in base alla distanza tra i singoli oggetti dell'insieme;
- *metodi non gerarchici*, nei quali l'appartenenza di un oggetto (dell'insieme) ad uno specifico sottoinsieme/gruppo/cluster viene stabilita sulla base della sua distanza dal centro o dalla media dei dati o da un punto rappresentativo del cluster;
- metodi *bottom-up* noti anche come *metodi agglomerativi* nei quali all'inizio del processo di classificazione ad ogni oggetto viene fatto corrispondere un cluster. In questo stadio gli oggetti sono considerati tutti dissimili tra di loro. Al passaggio successivo i due oggetti più simili sono raggruppati nello stesso cluster. Il numero dei cluster risulta quindi pari al numero di oggetti diminuito di uno. Il procedimento viene ripetuto ciclicamente, fino ad ottenere (all'ultimo passaggio) un unico cluster;
- metodi *top-down* noti anche come *metodi divisivi* nei quali inizialmente tutti gli oggetti sono considerati come appartenenti ad un unico cluster, che viene via via suddiviso in cluster fino ad avere un numero di cluster uguale al numero degli oggetti;
- *metodi esclusivi*, che prevedono che un oggetto possa appartenere esclusivamente a un cluster;
- *metodi non esclusivi (fuzzy)* che prevedono che un oggetto possa appartenere, in modo quantitativamente diverso, a più di un cluster.

[2] Vedere il post [Indice di massa corporea \(BMI\)](#).

[3] Trovate la documentazione nel manuale di riferimento del pacchetto: *Package 'cluster'*.

<https://cran.r-project.org/web/packages/cluster/cluster.pdf>

[4] Trovate la documentazione nel manuale di riferimento del pacchetto: *Package 'factoextra'*.

<https://cran.r-project.org/web/packages/factoextra/factoextra.pdf>

[5] Trovate la documentazione nel manuale di riferimento del pacchetto: *Package 'ggplot2'*.

<https://cran.r-project.org/web/packages/ggplot2/ggplot2.pdf>