

La distribuzione gaussiana

Innanzitutto una premessa. Uno dei punti più delicati nella statistica di base è rappresentato dalla distribuzione gaussiana (l'altro punto delicato è rappresentato dal coefficiente di correlazione r).

Media, deviazione standard, ANOVA, test t di Student, solo per citare i principali, sono test statistici (o più semplicemente statistiche) basati sull'assunto che i dati seguano una distribuzione gaussiana.

Poiché media e deviazione standard sono i "*parametri*" che descrivono una distribuzione gaussiana, i metodi statistici che sono basati sull'assunto che i dati siano distribuiti in modo gaussiano sono detti **metodi parametrici**, in contrapposizione a quelli che non prevedono questo assunto, che sono detti **metodi non parametrici** [1, 2].

Applicare metodi parametrici a variabili che non sono distribuite in modo gaussiano è inappropriato e porta a conclusioni sbagliate. Vediamo un esempio impiegando i valori della concentrazione della ferritina nel sangue (espressa in $\mu\text{g/L}$) rilevati in 202 atleti australiani.

Copiate il testo che segue, incollatelo nella `Console di R` e premete `↵ Invio`:

```
x <- c(60, 68, 21, 69, 29, 42, 73, 44, 41, 44, 38, 26, 30, 48, 30, 29, 43, 34, 53, 59, 43, 40, 92, 48,
77, 71, 37, 71, 73, 85, 64, 19, 39, 41, 13, 20, 59, 22, 30, 78, 21, 109, 102, 71, 64, 68, 78, 107, 39,
58, 127, 102, 86, 40, 50, 58, 33, 51, 82, 25, 86, 22, 30, 27, 60, 115, 124, 54, 29, 164, 50, 36, 40,
62, 90, 12, 36, 45, 43, 51, 22, 44, 26, 16, 58, 46, 43, 34, 41, 57, 73, 88, 182, 80, 88, 109, 69, 41,
66, 63, 34, 97, 55, 76, 93, 46, 155, 99, 35, 124, 176, 107, 177, 130, 64, 109, 125, 150, 115, 89,
93, 183, 84, 70, 118, 61, 72, 91, 58, 97, 110, 72, 36, 53, 72, 39, 61, 49, 35, 8, 106, 32, 41, 20, 44,
103, 50, 41, 101, 73, 56, 74, 58, 87, 139, 82, 87, 80, 67, 132, 43, 212, 94, 213, 122, 76, 53, 91,
36, 101, 184, 44, 66, 220, 191, 40, 189, 141, 212, 97, 53, 126, 234, 50, 94, 156, 124, 87, 97, 102,
55, 117, 52, 133, 214, 143, 65, 90, 38, 122, 233, 32)
```

Ora calcoliamo su questi dati la classica misura di posizione, la *media*, e la classica misura di dispersione dei dati, la *deviazione standard* (ds). Digitate o copiate e incollate nella `Console di R` queste due righe e premete `↵ Invio`:

```
mean(x) # calcola la media della ferritina
sd(x) # calcola la deviazione standard della ferritina
```

Questo è il risultato:

```
> mean(x) # calcola la media della ferritina
[1] 76.87624
> sd(x) # calcola la deviazione standard della ferritina
[1] 47.50124
```

Comunicare i risultati di questa ricerca a un vostro amico, il quale vi fa notare quanto segue:

→ in base alle proprietà della distribuzione gaussiana sappiamo che tra la $\text{media} - 1.96 \cdot \text{ds}$ e la $\text{media} + 1.96 \cdot \text{ds}$ si deve trovare il 95% dei dati campionari;

→ il valore della media della ferritina (arrotondato) è $76.9 \mu\text{g/L}$;

→ la deviazione standard della ferritina è $47.5 \mu\text{g/L}$;

→ moltiplicando $47.5 \mu\text{g/L}$ per 1.96 otteniamo $93.1 \mu\text{g/L}$.

→ dal fatto che $76.9 - 93.1 = -16.2 \mu\text{g/L}$ e $76.9 + 93.1 = 170 \mu\text{g/L}$ dovremmo dedurre che il 95% dei valori di ferritina rilevati negli atleti australiani cadeva nell'intervallo

$$-16.2 \div 170 \mu\text{g/L}$$

e pertanto concludere che in una certa quota degli atleti la concentrazione nel sangue della ferritina aveva valori inferiori a zero.

Voi ci restate malissimo, ma il punto è chiaro. Un evidente controsenso consente di individuare un grave errore nella metodologia statistica impiegata: non si possono applicare media e deviazione standard a dati che non sono distribuiti in modo gaussiano - e che questo sia proprio quello che accade nel caso della ferritina lo vedete seguendo il percorso logico indicato in [3].

Nel caso delle statistiche elementari, l'alternativa a media e deviazione standard è rappresentata dalle statistiche non parametriche mediana e deviazione assoluta mediana (MAD), dalla distanza interquartile e dai quantili non parametrici (quartili, decili, percentili).

Ma c'è un altro aspetto interessante che riguarda le statistiche non parametriche. Prendiamo questi dati

8	6	11	7	9	14	3
---	---	----	---	---	----	---

la cui media è 8.3, quindi ordiniamoli in ordine crescente

3	6	7	8	9	11	14
---	---	---	---	---	----	----

per calcolarne la mediana che è 8 (il valore centrale nella lista dei dati ordinati in ordine crescente).

Supponiamo ora di aggiungere una nuova osservazione che si discosta molto dalle precedenti ma di non avere ragioni plausibili per scartarla

8	6	11	7	9	14	3	45
---	---	----	---	---	----	---	----

Calcoliamo di nuovo la media, che ora è diventata 12.9, quindi di nuovo ordiniamo i dati in ordine crescente

3	6	7	8	9	11	14	45
---	---	---	---	---	----	----	----

per calcolarne la mediana, che ora è diventata $(8 + 9) / 2 = 8.5$.

Mentre con l'inserimento del nuovo dato la media è passata da 8.3 a 12.9, la mediana è passata da 8 a 8.5. Il fatto che la mediana sia una misura di posizione **più robusta** nei confronti di dati estremi rispetto alla media è un altro argomento a favore dell'impiego delle statistiche non parametriche [1, 2].

L'esempio della ferritina conferma la necessità che le statistiche parametriche siano impiegate solamente dopo che una attenta valutazione dei dati ha confermato che questi sono distribuiti in modo gaussiano.

Arriviamo quindi al tema. Mentre per la teoria della distribuzione gaussiana si rimanda ai test di statistica, vediamo qui come impiegare le funzioni di **R** per valutare se i dati sono distribuiti in modo gaussiano, e precisamente nell'ordine vediamo:

- i test di normalità dei dati;
- il confronto tra media e mediana (in un distribuzione gaussiana devono essere uguali);
- il confronto tra deviazione standard e MAD (in un distribuzione gaussiana devono essere uguali);
- il confronto tra percentili parametrici e non parametrici (in un distribuzione gaussiana devono essere uguali);

- un istogramma e un kernel density plot dei dati campionari (in una distribuzione gaussiana devono essere simmetrici);
- la distribuzione campionaria (deve sovrapporsi alla corrispondente curva gaussiana teorica);
- la distribuzione cumulativa dei dati campionari (deve sovrapporsi alla funzione di distribuzione cumulativa teorica);
- i quantili campionari (devono essere allineati sulla retta della distribuzione teorica).

Cinquemila valori di una distribuzione gaussiana con media 0 e deviazione standard 1 sono generati con la funzione **rnorm()** [4] e salvati nel file `gauss.csv` con questo script, copiatelo e incollatelo nella Console di R e premete ↵ Invio:

```
# SALVA I DATI DI UNA DISTRIBUZIONE GAUSSIANA IN UN FILE CSV
#
mydata <- rnorm(5000, mean = 0, sd = 1) # genera cinquemila valori con media=0, ds=1
#
write.table(mydata,file="C:/Rdati/gauss.csv",sep=";", dec=".", quote=FALSE,
row.names=FALSE) # esporta i dati in un file di testo .csv sostituendo il punto (.) con la virgola (,)
#
```

Questo è quindi il nostro campione, che ci consente di illustrare cosa ci si deve attendere dall'analisi di una variabile se questa è distribuita in modo gaussiano.

Se non l'avete già fatto, prima di continuare dovete scaricare e installare dal CRAN il pacchetto **moments** e il pacchetto **nortest**.

I prossimi script impiegano i dati salvati nel file `gauss.csv` [5].

Copiate questo script, incollatelo nella Console di R e premete ↵ Invio:

```
# TEST DI NORMALITA' (GAUSSIANITA')
#
library(moments) # carica il pacchetto
library(nortest) # carica il pacchetto
data <- read.table("C:/Rdati/gauss.csv", header=TRUE, sep=";", dec=".") # importa i dati
mydata <- unlist(data) # li converte in formato numerico
#
# asimmetria, curtosi e altri quattro test di normalità
#
agostino.test(mydata) # test di D'Agostino per il coefficiente di asimmetria
anscombe.test(mydata) # test di Anscombe-Glynn per il coefficiente di curtosi
ad.test(mydata) # test di Anderson-Darling per la gaussianità
cvm.test(mydata) # test di Cramer-von Mises per la gaussianità
pearson.test(mydata) # test chi-quadrato di Pearson per la gaussianità
sf.test(mydata) # test di Shapiro-Francia per la gaussianità
#
```

Come atteso tutti i test di normalità confermano per i dati una distribuzione gaussiana [3]:

```
> agostino.test(mydata) # test di D'Agostino per il coefficiente di asimmetria
```

```
D'Agostino skewness test
```

```
data: mydata
skew = -0.0050374, z = -0.1456345, p-value = 0.8842
alternative hypothesis: data have a skewness
```

```
> anscombe.test(mydata) # test di Anscombe-Glynn per il coefficiente di curtosi
```

```
Anscombe-Glynn kurtosis test
```

```
data: mydata  
kurt = 3.03034, z = 0.48405, p-value = 0.6283  
alternative hypothesis: kurtosis is not equal to 3
```

```
> ad.test(mydata) # test di Anderson-Darling per la gaussianità
```

```
Anderson-Darling normality test
```

```
data: mydata  
A = 0.13271, p-value = 0.9808
```

```
> cvm.test(mydata) # test di Cramer-von Mises per la gaussianità
```

```
Cramer-von Mises normality test
```

```
data: mydata  
W = 0.019132, p-value = 0.9754
```

```
> pearson.test(mydata) # test chi-quadrato di Pearson per la gaussianità
```

```
Pearson chi-square normality test
```

```
data: mydata  
P = 47.14, p-value = 0.8452
```

```
> sf.test(mydata) # test di Shapiro-Francia per la gaussianità
```

```
Shapiro-Francia normality test
```

```
data: mydata  
W = 0.99982, p-value = 0.9497
```

In una distribuzione gaussiana statistiche parametriche e statistiche non parametriche devono fornire gli stessi risultati. Copiate quindi questo script, incollatelo nella Console di R e premete ↵ Invio:

```
# TEST AGGIUNTIVI DI NORMALITA' (GAUSSIANITA')  
#  
data <- read.table("C:/Rdati/gauss.csv", header=TRUE, sep=";", dec=",") # importa i dati  
mydata <- unlist(data) # li converte in formato numerico  
#  
# confronta media e mediana  
#  
media <- mean(mydata) # calcola la media  
mediana <- median(mydata) # calcola la mediana  
data.frame(media, mediana) # le mette a confronto  
#  
# confronta deviazione standard e MAD  
#  
ds <- sd(mydata) # calcola la deviazione standard  
mad <- mad(mydata) # calcola la Median Absolute Deviation (about the median) o MAD  
data.frame(ds, mad) # le mette a confronto  
#
```

```
# confronta quantili parametrici e non parametrici
```

```
#
```

```
qpar <- round(qnorm(c(seq(0.025, 0.975, 0.025))), mean=0, sd=1), digits=2) # calcola i  
quantili parametrici
```

```
qnon <- round(quantile(mydata, probs=seq(0.025, 0.975, 0.025))), digits=2) # calcola i  
quantili non parametrici
```

```
data.frame(qnon, qpar) # li mette a confronto
```

```
#
```

A meno di una piccola differenza (dipendente dal generatore di numeri casuali di R) media e mediana sono uguali

```
      media      mediana  
1 0.01061802 0.0009510756
```

deviazione standard e MAD [6] sono uguali

```
      ds      mad  
1 1.000571 0.9948351
```

come pure i quantili parametrici e i quantili non parametrici

```
      qnon  qpar  
2.5% -1.97 -1.96  
5% -1.64 -1.64  
7.5% -1.42 -1.44  
10% -1.25 -1.28  
12.5% -1.14 -1.15  
15% -1.02 -1.04  
17.5% -0.92 -0.93  
20% -0.83 -0.84  
22.5% -0.75 -0.76  
25% -0.66 -0.67  
27.5% -0.59 -0.60  
30% -0.51 -0.52  
32.5% -0.44 -0.45  
35% -0.37 -0.39  
37.5% -0.31 -0.32  
40% -0.24 -0.25  
42.5% -0.18 -0.19  
45% -0.12 -0.13  
47.5% -0.05 -0.06  
50% 0.00 0.00  
52.5% 0.07 0.06  
55% 0.13 0.13  
57.5% 0.20 0.19  
60% 0.26 0.25  
62.5% 0.33 0.32  
65% 0.41 0.39  
67.5% 0.47 0.45  
70% 0.54 0.52  
72.5% 0.61 0.60  
75% 0.68 0.67  
77.5% 0.76 0.76  
80% 0.84 0.84  
82.5% 0.94 0.93
```


85%	1.06	1.04
87.5%	1.18	1.15
90%	1.31	1.28
92.5%	1.45	1.44
95%	1.64	1.64
97.5%	1.95	1.96

Ai valori numerici forniti dai test di normalità e dalle statistiche aggiuntive aggiungiamo ora quattro grafici. Copiate questo script, incollatelo nella Console di R e premete ↵ Invio:

```
# VALUTAZIONE GRAFICA DELLA NORMALITA' (GAUSSIANITA')
#
data <- read.table("C:/Rdati/gauss.csv", header=TRUE, sep=";", dec=",") # importa i dati
mydata <- unlist(data) # li converte in formato numerico
#
windows() # apre una nuova finestra
par(mfrow=c(2,2)) # predispone la suddivisione della finestra in quattro quadranti, uno per grafico
#
# istogramma e kernel density plot
#
hist(mydata, xlim=c(-4, 4), ylim=c(0, 0.5), freq=FALSE, breaks=50,
main="Istogramma\ne kernel density plot", xlab="Ferritina in µg/L", ylab="Densità di
probabilità") # traccia l'istogramma dei dati
par(new=TRUE, ann=FALSE) # consente di sovrapporre il grafico successivo
plot(density(mydata, n=1000, from=-4, to=4), xlim=c(-4, 4), ylim=c(0, 0.5), yaxt="n",
col="black") # sovrappone il kernel density plot della distribuzione campionaria
#
# distribuzione campionaria vs. gaussiana teorica
#
plot(density(mydata, n=1024, from=-4, to=4), xlim=c(-4, 4), ylim=c(0, 0.5)) # traccia il
kernel density plot della distribuzione campionaria
par(new=TRUE, ann=FALSE) # consente di sovrapporre il grafico successivo
x <- seq(-4, 4, length.out=1000) # calcola i valori in ascisse della gaussiana teorica
y <- dnorm(x, mean=mean(mydata), sd=sd(mydata)) # calcola i valori in ordinate della
gaussiana teorica
plot(x, y, xlim=c(-4, 4), ylim=c(0, 0.5), yaxt="n", col="red", type="l") # sovrappone la
distribuzione gaussiana teorica in colore rosso
title(main="Distribuzione campionaria\nvs. gaussiana teorica", xlab="Ferritina in µg/L",
ylab="Densità di probabilità") # aggiunge titolo e legende degli assi
#
# distribuzione cumulativa campionaria vs. distribuzione cumulativa teorica
#
par(new=FALSE, ann=TRUE) # per mostrare titolo e legende degli assi
plot(ecdf(scale(mydata)), main="Cumulativa campionaria\nvs. cumulativa teorica",
xlab="Deviata normale standardizzata z", ylab="Frequenza cumulativa", xlog = FALSE,
ylog = FALSE, xlim=c(-4, 4), ylim=c(0, 1), xaxp=c(-4, 4, 5), yaxp=c(0, 1, 5)) # traccia il
grafico della distribuzione cumulativa campionaria
par(new=TRUE, ann=FALSE) # consente di sovrapporre il grafico successivo
plot(ecdf(rnorm(10000, mean=0, sd=1)), col="red", xlog=FALSE, ylog=FALSE, xlim=c(-4,
4), ylim=c(0, 1), xaxp=c(-4, 4, 5), yaxp=c(0, 1, 5)) # sovrappone la distribuzione cumulativa
teorica in colore rosso
#
# quantili campionari vs. quantili teorici
#
par(new=FALSE, ann=TRUE) # per mostrare titolo e legende degli assi
```

```
qqnorm(scale(mydata), main="Quantili campionari\nvs. quantili teorici", xlab="Quantili
teorici", ylab="Quantili campionari", xlim=c(-4, 4), ylim=c(-4, 4)) # traccia il grafico della
distribuzione dei quantili campionari
abline (0, 1, col="red") # sovrappone la distribuzione dei quantili teorica in colore rosso
#
```

Questi sono i quattro grafici risultanti, con i dati campionari (in nero) che si sovrappongono perfettamente alla distribuzione teorica (in rosso), quello che aspettiamo appunto nel caso di dati distribuiti in modo gaussiano:



Con la funzione **`par(mfrow=c(2,2))`** la finestra grafica viene suddivisa in quattro quadranti, che verranno riempiti da sinistra a destra e dall'alto verso il basso dai quattro grafici generati con i successivi blocchi di codice, migliorando la sintesi dei risultati.

Per le funzioni qui riportate [7] sono previsti molti altri possibili argomenti, per i quali si rimanda alla documentazione di **R**. Quelli che vi capiterà di utilizzare più frequentemente, a parte ovviamente la variabile da analizzare, che è sempre il primo argomento in ogni funzione, sono:

- **main**, il titolo del grafico, che compare in alto;
- **xlab**, l'etichetta dell'asse delle ascisse x;
- **ylab**, l'etichetta dell'asse delle ordinate y;
- **xlim**, che indica limite inferiore e limite superiore della scala da applicare all'asse delle ascisse x;
- **ylim**, che indica limite inferiore e limite superiore della scala da applicare all'asse delle ordinate y;
- **xaxp**, che specifica il limite inferiore, il limite superiore e il numero di intervalli da applicare alla scala dell'asse delle ascisse x;
- **yaxp**, che specifica il limite inferiore, il limite superiore e il numero di intervalli da applicare alla scala dell'asse delle ordinate y.

Per riutilizzare gli script è sufficiente importare i vostri dati nell'oggetto **mydata**.

Conclusion: l'analisi statistica e grafica qui effettuata fornisce un esempio didattico di quello che tipicamente ci si deve attendere dall'analisi di una variabile se questa è distribuita in modo gaussiano.

[1] Siegel S, Castellan NJ. *Statistica non parametrica*. McGraw-Hill Libri Italia, Milano, 1992, ISBN 88-386-0620-X.

[2] Maritz JS. *Distribution-free statistical methods*. Chapman and Hall, New York, 1984, ISBN 0-412-25410-7.

[3] Il percorso logico prevede, per il calcolo delle statistiche elementari di una singola variabile, i seguenti passi:

→ **analisi esplorativa dei dati**;

→ esecuzione dei **test di normalità (gaussianità)**, per valutare se i dati seguono una distribuzione gaussiana;

→ calcolo delle **statistiche elementari parametriche** (media, deviazione standard, varianza, quantili parametrici) se i dati seguono una distribuzione gaussiana;

→ calcolo delle **statistiche elementari non parametriche** (mediana, deviazione assoluta mediana o MAD, quartili e altri quantili non parametrici) se i dati non seguono una distribuzione gaussiana.

[4] Digitate **help(rnorm)** nella Console di R per la documentazione della funzione **rnorm()**.

[5] Nuovi valori sono generati ogni volta che viene eseguita la funzione **rnorm()**, quindi se la eseguiamo più volte i risultati sarebbero sempre lievemente diversi, se non predisponessimo il file `gauss.csv`.

[6] La "Median Absolute Deviation about median" o MAD cioè letteralmente la "Deviazione Mediana Assoluta dalla mediana" è l'equivalente non parametrico della deviazione standard. Vedere: Rousseeuw PJ, Croux C. *Alternatives to the Median Absolute Deviation*. Journal of the American Statistical Association 88 (424), 1273-1283, 1993. URL consultato il 04/01/2019: <https://goo.gl/4Rh53b>

[7] Per la documentazione delle funzioni digitare **help(nomedellafunzione)** nella Console di R. Per gli argomenti **xlog**, **ylog**, **xlim**, **ylim**, **xaxp**, **yaxp** vedere anche la funzione **par()** con **help(par)**.
