


Valutare asimmetria e curtosi

I due test di normalità (gaussianità) più classici e tradizionali sono:

→ il **test di asimmetria** (test di D'Agostino) che valuta il grado di scostamento della simmetria della distribuzione campionaria (quella effettivamente osservata) da quella della distribuzione gaussiana teorica, che è per definizione perfettamente simmetrica;

→ il **test di curtosi** (test di Anscombe-Glynn) che ci dice se la distribuzione campionaria è troppo appiattita (bassa e larga) o troppo appuntita (alta e stretta) rispetto alla distribuzione gaussiana teorica, in ciascun punto della quale vale un preciso rapporto tra larghezza e altezza.



Prima di eseguire lo script è necessario scaricare e installare il pacchetto aggiuntivo **moments**. Trovate il manuale di riferimento, che include i riferimenti bibliografici, sul repository della documentazione di **R** [1]. Per il test di D'Agostino vedere anche [2].

I dati sono contenuti nella tabella **ais** del pacchetto **DAAG** - accertatevi di avere installato il pacchetto o in alternativa procedete come indicato in [3].

Copiate lo script, incollatelo nella Console di R e premete ↵ Invio:

```
# TEST DI ASIMMETRIA E TEST DI CURTOSI
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
library(moments) # carica il pacchetto per l'analisi statistica
#
skewness(ais$ferr) # coefficiente di asimmetria
agostino.test(ais$ferr) # test di D'Agostino per il coefficiente di asimmetria
kurtosis(ais$ferr) # coefficiente di curtosi
anscombe.test(ais$ferr) # test di Anscombe-Glynn per il coefficiente di curtosi
#
```

Dopo avere caricato il pacchetto **DAAG** che contiene i dati nella tabella **ais** e il pacchetto **moments** che contiene le funzioni che ci interessano, nella terza riga di codice con la funzione **skewness()** viene calcolato il coefficiente di asimmetria della variabile **ais\$ferr** (concentrazione della ferritina nel siero espressa in $\mu\text{g/L}$) la cui significatività viene valutata nella riga successiva con la funzione **agostino.test()**.

Il tutto viene ripetuto per il coefficiente di curtosi, calcolato con la funzione **kurtosis()** e la cui significatività viene poi valutata nella riga successiva mediante la funzione **anscombe.test()**.

Il coefficiente di asimmetria è significativo, perché con un valore osservato di asimmetria `skew=1.2806` che dista `z=6.1376` deviazioni standard dal valore 0 (zero) previsto per una distribuzione gaussiana, abbiamo una probabilità di osservare per caso tale valore molto bassa (`p-value=8.377e-10`):

D'Agostino skewness test

```
data: ais$ferr
skew = 1.2806, z = 6.1376, p-value = 8.377e-10
alternative hypothesis: data have a skewness
```

Il coefficiente di curtosi è anch'esso significativo, perché con un valore osservato di curtosi `kurt=4.4202` che dista `z=2.9449` deviazioni standard dal valore 3 previsto per una distribuzione gaussiana, abbiamo una probabilità di osservare per caso tale valore bassa (`p-value=0.003231`):

Anscombe-Glynn kurtosis test

```
data: ais$ferr
kurt = 4.4202, z = 2.9449, p-value = 0.003231
alternative hypothesis: kurtosis is not equal to 3
```

I criteri per valutare la significatività statistica sono i soliti:

- si considera il risultato non significativo quando la probabilità di osservare per caso il valore (effettivamente ottenuto nel caso specifico) della statistica è "elevato";
- si considera il risultato significativo quando la probabilità di osservare per caso il valore (effettivamente ottenuto nel caso specifico) della statistica è "sufficientemente basso";
- come valore soglia tra "elevato" e "sufficientemente basso" viene tradizionalmente impiegato il valore di probabilità `p=0.05` ma nulla vieta, al fine di ridurre ulteriormente la possibilità di trarre dal test statistico conclusioni errate, di impiegare un valore soglia inferiore, come per esempio `p=0.01` e quindi considerare significativo un risultato statistico solamente quando la probabilità di osservarlo per caso è dell'1% o meno.

Integriamo ora l'analisi statistica con una rappresentazione grafica dei dati che riporta, sovrapposti, l'istogramma e il kernel density plot della distribuzione campionaria e per confronto la distribuzione gaussiana teorica, quella che gli stessi dati avrebbero se fossero distribuiti in modo gaussiano.

Copiate lo script, incollatelo nella `Console di R` e premete ↵ Invio:


```
# DISTRIBUZIONE CAMPIONARIA vs. GAUSSIANA TEORICA
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
windows() # apre e inizializza una nuova finestra grafica
par(mar=c(5.1,4.1,4.1,5.1)) # aumenta il margine destro da 2.1 a 5.1
#
hist(ais$ferr, xlim=c(0,250), ylim=c(0,50), freq=TRUE, breaks="FD", density=20,
angle=45, border="black", main="Distribuzione campionaria vs. gaussiana teorica",
xlab="Ferritina in µg/L", ylab="Frequenza (numero dei casi)") # traccia l'istogramma
#
par(new=TRUE, ann=FALSE) # consente la sovrapposizione del grafico successivo
```

```

plot(density(ais$ferr), yaxt="n", xlim=c(0,250), ylim=c(0,0.012), col="blue", lwd=1) #
sovrappone all'istogramma il kernel density plot
axis(4, col.ticks="blue", col.axis="blue") # riporta sulla destra l'asse delle y del kernel density
plot
mtext("Stima kernel della densità di probabilità", side=4, line=3, cex=1, col="blue") #
aggiunge la legenda all'asse delle y sulla destra
#
par(new=TRUE, ann=FALSE) # consente la sovrapposizione del grafico successivo
x <- seq(0, 250, length.out=1000) # calcola i valori in ascisse della gaussiana teorica
y <- dnorm(x, mean=mean(ais$ferr), sd=sd(ais$ferr)) # calcola i valori in ordinate della
gaussiana teorica
plot(x, y, xlim=c(0, 250), ylim=c(0, 0.012), yaxt="n", col="red", type="l", lty=2,
lwd=2) # sovrappone la distribuzione gaussiana teorica in colore rosso
#
par(mar=c(5.1,4.1,4.1,2.1)) # ripristina i margini di default
#

```

Questo è il grafico risultante:



La conclusione dei test statistici trova una conferma empirica nella rappresentazione grafica dei dati: la concentrazione della ferritina nel siero, rispetto alla corrispondente distribuzione gaussiana teorica (in tratteggio di colore rosso) – cioè rispetto a quella che i dati dovrebbero avere se fossero distribuiti in modo gaussiano – è eccessivamente appuntita (leptocurtica) e asimmetrica (asimmetria positiva) pertanto la distribuzione dei dati non è gaussiana.

Nel codice riportato si possono notare alcune cose:

- il numero delle classi **breaks="FD"** è calcolato con la regola di Friedman-Diaconis [4];
- le barre dell'istogramma sono profilate in nero (**border="black"**) riempite di colore (il colore grigio di default) con un tratteggio che copre il 20% della superficie (**density=20**) ed è inclinato a 45 gradi (**angle=45**);
- la scala delle ordinate di sinistra riporta, per l'istogramma, il numero dei casi osservati in ciascuna classe;

- la scala delle ordinate di destra riporta, per il [kernel density plot](#), la stima kernel della densità di probabilità [5];
- per la [distribuzione gaussiana teorica](#) vale la stessa scala di densità di probabilità riportata sulla destra;
- le ordinate della distribuzione gaussiana corrispondente ai dati sono calcolate con la funzione **dnorm()** impiegando la media (**mean(ais\$ferr)**) e la deviazione standard (**sd(ais\$ferr)**) campionarie della ferritina;
- la distribuzione gaussiana teorica, quella che i dati avrebbero avere, è riportata con una linea tratteggiata (**lty=2**) di spessore aumentato (**lwd=2**) in colore rosso (**col="red"**).

Nel post [Analizzare graficamente la distribuzione di una variabile](#) potete trovare, riunite in un'unica vista, quattro grafici per una rappresentazione più completa delle differenze tra la vostra distribuzione campionaria e la distribuzione gaussiana teorica.

I test di asimmetria e di curtosi sono molto importanti, ma più importante ancora è che facciano parte di un approccio complessivo e organico al calcolo delle **statistiche elementari** di una variabile che, si ricorda, prevede di:

- effettuare una [analisi esplorativa dei dati](#)
- effettuare uno o più [test di normalità \(gaussianità\)](#).
- impiegare le [statistiche elementari parametriche](#) se i dati sono distribuiti in modo gaussiano;
- impiegare le [statistiche elementari non parametriche](#) se i dati non sono distribuiti in modo gaussiano.

[1] *Available CRAN Packages By Name.*

https://cran.r-project.org/web/packages/available_packages_by_name.html

[2] D'Agostino RB. *Transformation to Normality of the Null Distribution of g1*. Biometrika 1970;57(3);679-681.

https://www.jstor.org/stable/2334794#page_scan_tab_contents

[3] Vedere il post [Il set di dati ais](#) nel quale trovate anche come caricare i dati della tabella senza impiegare il pacchetto DAAG.

[4] Vedere: *Freedman–Diaconis rule*.

https://en.wikipedia.org/wiki/Freedman%E2%80%93Diaconis_rule

[5] Per i dettagli della rappresentazione grafica vedere il post [Istogrammi](#) e il post [Kernel density plot](#).