

Ricerca una possibile correlazione (tra più variabili)

La ricerca di una possibile correlazione, intesa come la tendenza di grandezze a variare congiuntamente in modo statisticamente significativo, richiede – oltre alla necessità ineludibile di spiegare per quale ragione l'una dipenda dall'altra – un approccio integrato che include il calcolo del coefficiente di correlazione, la regressione lineare e l'esecuzione dei test di normalità. Lo vediamo ora con tre script da tenere a portata di mano per un impiego immediato al bisogno.

Gli script consentono per la parte statistica di calcolare, nel caso del confronto tra più di due variabili:

- il **coefficiente di correlazione lineare r di Pearson** (test parametrico)
- il **coefficiente di correlazione per ranghi ρ (rho) di Spearman** (test non parametrico)
- il **coefficiente di correlazione τ (tau) di Kendall** (test non parametrico)

Quale dei tre coefficienti impiegare per trarre dai propri dati le conclusioni in merito alla significatività della correlazione deve essere valutato di volta in volta alla luce delle seguenti considerazioni:

- 1) come suggerisce anche la sua denominazione completa e corretta, il coefficiente di correlazione lineare **r** di Pearson fornisce una misura accurata del grado di correlazione quando sono soddisfatti i seguenti due requisiti: (i) i dati hanno una distribuzione gaussiana [1] in quanto si tratta di un test parametrico; (ii) tra le due variabili a confronto esiste una relazione lineare;
- 2) i due coefficienti di correlazione non parametrici (**ρ** e **τ**) forniscono una misura della correlazione valida anche quando i dati non sono distribuiti in modo gaussiano e tra le due variabili a confronto non esiste una relazione lineare;
- 3) i test non parametrici sono più conservativi cioè tendono a fornire valori di p superiori (quindi valori di p meno significativi) rispetto al test parametrico; se si preferisce essere più prudenti nelle conclusioni, si possono applicare i test non parametrici anche quando i dati soddisfano i requisiti di gaussianità e di linearità che consentirebbero l'applicazione del test parametrico. Il coefficiente di correlazione **τ** di Kendall è il più conservativo.

Per eseguire gli script è necessario disporre dei pacchetti **car**, **corrgram**, **gclus**, **Hmisc**, **moments** [2], se non li avete dovete scaricarli e installarli dal **CRAN**. Installate infine il pacchetto **DAAG** che contiene nella tabella **ais** i dati impiegati come esempio.

Gli script prevedono tutti la stessa sequenza logica che include:

- a) il calcolo dello specifico *coefficiente di correlazione* per tutte le coppie di variabili;
- b) il calcolo della *significatività* dei coefficienti di correlazione;
- c) i grafici xy con la *retta di regressione* per una valutazione grafica della linearità dei dati messi a confronto;
- d) la rappresentazione dei dati sotto forma di *correlogrammi*, per meglio evidenziare le correlazioni;
- e) i test per la valutazione della *normalità* (gaussianità) dei dati.

Vediamo per primo lo script per il calcolo del **coefficiente di correlazione lineare r di Pearson**, copiatelo e incollatelo nella Console di R e premete ↵ Invio:

```

# COEFFICIENTE DI CORRELAZIONE LINEARE r (erre) di Pearson (parametrico)
#
library(DAAG) # carica il pacchetto che include il set di dati ais
mydata <- ais[c(1:11)] # salva in mydata le colonne contenenti variabili numeriche
#
# coefficiente di correlazione lineare r di Pearson con valori p di significatività
#
library(Hmisc) # carica il pacchetto
rcorr(as.matrix(mydata), type="pearson") # mostra i valori di r di Pearson e i valori di p
corrispondenti
#
# grafico xy per tutte le coppie di variabili
#
library(car) # carica il pacchetto
scatterplotMatrix(~rcc+wcc+hc+hg+ferr+bmi+ssf+pcBfat+lbm+ht+wt,
regLine=list(method=lm, lty=1, lwd=2, col="red"), smooth=FALSE,
diagonal=list(method="density", bw="nrd0", adjust=1, kernel="gaussian", na.rm=TRUE),
col="black", main="Grafici di dispersione", data=mydata) # traccia i grafici di dispersione xy
che incrociano tutte le variabili
#
# correlogrammi
#
library(corrgram) # carica il pacchetto
windows() # apre una nuova finestra
corrgram(mydata, cor.method = "pearson", order=FALSE, lower.panel=panel.pts,
upper.panel=panel.pie, text.panel=panel.txt, main="Correlogramma (r di Pearson)") #
correlogramma con grafici xy e grafici a torta
#
windows() # apre una nuova finestra
corrgram(mydata, cor.method = "pearson", order=FALSE, lower.panel=panel.pts,
upper.panel=panel.conf, text.panel=panel.txt, main="Correlogramma (r di Pearson)") #
correlogramma con grafici xy e r di Pearson
#
windows() # apre una nuova finestra
corrgram(mydata, cor.method="pearson", order=FALSE, lower.panel=panel.pts,
upper.panel=panel.ellipse, text.panel=panel.txt, diag.panel=panel.density,
main="Correlogramma (r di Pearson)") # correlogramma con grafici xy ed ellissi delle tendenze
con curva loess
#
library(gclus) # carica il pacchetto
windows() # apre una nuova finestra
prs <- cor(mydata, method="pearson") # r di Pearson
mydata.col <- dmat.color(abs(prs)) # applica i colori
mydata.o <- order.single(abs(prs)) # dispone le variabili meglio correlate più vicine alla
diagonale
cpairs(mydata, mydata.o, panel.colors=mydata.col, gap=.5, main="Gradiente di
correlazione (r di Pearson)") # mostra il grafico
#
# test di gaussianità (asimmetria e curtosi)
#
library(moments) # carica il pacchetto
print(paste("numero dei dati =", n <- nrow(mydata)), quote=FALSE)
print(paste("deviazione standard del coefficiente di asimmetria (sa) =", sa <- sqrt(6/n)),
quote=FALSE)
print(paste("deviazione standard del coefficiente di curtosi (sc) =", sc <- sqrt(24/n)),
quote=FALSE)

```

```
#
ca <- skewness(mydata) # coefficiente di asimmetria (ca)
ca_sa <- round(abs(ca/sa), digits=2) # rapporto (ca/sa)
#
cc <- kurtosis(mydata)-3 # coefficiente di curtosi (cc)
cc_sc <- round(abs(cc/sc), digits=2) # rapporto (cc/sc)
#
ascurt <- data.frame(ca, ca_sa, cc, cc_sc) # costruisce la tabella
names(ascurt) <- c("ca", "ca/sa", "cc", "cc/sc") # assegna i nomi alle colonne
ascurt # mostra la tabella
#
```

Nel primo blocco di codice viene innanzitutto caricato con **library(DAAG)** il pacchetto che contiene nella tabella **ais** i dati utilizzati come esempio. Quindi all'oggetto **mydata** sono assegnate (**<-**) le variabili numeriche della tabella **ais** che si vogliono analizzare indicando le colonne che le contengono. Da notare che qui è possibile impiegare la forma **ais[c(1:11)]** in quanto le colonne sono contigue: in caso contrario è necessario specificare le colonne una per una nella forma **ais[c(1,2,3,4,5,6,8,9,10,11)]** nella quale, a titolo di esempio, è stata esclusa la colonna **7**.

Per importare i vostri dati è sufficiente sostituire **ais[c(1:11)]** con il nome della vostra tabella e **rcc, wcc, hc, hg** e così via con i nomi delle variabili contenute nella tabella.

Nel secondo blocco di codice, dopo avere caricato il pacchetto **Hmisc**, viene eseguita l'analisi statistica sull'oggetto **mydata** impiegando la funzione **rcorr()** e specificando l'argomento **type="pearson"**: in questo modo sono calcolati e riportati in forma di tabella i risultati per il coefficiente di correlazione lineare **r** di Pearson e i relativi valori di probabilità **p**.

Questi sono i valori di **r** calcolati

	rcc	wcc	hc	hg	ferr	bmi	ssf	pcBfat	lbm	ht	wt
rcc	1.00	0.15	0.92	0.89	0.25	0.30	-0.40	-0.49	0.55	0.36	0.40
wcc	0.15	1.00	0.15	0.13	0.13	0.18	0.14	0.11	0.10	0.08	0.16
hc	0.92	0.15	1.00	0.95	0.26	0.32	-0.45	-0.53	0.58	0.37	0.42
hg	0.89	0.13	0.95	1.00	0.31	0.38	-0.44	-0.53	0.61	0.35	0.46
ferr	0.25	0.13	0.26	0.31	1.00	0.30	-0.11	-0.18	0.32	0.12	0.27
bmi	0.30	0.18	0.32	0.38	0.30	1.00	0.32	0.19	0.71	0.34	0.85
ssf	-0.40	0.14	-0.45	-0.44	-0.11	0.32	1.00	0.96	-0.21	-0.07	0.15
pcBfat	-0.49	0.11	-0.53	-0.53	-0.18	0.19	0.96	1.00	-0.36	-0.19	0.00
lbm	0.55	0.10	0.58	0.61	0.32	0.71	-0.21	-0.36	1.00	0.80	0.93
ht	0.36	0.08	0.37	0.35	0.12	0.34	-0.07	-0.19	0.80	1.00	0.78
wt	0.40	0.16	0.42	0.46	0.27	0.85	0.15	0.00	0.93	0.78	1.00

n= 202

e questi i rispettivi valori di **p** tabulati (i valori **0.0000** sono da intendere come **p < 0.0001**) che consentono di stabilirne la significatività. Potete impiegare come valore soglia il classico **p = 0.05** ovvero essere un poco più esigenti (e prudenti) e porre la soglia per la significatività di **r** in corrispondenza del valore **p = 0.01**.


P	rcc	wcc	hc	hg	ferr	bmi	ssf	pcBfat	lbm	ht	wt
rcc		0.0367	0.0000	0.0000	0.0003	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
wcc	0.0367		0.0294	0.0559	0.0610	0.0118	0.0519	0.1262	0.1460	0.2773	0.0270
hc	0.0000	0.0294		0.0000	0.0002	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
hg	0.0000	0.0559	0.0000		0.0000	0.0000	0.0000	0.0000	0.0000	0.0000	0.0000
ferr	0.0003	0.0610	0.0002	0.0000		0.0000	0.1252	0.0090	0.0000	0.0805	0.0000

```

bmi      0.0000 0.0118 0.0000 0.0000 0.0000      0.0000 0.0075 0.0000 0.0000 0.0000
ssf      0.0000 0.0519 0.0000 0.0000 0.1252 0.0000      0.0000 0.0030 0.3136 0.0284
pcBfat   0.0000 0.1262 0.0000 0.0000 0.0090 0.0075 0.0000      0.0000 0.0074 0.9978
lbm      0.0000 0.1460 0.0000 0.0000 0.0000 0.0000 0.0030 0.0000      0.0000 0.0000
ht       0.0000 0.2773 0.0000 0.0000 0.0805 0.0000 0.3136 0.0074 0.0000      0.0000
wt       0.0000 0.0270 0.0000 0.0000 0.0000 0.0000 0.0284 0.9978 0.0000 0.0000

```

Con il terzo blocco di codice, dopo avere caricato il pacchetto **car**, con la funzione **scatterplotMatrix()** sono riportati in un'unica figura i grafici xy (grafici di dispersione) che incrociano tutte le variabili: questo consente una valutazione grafica preliminare dei dati, delle loro distribuzioni e delle loro possibili relazioni.




Sulla diagonale sono riportati i kernel density plot che consentono di valutare la distribuzione dei dati. In ciascun grafico xy è riportata a scopo orientativo la retta di regressione, la cui significatività peraltro deve essere valutata con gli altri strumenti che trovate più avanti.


L'argomento **~rcc+wcc+hc+hg+ferr+bmi+ssf+pcBfat+lbm+ht+wt** qui specifica tutte le variabili del set di dati **ais** allo scopo di non perdere nessuna potenziale correlazione. Se avete importato i dati da un vostro file non dimenticate di modificare questo argomento, riportando dopo la tilde (~) l'elenco delle variabili che volete rappresentare e collegando l'una all'altra con il segno **+**.

Nel quarto blocco di codice, sono realizzati innanzitutto mediante le funzioni del pacchetto **corrgram** tre correlogrammi che riportano come riferimento in basso a sinistra sotto alla diagonale i grafici xy dei dati (**lower.panel=panel.pts**).

Il primo correlogramma riporta in alto a destra i grafici a torta (**upper.panel=panel.pie**) che rappresentano i valori di **r** (**cor.method="pearson"**) con superficie colorata della torta e intensità del colore proporzionali al valore di **r** e con le gradazioni di blu e di rosso riferite rispettivamente a valori positivi e a valori negativi di **r**.




Il secondo correlogramma riporta in alto a destra i valori del coefficiente di correlazione lineare r di Pearson con i limiti di confidenza al 95% (**upper.panel=panel.conf**). Questi forniscono un test di significatività: il valore di r è significativo se i limiti di confidenza non includono lo 0 (zero), mentre non è significativo se includono lo 0.




Il terzo correlogramma riporta in alto a destra le ellissi (**upper.panel=panel.ellipse**) i cui assi maggiori delineano la tendenza delle due variabili a variare congiuntamente, con le regressioni loess che aiutano a valutare la linearità della loro relazione. Inoltre riporta sulla diagonale i kernel density plot delle variabili rappresentate (**diag.panel=panel.density**) già visti nel primo grafico, che ci

consentono di evidenziare variabili distribuite in modo spiccatamente asimmetrico, come la variabile `ferr`, o che hanno una evidente distribuzione bimodale, come la variabile `rcc`: fatti dei quali si deve tenere conto.



Un quarto e ultimo correlogramma viene quindi realizzato mediante le funzioni del pacchetto **gclus**. Innanzitutto con la funzione **corr()** e con l'argomento **method="pearson"** sono calcolati e salvati (**<-**) in **prs** i valori del coefficiente di regressione lineare **r** di Pearson. Quindi sono predisposti i colori (**mydata.cor**) per evidenziare le variabili meglio correlate e viene stabilito l'ordine della variabili (**mydata.o**) in modo che le meglio correlate siano più vicine alla diagonale. Ordine e colore delle variabili sono quindi impiegati nella funzione **cpairs()** per organizzare i grafici all'interno del correlogramma, con i valori di **r** più significativi le relazioni lineari più evidenti disposti attorno alla diagonale.



Ai correlogrammi seguono i test di normalità (gaussianità). Viene mostrato il numero dei dati

```
> print(paste("numero dei dati =", n <- nrow(mydata)), quote=FALSE)
[1] numero dei dati = 202
```

viene calcolata la deviazione standard **sa** del coefficiente di asimmetria

```
> print(paste("deviazione standard del coefficiente di asimmetria (sa) =", sa <-
sqrt(6/n)), quote=FALSE)
[1] deviazione standard del coefficiente di asimmetria (sa) = 0.172345496886428
```

e viene calcolata la deviazione standard **sc** del coefficiente di curtosi

```
> print(paste("deviazione standard del coefficiente di curtosi(sc) =", sc <-
sqrt(24/n)), quote=FALSE)
[1] deviazione standard del coefficiente di curtosi(sc) = 0.344690993772856
```

Per ognuna della variabili con la funzione **skewness()** viene calcolato il coefficiente di asimmetria **ca** dal quale si ricava il rapporto **ca/sa**, sempre per ognuna delle variabili con la funzione **kurtosis()** viene calcolato il coefficiente di curtosi **cc** dal quale si ricava il rapporto **cc/sc**. Infine i valori calcolati sono assemblati mediante la funzione **data.frame()** in una tabella:

	ca	ca/sa	cc	cc/sc
rcc	0.4160046	2.41	0.662946166	1.92
wcc	0.8352336	4.85	1.449462762	4.21
hc	0.2752244	1.60	0.891229892	2.59
hg	0.1759351	1.02	0.008064219	0.02
ferr	1.2805839	7.43	1.420173468	4.12
bmi	0.9465155	5.49	2.183474974	6.33
ssf	1.1746685	6.82	1.365135223	3.96
pcBfat	0.7595480	4.41	-0.173299598	0.50
lbm	0.3585088	2.08	-0.240119844	0.70
ht	-0.1993028	1.16	0.528116566	1.53

wt 0.2406053 1.40 0.385610737 1.12

Se il rapporto **ca/sa** è superiore a 2.6 la asimmetria è significativa. Se il rapporto **cc/sc** è superiore a 2.6 la curtosi è significativa. Questo modo semplificato di effettuare il test di significatività è stato adottato per alleggerire il codice dello script, ma nulla impedisce di approfondire al bisogno lo studio delle variabili cui si è maggiormente interessati con altri test di gaussianità [3].

Non ho consigli pratici in merito ai criteri da impiegare per la scelta tra l'uno o l'altro dei due test non parametrici, a parte il fatto che rispetto al **ρ** di Spearman il coefficiente di correlazione **τ** di Kendall è più robusto (meno influenzato da valori estremi) ed è più conservativo (a parità di condizioni fornisce valori di **p** maggiori quindi significatività inferiori).

Lo script per l'analisi della correlazione basata sul **coefficiente di correlazione per ranghi ρ (rho) di Spearman** ricalca il precedente, copiatelo e incollatelo nella Console di R e premete ↵ Invio:


```

# COEFFICIENTE DI CORRELAZIONE PER RANGHI  $\rho$  (rho) di Spearman (non parametrico)
#
library(DAAG) # carica il pacchetto che include il set di dati ais
mydata <- ais[c(1:11)] # salva in mydata solamente le colonne contenenti variabili numeriche
#
# coefficiente di correlazione per ranghi  $\rho$  di Spearman con valori p di significatività
#
library(Hmisc) # carica il pacchetto
rcorr(as.matrix(mydata), type="spearman") # mostra i valori di  $\rho$  di Spearman e i valori di p
corrispondenti
#
# grafico xy per tutte le coppie di variabili
#
library(car) # carica il pacchetto
scatterplotMatrix(~rcc+wcc+hc+hg+ferr+bmi+ssf+pcBfat+lbm+ht+wt,
regLine=list(method=lm, lty=1, lwd=2, col="red"), smooth=FALSE,
diagonal=list(method="density", bw="nrd0", adjust=1, kernel="gaussian", na.rm=TRUE),
col="black", main="Grafici di dispersione", data=mydata) # traccia i grafici di dispersione xy
che incrociano tutte le variabili
#
# correlogrammi
#
library(corrgram) # carica il pacchetto
windows() # apre una nuova finestra
corrgram(mydata, cor.method="spearman", order=FALSE, lower.panel=panel.pts,
upper.panel=panel.pie, text.panel=panel.txt, main="Correlogramma ( $\rho$  di Spearman)") #
correlogramma con grafici xy e grafici a torta
#
windows() # apre una nuova finestra
corrgram(mydata, cor.method="spearman", order=FALSE, lower.panel=panel.pts,
upper.panel=panel.cor, text.panel=panel.txt, main="Correlogramma ( $\rho$  di Spearman)") #
correlogramma con grafici xy e  $\rho$  di Spearman
#
windows() # apre una nuova finestra
corrgram(mydata, cor.method="spearman", order=FALSE, lower.panel=panel.pts,
upper.panel=panel.ellipse, text.panel=panel.txt,
diag.panel=panel.density, main="Correlogramma ( $\rho$  di Spearman)") # correlogramma con
grafici xy ed ellissi delle tendenze con curva loess
#
library(gclus) # carica il pacchetto
windows() # apre una nuova finestra
rho <- cor(mydata, method="spearman") #  $\rho$  di Spearman
mydata.col <- dmat.color(abs(rho)) # applica i colori
mydata.o <- order.single(abs(rho)) # dispone le variabili meglio correlate più vicine alla
diagonale
cpairs(mydata, mydata.o, panel.colors=mydata.col, gap=.5, main="Gradiente di
correlazione ( $\rho$  di Spearman)") # mostra il grafico
#
# test di gaussianità (asimmetria e curtosi)
#
library(moments) # carica il pacchetto
print(paste("numero dei dati =", n <- nrow(mydata)), quote=FALSE)
print(paste("deviazione standard del coefficiente di asimmetria (sa) =", sa <- sqrt(6/n)),
quote=FALSE)
print(paste("deviazione standard del coefficiente di curtosi (sc) =", sc <- sqrt(24/n)),
quote=FALSE)

```

```
#
ca <- skewness(mydata) # coefficiente di asimmetria (ca)
ca_sa <- round(abs(ca/sa), digits=2) # rapporto (ca/sa)
#
cc <- kurtosis(mydata)-3 # coefficiente di curtosi (cc)
cc_sc <- round(abs(cc/sc), digits=2) # rapporto (cc/sc)
#
ascurt <- data.frame(ca, ca_sa, cc, cc_sc) # costruisce la tabella
names(ascurt) <- c("ca", "ca/sa", "cc", "cc/sc") # assegna i nomi alle colonne
ascurt # mostra la tabella
#
```

Da notare che l'argomento **upper.panel=panel.conf** che riporta nel correlogramma i limiti di confidenza del coefficiente di correlazione può essere impiegato solamente con il test **r** di Pearson ed è stato qui sostituito con l'argomento **upper.panel=panel.cor**

L'analisi della correlazione per dati multivariati si conclude con lo script per l'analisi della correlazione basata sul **coefficiente di correlazione τ (tau) di Kendall**. Copiatelo e incollatelo nella `Console` di R e premete ↵ Invio:

```

# COEFFICIENTE DI CORRELAZIONE PER RANGHI  $\tau$  (tau) di Kendall (non parametrico)
#
library(DAAG) # carica il pacchetto che include il set di dati ais
mydata <- ais[c(1:11)] # salva in mydata solamente le colonne contenenti variabili numeriche
#
# coefficiente di correlazione  $\tau$  di Kendall
#
cor(mydata, method="kendall") # mostra i valori di  $\tau$  di Kendall
#
# grafico xy per tutte le coppie di variabili
#
library(car) # carica il pacchetto
scatterplotMatrix(~rcc+wcc+hc+hg+ferr+bmi+ssf+pcBfat+lbm+ht+wt,
regLine=list(method=lm, lty=1, lwd=2, col="red"), smooth=FALSE,
diagonal=list(method="density", bw="nrd0", adjust=1, kernel="gaussian", na.rm=TRUE),
col="black", main="Grafici di dispersione", data=mydata) # traccia i grafici di dispersione xy
che incrociano tutte le variabili
#
# correlogrammi
#
library(corrgram) # carica il pacchetto
windows() # apre una nuova finestra
corrgram(mydata, cor.method="kendall", order=FALSE, lower.panel=panel.pts,
upper.panel=panel.pie, text.panel=panel.txt, main="Correlogramma ( $\tau$  di Kendall)") #
correlogramma con grafici xy e grafici a torta
#
windows() # apre una nuova finestra
corrgram(mydata, cor.method="kendall", order=FALSE, lower.panel=panel.pts,
upper.panel=panel.cor, text.panel=panel.txt, main="Correlogramma ( $\tau$  di Kendall)") #
correlogramma con grafici xy e  $\tau$  di Kendall
#
windows() # apre una nuova finestra
corrgram(mydata, cor.method="kendall", order=FALSE, lower.panel=panel.pts,
upper.panel=panel.ellipse, text.panel=panel.txt,
diag.panel=panel.density, main="Correlogramma ( $\tau$  di Kendall)") # correlogramma con
grafici xy ed ellissi delle tendenze con curva loess
#
library(gclus) # carica il pacchetto
windows() # apre una nuova finestra
tau <- cor(mydata, method="kendall") #  $\tau$  di Kendall
mydata.col <- dmat.color(abs(tau)) # applica i colori
mydata.o <- order.single(abs(tau)) # dispone le variabili meglio correlate più vicine alla
diagonale
cpairs(mydata, mydata.o, panel.colors=mydata.col, gap=.5, main="Gradiente di
correlazione ( $\tau$  di Kendall)") # mostra il grafico
#
# test di gaussianità (asimmetria e curtosi)
#
library(moments) # carica il pacchetto
print(paste("numero dei dati =", n <- nrow(mydata)), quote=FALSE)
print(paste("deviazione standard del coefficiente di asimmetria (sa) =", sa <- sqrt(6/n)),
quote=FALSE)
print(paste("deviazione standard del coefficiente di curtosi (sc) =", sc <- sqrt(24/n)),
quote=FALSE)
#
ca <- skewness(mydata) # coefficiente di asimmetria (ca)

```

```

ca_sa <- round(abs(ca/sa), digits=2) # rapporto (ca/sa)
#
cc <- kurtosis(mydata)-3 # coefficiente di curtosi (cc)
cc_sc <- round(abs(cc/sc), digits=2) # rapporto (cc/sc)
#
ascurt <- data.frame(ca, ca_sa, cc, cc_sc) # costruisce la tabella
names(ascurt) <- c("ca", "ca/sa", "cc", "cc/sc") # assegna i nomi alle colonne
ascurt # mostra la tabella
#

```

Lo script ricalca il precedente. Anche in questo caso l'argomento **upper.panel=panel.conf** che riporta nel correlogramma i limiti di confidenza del coefficiente di correlazione e che può essere impiegato solamente con il test **r** di Pearson viene sostituito con l'argomento **upper.panel=panel.cor**

Lo sola differenza sostanziale, a parte ovviamente il differente coefficiente di correlazione, è la sostituzione della funzione **rcorr()**, che non prevede il calcolo del test **τ** di Kendall, con la funzione **cor()**. Il fatto che questa non riporti i valori di p di significatività del **τ** di Kendall si risolve ricorrendo al bisogno al confronto diretto tra le due variabili che interessano [4].

La conclusione?

*Non è vero che ricercare una correlazione equivale semplicemente a calcolare il coefficiente di correlazione lineare **r** e la sua significatività.*

Innanzitutto integrando i risultati:

- del coefficiente di correlazione e della sua significatività
- della valutazione grafica della linearità
- dei test di normalità (gaussianità) dei dati

abbiamo le basi per decidere se sia opportuno basare le nostre conclusioni sul più classico e tradizionale test **r** di Pearson, test parametrico basato sull'assunto di gaussianità e di linearità dei dati, o ricorrere in alternativa a un test non parametrico, il coefficiente di correlazione per ranghi **ρ** (rho) di Spearman oppure il coefficiente di correlazione **τ** (tau) di Kendall, che forniscono una misura della correlazione valida anche quando i dati non soddisfano i requisiti di normalità (gaussianità) e di linearità necessari per applicare **r**.


Ad esempio per le variabili **hc** e **hg** (per il significato delle variabili vedere il post [Il set di dati ais](#)) abbiamo che:

- il valore del coefficiente di correlazione lineare **r** di Pearson è elevato ed è significativo;
 - i grafici mostrano una evidente relazione lineare tra le due variabili;
 - i test di normalità (gaussianità) confermano per entrambe le variabili una distribuzione gaussiana;
- pertanto possiamo basare le nostre conclusioni in merito alla correlazione sul coefficiente di correlazione lineare **r** di Pearson.

Nel caso della correlazione tra le variabili **bmi** e **ssf** abbiamo che:

- i valori del coefficiente di correlazione **ρ** (rho) di Spearman e del coefficiente di correlazione **τ** (tau) di Kendall sono elevati e sono significativi;
 - i grafici ci mostrano tra le due variabili una relazione praticamente casuale (difficile poterla considerare "lineare");
 - i test di normalità (gaussianità) confermano per entrambe le variabili una distribuzione non gaussiana;
- pertanto **r** non è applicabile e per le nostre conclusioni in merito alla correlazione dobbiamo ricorrere a uno dei due test non parametrici.

Ma non è tutto. Nel confronto che abbiamo fatto tra le variabili **rcc** e **wcc**



abbiamo un esempio tipico di una situazione nella quale un r significativo ($p = 0.0367$) è fuorviante e sarebbe sbagliato basarsi solamente su di esso senza considerare il contesto nel quale è stato generato, infatti:

→ una delle due condizioni per applicare il *coefficiente di correlazione lineare r di Pearson* è che i dati siano distribuiti in modo gaussiano mentre i test mostrano che la variabile `rcc` ha una asimmetria significativa e la variabile `wcc` ha asimmetria e curtosi significative, quindi i dati non sono distribuiti in modo gaussiano;

→ l'altra delle due condizioni per applicare il coefficiente di correlazione lineare r di Pearson è che i dati seguano un andamento lineare. Essendo $r = 0.15$ abbiamo che R^2 – il **coefficiente di determinazione**, che rappresenta la variabilità spiegata dalla regressione lineare – è uguale a 0.0225 il che significa che solamente il 2.2% della variabilità osservata è spiegata dalla regressione lineare, troppo poco per assumere che la relazione tra `rcc` e `wcc` possa essere rappresentata mediante una retta;

→ il grafico xy di `rcc` e `wcc` mostra una distribuzione dei punti in un'area sostanzialmente circolare, nella quale non vi è alcuna tendenza che possa essere ragionevolmente approssimata mediante una retta;

→ queste osservazioni confermano che il coefficiente di correlazione r non è applicabile e indicano la necessità di ricorrere a un coefficiente di correlazione non parametrico – il *coefficiente di correlazione per ranghi ρ (rho) di Spearman* o il *coefficiente di correlazione τ (tau) di Kendall* – che è in grado di fornire una misura della correlazione valida anche quando i dati non soddisfano i requisiti di normalità (gaussianità) e di linearità previsti per r .

C'è infine dell'altro che coinvolge tutti i coefficienti di correlazione in quanto:

→ per valori identici del coefficiente di correlazione, tanto maggiore è il numero di dati sui quali un valore è stato calcolato, tanto maggiore è la sua significatività (cioè tanto minore è il valore di p) – in altre parole è possibile rendere significativo un coefficiente di correlazione aumentando opportunamente il numero dei dati senza che il coefficiente cambi valore;

→ il coefficiente di correlazione misura la forza del legame tra due variabili ponendola tra 0 e 1 e l'esperienza insegna che valori inferiori a 0.5 corrispondono a correlazioni che non hanno rilevanza pratica – qui abbiamo 0.15 per r , 0.17 per ρ , 0.11 per τ , cioè valori ormai prossimi allo 0, in sostanza valori inadeguati;

→ a prescindere dal fatto che r in questo caso non deve essere impiegato per le ragioni riportate sopra, questi valori inadeguati del coefficiente di correlazione risultano paradossalmente significativi sia per r ($p = 0.0367$), sia per ρ ($p = 0.01697$), sia per τ ($p = 0.02104$) in virtù del numero elevato (202) di dati sui quali è stato calcolato;

→ è ragionevole concludere che i coefficienti di correlazione r , ρ e τ in questo caso sono falsamente significativi:

a) a causa della distorsione indotta sui risultati dalla numerosità campionaria;

b) perché p è appena al di sotto della soglia del 5% ($p = 0.05$) e potremmo optare per una più prudente soglia dell'1% ($p = 0.01$) che li renderebbe tutti e tre non significativi;

c) perché dal grafico non si riesce proprio a immaginare un qualsivoglia tipo di relazione che colleghi le due variabili;

d) in quanto (soprattutto) sappiamo che nei soggetti sani (come sono gli atleti australiani i cui valori ematologici e biometrici sono riportati nel set di dati **ais** qui impiegato) i meccanismi di produzione dei globuli rossi (r_{cc}) e dei globuli bianchi (w_{cc}) del sangue sono tra loro indipendenti e quindi non in relazione l'uno con l'altro.

Quest'ultima osservazione ci riporta ancora ai principi generali soggiacenti alla correlazione ricordandoci che:

- uno studio di correlazione ha un senso solamente quando sia supportato da un modello di un evento – fisico, chimico-fisico, biologico, fisiologico, econometrico o quant'altro – che si assume spieghi e descriva adeguatamente la relazione di funzione che intercorre tra le variabili;
- è indispensabile verificare che gli assunti alla base del modello di correlazione impiegato siano rispettati;
- esistono alternative al coefficiente di correlazione lineare r che è necessario utilizzare quando detti assunti non sono rispettati;
- correlazione statisticamente significativa non significa causazione [5], l'assunzione implicita di un rapporto di causa-effetto in seguito ad un coefficiente di correlazione significativo è una trappola subdola e ricorrente nella statistica [6].

Nonostante questi limiti, in **R** sono disponibili gli strumenti che, impiegati in modo appropriato, possono fornire un valido aiuto quando si vogliono analizzare i dati alla ricerca di una possibile correlazione, che in ogni caso va interpretata con attenzione, cautela e spirito critico.

[1] Cerco per quanto possibile di evitare l'aggettivo "*normale*" in quanto viene impiegato con troppi differenti significati: la distribuzione cui ci si riferisce è a rigore la "*distribuzione gaussiana*".

[2] Trovate i relativi manuali in: *Available CRAN Packages By Name*.

https://cran.r-project.org/web/packages/available_packages_by_name.html

[3] I metodi per l'analisi della normalità (gaussianità) di una distribuzione sono riportati in:

- [Test di normalità \(gaussianità\)](#);
- [Valutare asimmetria e curtosi](#);
- [Tabulare una serie di test di normalità \(gaussianità\)](#).

[4] Vedere il post [Ricerca una possibile correlazione \(tra due variabili\)](#).

[5] "*Correlation is not causation*". In: Campbell MJ, Machin D. *Medical Statistics. A Commonsense Approach*. John Wiley & Sons, New York, 1993, ISBN 0-471-93764-9, p. 103.

[6] Vedere quanto ho già sottolineato nel post [Correlazione e causazione](#).
