

Tracciare barre dell'errore e limiti di confidenza

Questa volta vediamo come con **ggplot2** sia possibile, impiegando una sola riga di codice, ottenere rappresentazioni multiple di una statistica (come ad esempio la media) con le corrispondenti **barre dell'errore**, che tecnicamente definiscono i **limiti di confidenza** della statistica.

Limiti di confidenza di una distribuzione campionaria

In questo primo esempio sottraiamo e sommiamo alla media di una variabile 1.96 volte la sua deviazione standard ottenendo i limiti di confidenza al 95% della **distribuzione** campionaria cioè i limiti entro i quali si trova il 95% dei dati del campione in esame.

Copiate e incollate nella `Console di R` questo script e premete ↵ `Invio`.

```
# BARRE DELL'ERRORE E LIMITI DI CONFIDENZA della distribuzione campionaria
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(dplyr) # carica il pacchetto per i calcoli
library(ggplot2) # carica il pacchetto per la grafica
#
# calcola media e deviazione standard separatamente per sport e per sesso
#
ais_stat <- ais %>% group_by(sport, sex) %>% summarise(mean_hg=mean(hg),
sd_hg=sd(hg)) %>% ungroup()
#
# crea il grafico ma alcuni dati risultano sovrapposti
#
ggplot(ais_stat, aes(x=sport, y=mean_hg, color=sex)) + geom_point(size=3) +
geom_errorbar(aes(ymin=mean_hg-1.96*sd_hg, ymax=mean_hg+1.96*sd_hg),
width=0.2) + labs(x="Sport praticato", y="Emoglobina in g/dL", color="Sesso
dell'atleta") + theme_minimal() + theme(legend.position="top")
#
```

Le prime tre righe servono a caricare i pacchetti necessari, che devono essere preventivamente scaricati dal **CRAN**, il primo dei quali contiene il set di dati **ais** impiegato come esempio [1].

La quarta riga di codice serve per preparare i dati impiegando l'operatore pipe (`%>%`) [2] che trasferisce i dati da una funzione alla successiva in questo modo:


- i dati (**ais**) sono trasferiti (`%>%`) alla funzione **group_by()**;
- la funzione **group_by()** raggruppa i dati in sottoinsiemi per sport praticato (**sport**) e per sesso dell'atleta (**sex**) e il risultato di questa suddivisione viene trasferito (`%>%`) alla funzione **summarise()**;
- la funzione **summarise()** calcola la media **mean()** e deviazione standard **sd()** della variabile **hg** che è la concentrazione nel sangue dell'emoglobina (espressa in g/dL, grammi per decilitro di sangue) dei 202 atleti australiani [1] suddivisi per sport e per sesso, e il risultato viene salvato (`<-`) nella tabella **ais_stat**;
- i risultati sono trasferiti (`%>%`) alla funzione **ungroup()** che rimuove dalla tabella **ais_stat** una serie di valori impiegati provvisoriamente per generarla.

L'ultima riga di codice realizza un grafico:

- impiegando le statistiche salvate nella variabile **ais_stat**;
- riportando in ascisse lo sport praticato (**sport**), in ordinate la media dell'emoglobina (**mean_hg**), assegnando colori diversi in base al sesso (**sex**);
- riportando un grafico a punti (**geom_point**) dei dati;

- aggiungendo con **geom_errorbar()** le barre che indicano l'errore che nel nostro caso è rappresentato da **1.96** volte la deviazione standard (**sd_hg**);
- aggiungendo con **labs()** le opportune etichette;
- impiegando con **theme_minimal()** una rappresentazione semplice;
- posizionando infine la legenda in alto (**legend.position="top"**).

Questo è il grafico.




Poiché le barre dell'errore nei due sessi risultano sovrapposte, riducendo la chiarezza del grafico, riprendiamo lo stesso codice con la piccola modifica evidenziata in colore nel codice. Copiate e incollate nella Console di R questo script e premete ↵ Invio.

```
# BARRE DELL'ERRORE E LIMITI DI CONFIDENZA della distribuzione campionaria
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(dplyr) # carica il pacchetto per i calcoli
library(ggplot2) # carica il pacchetto per la grafica
#
# calcola media e deviazione standard separatamente per sport e per sesso
#
ais_stat <- ais %>% group_by(sport, sex) %>% summarise(mean_hg=mean(hg),
sd_hg=sd(hg)) %>% ungroup()
#
# crea il grafico evitando la sovrapposizione dei dati
ggplot(ais_stat, aes(x=sport, y=mean_hg, color=sex)) + geom_point(size=3,
position=position_dodge(width=0.5)) + geom_errorbar(aes(ymin=mean_hg-1.96*sd_hg,
ymax=mean_hg+1.96*sd_hg), width=0.2, position=position_dodge(width=0.5)) +
labs(x="Sport praticato", y="Emoglobina in g/dL", color="Sesso dell'atleta") +
theme_minimal() + theme(legend.position="top")
#
```

L'unica differenza è che aggiungiamo alla funzione **geom_point()** e alla funzione **geom_errorbar()** l'argomento **position=position_dodge(width=0.5)**: questo consente

di eliminare la sovrapposizione delle barre dell'errore.



Se ora digitate **ais_stat** nella Console di R potete visualizzare i dati impiegati per realizzare i due grafici precedenti: le medie (`mean_hg`) e le deviazioni standard (`sd_hg`), suddivise per ciascuno sport (`sport`) e per ciascun sesso (`sex`).

```
> ais_stat
# A tibble: 17 × 4
  sport    sex mean_hg sd_hg
  <fct>   <fct>   <dbl> <dbl>
1 B_Ball  f      13.1 0.878
2 B_Ball  m      15.1 0.922
3 Field   f      14.6 0.682
4 Field   m      16.0 0.805
5 Gym     f      13.6 0.860
6 Netball f      12.8 0.567
7 Row     f      14.0 0.740
8 Row     m      15.4 0.711
9 Swim    f      13.6 0.583
10 Swim   m      15.5 0.655
11 T_400m f      13.8 1.04
12 T_400m m      15.3 0.824
13 T_Sprnt f      14.2 0.556
14 T_Sprnt m      16.2 1.49
15 Tennis f      13.5 1.10
16 Tennis m      15.6 1.48
17 W_Polo m      15.5 0.718
```


Limiti di confidenza di una media campionaria

Ripetiamo l'analisi dei dati: ma questa volta sottraiamo e sommiamo alla media della variabile 1.96 volte il suo errore standard ottenendo così i limiti di confidenza al 95% della **media** campionaria, che forniscono una misura del grado di incertezza che caratterizza detta media.

Copiate e incollate nella Console di R questo script e premete ↵ Invio.

```
# BARRE DELL'ERRORE E LIMITI DI CONFIDENZA della media campionaria
#
library(DAAG) # carica il pacchetto che include il set di dati ais
library(dplyr) # carica il pacchetto per i calcoli
library(ggplot2) # carica il pacchetto per la grafica
library(plotrix) # carica il pacchetto per il calcolo dell'errore standard
#
# calcola media e deviazione standard separatamente per sport e per sesso
#
ais_stat <- ais %>% group_by(sport, sex) %>%
summarise(mean_hg=mean(hg), es_hg=std.error(hg)) %>% ungroup()
#
# crea il grafico evitando la sovrapposizione dei dati
#
ggplot(ais_stat, aes(x=sport, y=mean_hg, color=sex)) + geom_point(size=3,
position=position_dodge(width=0.5)) + geom_errorbar(aes(ymin=mean_hg-1.96*es_hg,
ymax=mean_hg+1.96*es_hg), width=0.2, position=position_dodge(width=0.5)) +
labs(x="Sport praticato", y="Emoglobina in g/dL", color="Sesso dell'atleta") +
theme_minimal() + theme(legend.position="top")
#
```

Da notare che deve essere installato anche il pacchetto **plotrix** che viene impiegato per calcolare l'errore standard della media. Per il resto viene impiegato esattamente lo stesso codice dello script precedente, semplicemente sostituendo la deviazione standard dell'emoglobina con l'errore standard della media (**es_hg**) calcolato con la funzione **std.error()**. Questo è il risultato.



Come si rileva dal grafico, a parte il caso del tennis (Tennis), all'interno di ciascuno sport i limiti di confidenza al 95% delle medie dell'emoglobina negli atleti dei due sessi non si sovrappongono (la considerazione che se ne può trarre è riportata qui sotto nella Conclusione).

Se digitate **ais_stat** nella Console di R potete ora visualizzare la tabella che contiene media (**mean_hg**) ed errore standard (**es_hg**) calcolati per ciascuno sport (**sport**) e per ciascun sesso (**sex**).

```
> ais_stat
# A tibble: 17 × 4
  sport    sex mean_hg es_hg
  <fct>   <fct>   <dbl> <dbl>
1 B_Ball  f      13.1  0.243
2 B_Ball  m      15.1  0.266
3 Field   f      14.6  0.258
4 Field   m      16.0  0.232
5 Gym     f      13.6  0.430
6 Netball f      12.8  0.118
7 Row     f      14.0  0.158
8 Row     m      15.4  0.184
9 Swim    f      13.6  0.194
10 Swim   m      15.5  0.182
11 T_400m f      13.8  0.312
12 T_400m m      15.3  0.194
13 T_Sprnt f      14.2  0.278
14 T_Sprnt m      16.2  0.450
15 Tennis f      13.5  0.414
16 Tennis m      15.6  0.741
17 W_Polo m      15.5  0.174
```

Conclusione:

→ il termine barra dell'errore o errorbar indica semplicemente l'espedito grafico impiegato per rappresentare attorno al valore di una statistica i suoi **limiti di confidenza** al livello di probabilità desiderato, che il più delle volte viene fissato al 95%;

→ i limiti di confidenza al 95% della **distribuzione** campionaria – calcolati come $\text{media} \pm 1.96 \cdot \text{ds}$ (deviazione standard) – sono i limiti all'interno dei quali cade il 95% dei valori osservati nel campione esaminato, quindi la probabilità che un dato risulti al di fuori di questi limiti è del 5%;

→ i limiti di confidenza al 95% della **media** campionaria – calcolati come $\text{media} \pm 1.96 \cdot \text{es}$ (errore standard) – sono i limiti all'interno dei quali abbiamo il 95% di probabilità che cada la media, quindi la probabilità che la media che andiamo ricercando risulti al di fuori di questi limiti è del 5% (stante l'informazione contenuta nel nostro campione). Questi limiti forniscono un test di significatività della differenza tra le medie: quando i limiti di confidenza al 95% di due medie non si sovrappongono, possiamo affermare che tra le due medie esiste una differenza statisticamente significativa. Quindi nel nostro caso possiamo concludere che all'interno di ciascuno degli sport praticati da entrambi i sessi, con una sola eccezione, la concentrazione media dell'emoglobina nelle atlete è significativamente inferiore a quella degli atleti e che la probabilità che questa conclusione sia errata è del 5% o meno;

→ il risultato di una statistica dovrebbe essere sempre riportato con la sua **incertezza**, espressa in termini dei suoi limiti di confidenza opportunamente specificati: limiti di confidenza al 95%, limiti di confidenza al 99%, $\text{media} \pm n \cdot \text{ds}$, $\text{media} \pm n \cdot \text{es}$, ove n è l'opportuno moltiplicatore, eccetera.

[1] Vedere il post [Il set di dati ais](#) nel quale trovate anche come caricare i dati senza impiegare il pacchetto **DAAG**.

[2] Vedere il post [Come impiegare l'operatore %>% e l'argomento FUN](#).