

Tracciare kernel density plot sovrapposti

Abbiamo una distribuzione bimodale quando, all'interno della stessa variabile, coesistono due sottoinsiemi differenti, con differente moda (e media).

In effetti è noto che la concentrazione degli eritrociti (globuli rossi) nel sangue nella donna è mediamente inferiore a quella presente nell'uomo. Impiegando la concentrazione degli eritrociti nel sangue rilevata in 202 atleti australiani riportata nella colonna/variabile `rcc` della tabella **ais** inclusa nel pacchetto **DAAG**, verifichiamo la loro distribuzione impiegando uno script che genera due kernel density plot separati - uno per il sesso/fattore `m` e uno per il sesso/fattore `f` - e vediamo se si sovrappongono. Accertatevi di avere installato il pacchetto o in alternativa procedete come indicato in [1].

Lo script richiede inoltre il pacchetto aggiuntivo **sm** che deve essere anch'esso preventivamente scaricato e installato dal **CRAN**.

Copiate lo script, incollatelo nella Console di R e premete ↵ Invio:

```
# KERNEL DENSITY PLOT SOVRAPPOSTI separati per sesso
#
library(DAAG) # carica il pacchetto DAAG che include il set di dati ais
str(ais) # mostra la struttura di ais
#
library(sm) # carica il pacchetto
attach(ais) # funzione per impiegare direttamente i nomi delle variabili di ais
#
# al termine fare click con il tasto sinistro del mouse nel punto in cui si desidera posizionare la
legenda
#
windows() # apre una nuova finestra
sm.density.compare(rcc, sex, xlab="Eritrociti in 10^12/L", ylab="Stima kernel di
densità") # traccia kernel density plot separati per sesso
title(main="Concentrazione degli eritrociti per sesso") # aggiunge il titolo
sesso <- factor(sex, levels= c("f","m"), labels = c("Donna", "Uomo")) # identifica i casi per
sesso
colfill<-c(2:(2+length(levels(sesso)))) # predispone i colori
legend(locator(1), levels(sesso), fill=colfill) # posiziona la legenda
#
```

Dopo avere caricato il pacchetto **DAAG** con il set di dati **ais**, viene mostrata la struttura dei dati:


```
> library(DAAG) # carica il pacchetto DAAG incluso il set di dati ais
Carico il pacchetto richiesto: lattice
> str(ais) # mostra la struttura di ais
'data.frame': 202 obs. of 13 variables:
 $ rcc : num 3.96 4.41 4.14 4.11 4.45 4.1 4.31 4.42 4.3 4.51 ...
 $ wcc : num 7.5 8.3 5 5.3 6.8 4.4 5.3 5.7 8.9 4.4 ...
 $ hc : num 37.5 38.2 36.4 37.3 41.5 37.4 39.6 39.9 41.1 41.6 ...
 $ hg : num 12.3 12.7 11.6 12.6 14 12.5 12.8 13.2 13.5 12.7 ...
 $ ferr : num 60 68 21 69 29 42 73 44 41 44 ...
 $ bmi : num 20.6 20.7 21.9 21.9 19 ...
 $ ssf : num 109.1 102.8 104.6 126.4 80.3 ...
 $ pcBfat: num 19.8 21.3 19.9 23.7 17.6 ...
 $ lbm : num 63.3 58.5 55.4 57.2 53.2 ...
 $ ht : num 196 190 178 185 185 ...
```

```
$ wt      : num  78.9 74.4 69.1 74.9 64.6 63.7 75.2 62.3 66.5 62.9 ...
$ sex     : Factor w/ 2 levels "f","m": 1 1 1 1 1 1 1 1 1 1 ...
$ sport   : Factor w/ 10 levels "B_Ball","Field",...: 1 1 1 1 1 1 1 1 1 1 ...
```

La variabile `sex` e la variabile `sport`, le due ultime elencate, sono i **fattori** che possono essere impiegati per la classificazione dei casi. La prima prevede due livelli di classificazione dei casi (`m`, `f`), la seconda ne prevede dieci (`B_Ball`, `Field`, `Gym`, `Netball`, `Row`, `Swim`, `T_400m`, `T_Sprnt`, `Tennis`, `W_Polo`).

Nello script per tracciare i kernel density plot separati per i due sessi viene impiegata la funzione **`sm.density.compare()`** del pacchetto **`sm`**, che prevede molto semplicemente come primo argomento la variabile (**`rcc`**) da analizzare e come secondo argomento il fattore (**`sex`**) da impiegare per la classificazione dei casi.

Il codice fa una cosa piuttosto interessante: dopo avere tracciato due kernel density plot indipendenti e sovrapposti per i soggetti di sesso maschile (**`m`**) e di sesso femminile (**`f`**) rimane in attesa. A questo punto, posizionate il mouse dove volete che compaia la legenda [2] e fate `click` con il tasto sinistro del mouse per farla comparire (e terminare lo script).



Il codice riportato non consente di spostare la legenda. Se non si è soddisfatti della sua posizione, è necessario rieseguire l'intero script e fare nuovamente `click` con il tasto sinistro del mouse nel punto in cui si vuole posizionare la legenda.

Come risulta evidente dal grafico i kernel density plot separati per sesso mostrano per la concentrazione degli eritrociti nel siero degli atleti australiani la presenza di due sottopopolazioni, una dovuta alle donne, con valori mediamente inferiori, e una dovuta agli uomini, con valori mediamente superiori. Quando i dati sono rappresentati senza essere differenziati per sesso, queste due sottopopolazioni si sommano, determinando la distribuzione bimodale degli eritrociti che si osserva negli istogrammi e nei kernel density plot [3].


Possiamo effettuare un ulteriore approfondimento grafico sugli eritrociti mediante kernel density plot separati per ciascuno degli sport. Copiate quest'altro script, incollatelo nella Console di R e

premete ↵ Invio:

```
# KERNEL DENSITY PLOT SOVRAPPOSTI separati per sport
#
library(DAAG) # carica il pacchetto DAAG incluso il set di dati ais
str(ais) # mostra la struttura di ais
#
library(sm) # carica il pacchetto
attach(ais) # funzione per impiegare direttamente i nomi delle variabili di ais
#
# al termine fare click con il tasto sinistro del mouse nel punto in cui si desidera posizionare la
legenda
#
windows() # apre una nuova finestra
mycol <- c("green", "red", "purple", "blue", "cyan", "grey50", "brown", "tomato",
"magenta", "gold") # predispone i colori per ciascuno sport
sm.density.compare(rcc, sport, col=mycol, xlab="Eritrociti in 10^12/L", ylab="Stima
kernel di densità") # traccia kernel density plot separati per sport
title(main="Concentrazione degli eritrociti per sport") # aggiunge il titolo
sprt <- factor(sport, levels=c("B_Ball", "Field", "Gym", "Netball", "Row", "Swim",
"T_400m", "T_Sprnt", "Tennis", "W_Polo"), labels=c("Basketball", "Field", "Gymnastics",
"Netball", "Rowing", "Swimming", "Track 400m", "Track Sprint", "Tennis", "Water
Polo")) # identifica i casi per sport
legend(locator(1), levels(sprt), fill=mycol) # posiziona la legenda
#
```

In questo caso i colori sono scelti e assegnati a ciascuno sport mediante il vettore **mycol** che viene poi impiegato sia nella funzione **sm.density.compare()** sia nella funzione **legend()**.

Di nuovo posizionate il mouse dove volete che compaia la legenda, e fate `click` con il tasto sinistro del mouse per farla comparire (e terminare lo script).



Questo grafico fornisce una prova tangibile delle notevoli rappresentazioni grafiche che possono essere realizzate con **R** quando i dati in ingresso sono adeguatamente raccolti e organizzati.

[1] Vedere il post [Il set di dati ais](#). La concentrazione degli eritrociti viene espressa in $10^{12}/L$ o in $10^6/\mu L$, le due unità di misura impiegate nella pratica, che sono numericamente identiche. Nel post trovate anche come caricare i dati della tabella senza impiegare il pacchetto **DAAG**.

[2] Più precisamente nel punto in cui viene fatto il click verrà posizionato l'angolo superiore sinistro della legenda.

[3] Potete osservare la distribuzione bimodale nel post [Istogrammi](#) e nel post [Kernel density plot](#).
