

Identificare i dati in un grafico xy con un click

Accade con una certa frequenza, nel corso dell'analisi esplorativa dei dati, osservando un grafico di dispersione (xy), di porsi la domanda: questo valore, che si discosta così tanto dagli altri, a quale dato corrisponde?

R fornisce con uno strumento molto efficace per identificare il numero del record/riga che corrisponde ad uno specifico punto riportato in un grafico, la funzione **identify()** [1], il cui utilizzo viene illustrato con questo script. Copiatelo e incollatelo nella Console di R e premete ↵ Invio:

```
# IDENTIFICA I DATI IN UN GRAFICO CON UN SEMPLICE CLICK
#
library(DAAG) # carica il pacchetto che include il set di dati ais
attach(ais) # consente di impiegare direttamente i nomi delle variabili
#
windows() # apre una nuova finestra
#
plot(rcc, hc, main="Identifica i punti in un grafico", xlab="Eritrociti (10^12/L)",
ylab="Ematòcrito (%)", pch=1) # traccia il grafico di dispersione (xy)
#
# fare click accanto al punto da identificare, ripetere secondo necessità, premere <esc> per
terminare
identify(rcc, hc, plot=TRUE, atpen=FALSE, offset=0.5, tolerance=0.25)
#
```

I dati impiegati sono contenuti nel [set di dati ais](#). Dopo che con la funzione **plot()** [2] è stato tracciato il grafico di dispersione (xy), la funzione **identify()** consente di identificare nel grafico uno o più punti impiegando i seguenti argomenti:


- **rcc** la variabile in ascisse;
- **hc** la variabile in ordinate;
- **plot=TRUE** che visualizza l'identificativo del dato sul quale si è fatto click con il mouse;
- **atpen=FALSE** che posiziona l'identificativo del dato lievemente discosto dal punto al quale corrisponde (provare a cambiare l'argomento ponendo **atpen=TRUE** per vedere la differenza);
- **offset=0.5** che indica la distanza che l'identificativo del dato deve avere dal punto al quale corrisponde;
- **tolerance=0.25** che indica la tolleranza ammessa per la distanza definita con l'argomento **offset**.

Facendo click con il tasto sinistro del mouse accanto a un punto, vedrete comparire il suo identificativo. L'operazione può essere ripetuta per più punti. Di default viene emesso un suono ogniquale si fa click e viene identificato un punto: per silenziare la funzione **identify()** è necessario aggiungere l'argomento **locatorBell=FALSE**.

Per uscire dal processo di identificazione e terminare lo script è sufficiente premere il tasto <esc>.

Questo è il grafico ottenuto dopo avere fatto click con il tasto sinistro del mouse sui valori che più si discostano dai rimanenti, valori identificati dalla funzione **identify()** come corrispondenti ai dati numero [68](#), [78](#), [161](#) e [166](#).

Come è facile intuire questa funzione grafica avanzata è molto interessante perché permette di individuare e identificare quelli che i test statistici possono avere indicato come possibili dati anomali (o dati aberranti o outliers).



Potete riutilizzare facilmente lo script sostituendo all'oggetto **ais** l'oggetto contenente i vostri dati, opportunamente strutturati, e modificando conseguentemente i nomi della variabili. Per una guida rapida all'importazione dei dati potete consultare i link:

- [importazione dei dati da un file .csv](#)
- [importazione dei dati da un file .xls o .xlsx](#)
- [gestione dei dati mancanti](#)

[1] Per la documentazione della funzione **identify()** digitare **help(identify)** nella *Console di R*.

[2] Per la documentazione della funzione **plot()** digitare **help(plot)** nella *Console di R*.
