

Curve ROC e valore soglia

Nel post [Teorema di Bayes e diagnosi medica](#) abbiamo visto che è possibile impiegare il teorema per rispondere, sulla base dei risultati di un test diagnostico per una specifica malattia, alle domande:

→ quale probabilità ha di essere malato un soggetto cui il test è risultato positivo?


→ quale probabilità ha di essere sano un soggetto cui il test è risultato negativo?

Per farlo dobbiamo calcolare il **valore soglia** che meglio discrimina tra sani e malati, e ricavare la **sensibilità** e la **specificità** del test che ad esso corrispondono, impiegando:

→ i risultati del test in questione in un campione rappresentativo di sani e di malati;


→ un metodo per calcolare il valore soglia del test che meglio discrimina tra sani e malati (sensibilità e specificità sono una conseguenza di questo).

I risultati del test sono raccolti eseguendolo, in condizioni controllate, nel corso di una sperimentazione, a un congruo numero di soggetti sani e di soggetti affetti dalla malattia diagnosticata dal test. Il metodo per calcolare il valore soglia applica la strategia diagnostica riportata nella Fig. 1d




che consente di identificare malati (casi) e sani (controlli) massimizzando veri positivi (VP) e veri negativi (VN), minimizzando falsi positivi (FP) e falsi negativi (FN) e individuando quindi il miglior equilibrio tra sensibilità e specificità del test. Alcuni cenni su questa e le altre strategie applicabili sono riportati nel post [Teorema di Bayes e diagnosi medica](#).

La relazione che intercorre tra i risultati del test ottenuti in un campione di soggetti sani, quelli ottenuti in un campione di soggetti malati e la loro curva ROC [1] è riportata in questa figura per un test diagnostico ideale, nel quale le distribuzioni dei risultati del test sono completamente separate, e l'area sotto la curva AUC (Area Under the Curve) è uguale a 1



in quest'altra figura per un test diagnostico inutile nel quale le distribuzioni dei risultati del test sono completamente sovrapposte, non è possibile discriminare, impiegando i risultati dello specifico test diagnostico, tra malati e sani, e l'AUC è uguale a 0.5



e infine in questa figura per un test diagnostico reale, nel quale è presente una parziale sovrapposizione tra i risultati del test nei sani e nei malati e l'AUC è tanto più prossima a 1 quanto meglio il test è in grado di discriminare i soggetti sani da quelli malati.



Quindi la curva ROC fornisce una misura della informazione fornita dal test, espressa come probabilità (misurata dall'AUC) che va da 0.5 (equivalente a decidere se un soggetto è sano o malato mediante il lancio di una moneta) a 1 (il test ci dice con certezza se il paziente è sano o malato). Per impiegare le funzioni del pacchetto **pROC**, i risultati del test raccolti durante la sperimentazione devono essere strutturati in due variabili, una variabile qualitativa, in **R** definita "fattore", e qui denominata `classe`, che contiene la classe di appartenenza (qui vengono impiegati i valori previsti di default nel pacchetto e cioè 0 per indicare un soggetto sano/controllo e 1 per indicare un soggetto malato/caso) e una variabile quantitativa, qui denominata `valore`, che per ciascun caso riporta il risultato del test, come appare in questi dati, i primi cinque e gli ultimi cinque del file `bayes.csv` che ci apprestiamo a impiegare:

```
classe;valore
0;19
0;22
0;26
0;28
0;29
.....
1;235
1;237
1;237
1;242
1;242
```

Quindi la coppia di valori 0;19 indica che in un sano/controllo (0) il risultato fornito dal test era 19; la coppia di valori 1;235 indica che in un malato/caso (1) il risultato fornito dal test era 235; e così via.

Per proseguire ora è necessario:

- effettuare il download del file `bayes.csv`
- salvare il file nella cartella `C:\Rdati\`

Trovate il file, con le istruzioni per scaricare questo e gli altri file di dati impiegati nei post, alla [pagina Dati](#).

Per effettuare i calcoli impieghiamo alcune funzioni contenute nei pacchetti aggiuntivi **pROC** e **sm** [2], che devono essere preventivamente scaricati dal **CRAN**. Copiate questo script, incollatelo nella Console di R e premete ↵ Invio:

```
# CURVE ROC E VALORE SOGLIA
```

```
#
```

```
mydata <- read.table("c:/Rdati/bayes.csv", header=TRUE, sep=";") # importa i dati
```

```
attach(mydata) # consente di impiegare direttamente i nomi delle variabili
```

```
str(mydata) # mostra la struttura dei dati della tabella importata
```

```
head(mydata, n=5) # lista dei primi 5 casi
```

```
tail(mydata, n=5) # lista degli ultimi 5 casi
```

```
#
```

```
sani <- subset(valore, classe==0) # sottoinsieme con i valori dei soggetti sani
```

```
malati <- subset(valore, classe==1) # sottoinsieme con i valori dei soggetti malati
```

```
#
```

```
windows() # apre una nuova finestra
```

```
par(mfrow=c(2,2)) # predispone la suddivisione della finestra in quattro quadranti, uno per grafico
```

```
#
```

```
# primo istogramma
```

```
#
```

```
hist(malati, xlim=c(0,250), ylim=c(0,0.04), xaxp = c(0, 250, 5), yaxp = c(0, 0.04, 4),  
breaks=seq(from=0, to=250, by=5), border="red", col="white", main="Istogramma",  
xlab="Valore osservato", ylab="Densità", freq=FALSE, plot=TRUE) # traccia istogramma  
malati
```

```
hist(sani, xlim=c(0,250), breaks=seq(from=0, to=250, by=5), border="green4",  
col="lightgreen", freq=FALSE, add=TRUE, plot=TRUE) # sovrappone istogramma sani
```

```
legend(150, 0.04, legend=c("Sani", "Malati"), col=c("green", "red"), lty=c(1,1),  
lwd=c(1,1), cex=0.8) # aggiunge al grafico la legenda
```

```
#
```

```
# secondo istogramma
```

```
#
```

```
hist(sani, xlim=c(0,250), ylim=c(0,0.04), xaxp = c(0, 250, 5), yaxp = c(0, 0.04, 4),  
breaks=seq(from=0, to=250, by=5), border="green4", col="lightgreen", main =  
"Istogramma", xlab = "Valore osservato", ylab = "Densità", freq=FALSE, plot=TRUE) #
```

```
traccia istogramma sani
```

```
hist(malati, breaks=seq(from=0, to=250, by=5), border="red", col="white", main="",  
freq=FALSE, add=TRUE, plot=TRUE) # sovrappone istogramma malati
```

```
legend(150, 0.04, legend=c("Sani", "Malati"), col=c("green", "red"), lty=c(1,1),  
lwd=c(1,1), cex=0.8) # aggiunge al grafico la legenda
```

```
#
```

```
# kernel density plot
```

```
#
```

```
library(sm) # carica il pacchetto
```

```
sm.density.compare(valore, classe, xlim=c(0,250), col=c("green", "red"), main="Kernel  
density plot", xlab="Valore osservato", ylab="Stima kernel di densità") # traccia kernel  
density plot separati per sani e malati
```

```
title(main="Kernel density plot") # aggiunge al grafico un titolo
```

```
legend(150, 0.03, legend=c("Sani", "Malati"), col=c("green", "red"), lty=c(1,2),  
lwd=c(1,1), cex=0.8) # aggiunge al grafico la legenda
```

```
#
```

```
# curva ROC
```

```
#
```

```
library(pROC) # carica il pacchetto
```

```
roc(response=classe, predictor=valore, smooth=FALSE, auc=TRUE, ci=TRUE, plot=TRUE,  
col="orange", identity=TRUE, identity.col="grey", identity.lty=3, main="Curva ROC",  
xlab="Specificità", ylab="Sensibilità") # traccia la curva ROC e riporta l'AUC con gli intervalli di  
confidenza
```

```
#
```

```
# calcola valore soglia, sensibilità e specificità con gli intervalli di confidenza
```

```
#
```

```

ci.thresholds(response=classe, predictor=valore, thresholds="best", conf.level=0.95, boot.n=100) # calcola il miglior valore soglia tra sani e malati e la sensibilità e la specificità corrispondenti con gli intervalli di confidenza al 95%
ci.se(response=classe, predictor=valore, specificities=seq(0,1,.1), conf.level=0.95, boot.n=100) # calcola gli intervalli di confidenza al 95% della sensibilità per valori di specificità da 0 a 1 con passo .1
ci.sp(response=classe, predictor=valore, sensitivities=seq(0,1,.1), conf.level=0.95, boot.n=100) # calcola gli intervalli di confidenza al 95% della specificità per valori di sensibilità da 0 a 1 con passo .1
#

```

La parte dello script che precede la creazione dei grafici si spiega da sola, con i commenti inseriti in ciascuna riga. L'unica cosa un po' particolare è la funzione **subset()** [3] che viene impiegata per generare, dai dati importati, due sottoinsiemi separati, uno contenente solamente i valori dei soggetti sani/controlli e l'altro contenente solamente i valori dei soggetti malati/casi, impiegando come argomenti:

- il nome della variabile (**valore**) dalla quale si desidera estrarre il sottoinsieme di valori;
- il criterio di selezione dei casi da estrarre, laddove **classe==0** indica di estrarre i valori per i quali nella variabile **classe** è riportato 0 (sano) e laddove **classe==1** indica di estrarre i valori per i quali nella variabile **classe** è riportato 1 (malato).

Nel blocco di codice che realizza gli istogrammi sono degni di nota i seguenti argomenti:

- **xlim = c(0,250)** indica limite inferiore e limite superiore della scala applicata all'asse delle ascisse;
- **ylim = c(0,0.04)** indica limite inferiore e limite superiore della scala applicata all'asse delle ordinate, sulla quale è riportata la densità (di probabilità) della distribuzione dei dati;
- **xaxp = c(0, 250, 5)** specifica che sull'asse delle ascisse la scala che va da 0 a 250 deve essere suddivisa in cinque intervalli, quindi sull'asse delle ascisse compariranno sei tacche con i valori 0, 50, 100, 150, 200, 250;
- **yaxp = c(0,0.04,4)** specifica che sull'asse delle ordinate la scala che va da 0 a 0.04 deve essere suddivisa in quattro intervalli, quindi sull'asse delle ordinate compariranno cinque tacche con i valori 0, 0.01, 0.02, 0.03, 0.04;
- **breaks=seq(from=0, to=250, by=5)** traccia l'istogramma tra 0 e 250 con classi di ampiezza 5;
- **freq=FALSE** comporta di riportare sull'asse delle ordinate non il numero di casi osservati in ciascuna classe bensì la densità di probabilità;
- **add=TRUE** permette che il secondo istogramma sia sovrapposto al primo.

Per la funzione **legend()** si rimanda a [4].

Per i kernel density plot sovrapposti l'unica cosa significativa è che sono tracciati mediante la funzione **sm.density.compare()** del pacchetto aggiuntivo **sm**, mentre la funzione **legend()** semplicemente adatta ai nuovi grafici gli argomenti già visti nel caso degli istogrammi.


La curva ROC viene tracciata mediante la funzione **roc()** che prevede come argomenti:

- la variabile che contiene la classificazione di ciascun caso (**response=caso**);
- la variabile che contiene il valore di ciascun caso (**predictor=valore**);
- **smooth=FALSE** in quanto non vogliamo che la curva ROC sia smussata (ma potete provare a farlo mettendo **TRUE**);
- **auc=TRUE** in quanto vogliamo che sia calcolata l'area sotto la curva AUC;
- **ci=TRUE** in quanto vogliamo che sia riportato l'intervallo di confidenza al 95% della AUC;
- il colore della curva ROC (**col="orange"**);
- **identity=TRUE** per riportare nel grafico la retta che va dall'angolo inferiore sinistro all'angolo superiore destro, **identity.col** per specificarne il colore, **identity.lty** per specificare lo stile della linea, che rappresenta la curva ROC di un test nel quale l'AUC è uguale a 0.5, i valori dei sani e quelli dei malati sono completamente sovrapposti, e non è possibile discriminare gli uni dagli altri (Fig. 2).

In altre parole, se la curva ROC del test coincide con la diagonale, il test fornisce la stessa informazione che viene fornita dal lancio di una moneta;

→ i noti argomenti impiegati per aggiungere a un grafico il titolo e le legende degli assi.

La funzione **roc()** completa i grafici [5] con la curva ROC del test [6]



quindi riporta il valore dell'AUC (0.9734) con il suo intervallo di confidenza al 95%:

```
Data: valore in 853 controls (classe 0) < 843 cases (classe 1).
Area under the curve: 0.9734
95% CI: 0.9664-0.9805 (DeLong)
```

La funzione **ci.thresholds()** riporta il miglior valore soglia tra sani e malati (74.5), insieme ai valori di specificità (0.9484) e di sensibilità (0.9063) corrispondenti, con i relativi intervalli di confidenza al 95% (**conf.level=0.95**):

```
> ci.thresholds(response=classe, predictor=valore, thresholds="best",
conf.level=0.95, boot.n=100) # calcola il miglior valore soglia tra sani e malati e
la sensibilità e la specificità corrispondenti con gli intervalli di confidenza al
95%
95% CI (100 stratified bootstrap replicates):
thresholds sp.low sp.median sp.high se.low se.median se.high
74.5 0.9349 0.9484 0.9643 0.8843 0.9063 0.9242
```

La funzione **ci.se()** consente di tabulare i valori di sensibilità corrispondenti ai valori di specificità prescelti, che qui con l'argomento **specificities=seq(0,1,.1)** sono fatti variare da 0 a 1 con passo 0.1, con i relativi intervalli di confidenza al 95% (**conf.level=0.95**):

```
> ci.se(response=classe, predictor=valore, specificities=seq(0,1,.1),
conf.level=0.95, boot.n=100) # calcola gli intervalli di confidenza al 95% della
sensibilità per valori di specificità da 0 a 1 con passo .1
sp se.low se.median se.high
0.0 1.0000 1.0000 1.0000
```

0.1	1.0000	1.0000	1.0000
0.2	0.9941	0.9976	1.0000
0.3	0.9882	0.9941	0.9988
0.4	0.9844	0.9912	0.9975
0.5	0.9754	0.9858	0.9923
0.6	0.9709	0.9821	0.9899
0.7	0.9567	0.9678	0.9762
0.8	0.9480	0.9597	0.9719
0.9	0.9138	0.9311	0.9453
1.0	0.6494	0.6821	0.7788

La funzione **ci.sp()** consente di tabulare i valori di specificità corrispondenti ai valori di sensibilità prescelti, che qui con l'argomento **sensitivities=seq(0,1,.1)** sono fatti variare da 0 a 1 con passo 0.1, con i relativi intervalli di confidenza al 95% (**conf.level=0.95**):

```
> ci.sp(response=classe, predictor=valore, sensitivities=seq(0,1,.1),
conf.level=0.95, boot.n=100) # calcola gli intervalli di confidenza al 95% della
specificità per valori di sensibilità da 0 a 1 con passo .1
  se sp.low sp.median sp.high
0.0 1.0000  1.0000  1.0000
0.1 1.0000  1.0000  1.0000
0.2 1.0000  1.0000  1.0000
0.3 1.0000  1.0000  1.0000
0.4 1.0000  1.0000  1.0000
0.5 1.0000  1.0000  1.0000
0.6 1.0000  1.0000  1.0000
0.7 0.9965  0.9990  1.0000
0.8 0.9900  0.9953  0.9999
0.9 0.9312  0.9538  0.9753
1.0 0.1354  0.1583  0.2446
```

Le funzioni **ci.treshold()**, **ci.se()**, **ci.sp()** impiegano un metodo di bootstrap per calcolare gli intervalli di confidenza: questo significa che i risultati generati ogni volta saranno lievemente differenti da quelli qui riportati.

L'AUC è uguale a **0.9734** (**0.9664-0.9805**); il miglior valore soglia tra sani e malati è **74.5** - per un valore inferiore o uguale al valore soglia il test è considerato negativo e per un valore superiore al valore soglia il test è considerato positivo [7].

Per il **valore soglia 74.5** abbiamo:

- un valore di **specificità del test** (mediana) uguale a **0.9484** che significa che il test è negativo nel 94.8% dei soggetti sani;
- un valore di **sensibilità del test** (mediana) uguale a **0.9063** che significa che il test è positivo nel 90.6% dei soggetti malati.

Da notare che una volta fissato il valore soglia tra sani e malati, la sensibilità e la specificità ad esso corrispondenti diventano le due caratteristiche diagnostiche tipiche del test.

Infine per importare ed elaborare i vostri dati, dopo averli strutturati come nel file bayes.csv, dovete semplicemente sostituire nella prima riga di codice **c:/Rdati/bayes.csv** con nome e posizione del vostro file di dati.

Potete trovare:

- nel post [Curve ROC sovrapposte](#) come riportare sullo stesso grafico due curve ROC per un più immediato confronto tra i risultati di due test per la diagnosi della stessa malattia;

→ nel post [Sensibilità, specificità e valore predittivo](#) come il valore predittivo del test positivo (la probabilità di essere malato per un soggetto che presenta un test positivo) e il valore predittivo del test negativo (la probabilità di essere sano per un soggetto che presenta un test negativo) possono essere calcolati impiegando il numero di casi osservati VP, FP, FN, VN;

→ nel post [Teorema di Bayes e diagnosi medica](#) come il valore predittivo del test positivo e quello del test negativo possono essere calcolati impiegando la sensibilità del test, la specificità del test e la prevalenza della malattia mediante la (iv) e la (v) lì riportate.

Rispondendo così finalmente alle due domande iniziali.

[1] Per una sintesi sul tema delle curve ROC vedere Altman nella [pagina Bibliografia](#).

[2] Trovate la documentazione completa dei pacchetti, indispensabile per impiegarne queste e le altre funzioni, nei loro manuali di riferimento che trovate alla pagina *Available CRAN Packages By Name*.
https://cran.r-project.org/web/packages/available_packages_by_name.html

[3] Digitate **help(subset)** nella Console di R per la documentazione della funzione **subset()**.

[4] Vedere il post [Aggiungere la legenda a un grafico](#).

[5] A scopo didattico i grafici sono stati compattati in un'unica figura, ma è possibile riportarli separatamente, impiegando la trasparenza dei colori per un miglior aspetto della sovrapposizione (vedere il post [Istogrammi](#) e il post [Kernel density plot](#)).

[6] Sull'asse delle ascisse del grafico di una curva ROC sono normalmente riportati i valori 1 - Specificità, valori che vanno da 0 a 1, con lo zero a sinistra e i valori in ordine crescente fino a 1 verso destra: come si confà a un grafico cartesiano. La rappresentazione realizzata con il pacchetto **pROC** riporta invece sull'asse delle ascisse i valori di Specificità, che, da sinistra verso destra, vanno da 1 a 0: una rappresentazione non canonica, che ha chiaramente lo scopo di evidenziare il rapporto inverso esistente tra sensibilità e specificità.

[7] L'esempio qui impiegato rappresenta la situazione più frequente, quella nella quale la malattia determina un aumento del risultato dei test, ma ovviamente è sufficiente ribaltare dati e conclusioni per riadattare il tutto a un caso nel quale la malattia determina una diminuzione del risultato del test.
