

Curve ROC sovrapposte

Le curve ROC sono già state illustrate [1]. Ora aggiungiamo un breve script che consente di riportare sullo stesso grafico le curve ROC di due diversi test per la diagnosi di una malattia X, qui denominati test 1 e test 2, onde confrontare anche visivamente la loro capacità di discriminare tra sani e malati, espressa numericamente come **AUC** (**A**rea **U**nder the **C**urve, area sotto la curva ROC).

Per proseguire è necessario:

→ effettuare il download del file `test_1.csv` e del file `test_2.csv`

→ salvare entrambi i file nella cartella `C:\Rdati\`

Trovate i file, con le istruzioni per scaricare questi e gli altri file di dati impiegati nei post, alla [pagina Dati](#).

Volendo impiegare le funzioni del pacchetto **pROC** i file di dati devono contenere i risultati del/i test strutturati in due variabili, una variabile quantitativa, qui denominata `valore`, che per ciascun caso riporta il risultato del test, e una variabile qualitativa, in **R** definita "*fattore*", e qui denominata classe, che contiene la classe di appartenenza (qui vengono impiegati i valori previsti di default nel pacchetto e cioè 0 per indicare un soggetto sano/controllo e 1 per indicare un soggetto malato/caso) come vedete ad esempio aprendo con un editor di testo il file `test_1.csv` che contiene i risultati del test 1:

```
valore;classe
19;0
22;0
22;1
24;1
24;1
26;0
```

Quindi la coppia di valori 19;0 indica che in un soggetto sano/controllo (0) il risultato fornito dal test era 19; la coppia di valori 22;0 indica che in un soggetto sano/controllo (0) il risultato fornito dal test era 22; la coppia di valori 22;1 indica che in un soggetto malato/caso (1) il risultato fornito dal test era 22; e così via.

Per effettuare i calcoli sono impiegate le funzioni del pacchetto aggiuntivo **pROC** [1] che deve essere scaricato, se non ancora fatto in precedenza, dal **CRAN**. Copiate questo script, incollatelo nella Console di R e premete ↵ Invio:

```
# CONFRONTO TRA DUE CURVE ROC
#
# importa i dati dei due test da mettere a confronto
test_1 <- read.table("c:/Rdati/test_1.csv", header=TRUE, sep=";")
test_2 <- read.table("c:/Rdati/test_2.csv", header=TRUE, sep=";")
#
library(pROC)
#
# traccia la curva ROC del primo test
roc(response=test_1$classe, predictor=test_1$valore, smooth=FALSE, auc=TRUE,
ci=FALSE, plot=TRUE, identity=FALSE, main="Confronto tra due curve ROC",
xlab="Specificità", ylab="Sensibilità")
# calcola valore soglia, sensibilità e specificità del primo test
ci.thresholds(response=test_1$classe, predictor=test_1$valore, thresholds="best",
conf.level=0.95, boot.n=100)
```

```
#
# sovrappone la curva ROC del secondo test
roc(response=test_2$classe, predictor=test_2$valore, smooth=FALSE, auc=TRUE,
ci=FALSE, plot=TRUE, add=TRUE, col="red", lty=4)
# calcola valore soglia, sensibilità e specificità del secondo test
ci.thresholds(response=test_2$classe, predictor=test_2$valore, thresholds="best",
conf.level=0.95, boot.n=100)
#
# aggiunge una legenda al grafico
legend(0.35, 0.8, legend=c(paste("Test 1, AUC =", round(auc(response=test_1$classe,
predictor=test_1$valore), digits=3), sep=" "), paste("Test 2, AUC =",
round(auc(response=test_2$classe, predictor=test_2$valore), digits=3), sep=" ")),
col=c("black", "red"), lty=c(1,4), cex=0.8) # aggiunge al grafico la legenda
#
```

Le prime due righe di codice provvedono a importare i dati. Con la terza viene caricato il pacchetto **pROC**.

Con la quarta e la quinta riga di codice le funzioni **roc()** e **ci.treshold()** sono impiegate rispettivamente per tracciare il grafico e calcolare le statistiche del primo test. Entrambe le funzioni le trovate illustrate in dettaglio in [1], nel manuale di riferimento del pacchetto [1] e anche digitando **help(roc)** e **help(ci.treshold)** nella Console di R.

Nelle due righe successive la funzione **roc()** viene impiegata con l'argomento **add=TRUE** per sovrapporre la seconda curva ROC alla prima, quindi con la funzione **ci.treshold()** sono calcolate le statistiche del secondo test.


Infine con l'ultima riga di codice al grafico viene aggiunta una legenda impiegando la funzione **legend()** i cui argomenti sono:

- **0.3** per indicare il valore in ascisse al quale posizionare l'angolo superiore sinistro del box della legenda;
- **0.75** per indicare il valore in ordinate al quale posizionare l'angolo superiore sinistro del box della legenda;
- **legend** che riporta con la funzione **c()** le etichette che descrivono il primo e il secondo test;
- **col** che riprende con la funzione **c()** i colori assegnati alle due curve ROC;
- **lty** che riprende lo stile delle linee delle due curve ROC;
- **cex** che dimensiona i caratteri della legenda.

Da notare che la funzione **legend()** è stata condensata in una sola riga di codice sfruttando una caratteristica fondamentale della programmazione a oggetti, cioè il fatto che una funzione può impiegare come valore per un argomento il risultato di una funzione, che a sua volta può impiegare come valore per un argomento il risultato di una funzione, e così via, come avviene in questo caso, nel quale:

- la funzione **legend()**, che costruisce la legenda,
 - impiega come terzo argomento **legend**, che riporta il contenuto della legenda
 - che a sua volta impiega il risultato della funzione **c()**, che fornisce i valori all'argomento **legend**
 - impiegando come primo argomento la funzione **paste()**
 - che impiega come secondo argomento il risultato della funzione **round()**, che arrotonda i risultati
 - impiegando come argomento il risultato della funzione **auc()**, che calcola il valore dell'area sotto la curva AUC impiegando come argomenti i dati del file `test_1.csv`
- ripetendo infine gli ultimi tre passi anche per i dati del file `test_2.csv`. Anche se va a scapito della leggibilità del codice, che di norma è preferibile spezzare su più righe introducendo opportune variabili accessorie, questo è comunque un esempio della possibilità di concisione offerta da **R**.

Ecco il grafico ottenuto mediante lo script:



La conclusione è che per la diagnosi della malattia X è preferibile impiegare il test 1, che con una $AUC = 0.963$ fornisce un'informazione diagnostica superiore a quella del test 2 ($AUC = 0.902$). E questo è espresso anche dal fatto che il test 1 ha sensibilità e specificità entrambe superiori a quelle del test 2.

Una analisi separata di ciascuno dei due test diagnostici qui messi a confronto può essere effettuata mediante lo script riportato in [1] semplicemente cambiando nella prima riga di codice il nome del file, sostituendo quindi `bayes.csv` prima con `test_1.csv` e poi con `test_2.csv`.

[1] Vedere il post [Curve ROC e valore soglia](#).

[1] Per la funzione **`roc()`** e la funzione **`ci.thresholds()`** vedere il manuale di riferimento del pacchetto *Package 'pROC'*.

<https://cran.r-project.org/web/packages/pROC/pROC.pdf>
