

Efficienza e accuratezza diagnostica [1]

Nel post [Teorema di Bayes e diagnosi medica](#) abbiamo visto che è possibile impiegare il teorema di Bayes per rispondere alle due domande: quale probabilità ha di essere affetto da una specifica malattia un soggetto cui un dato test per quella specifica malattia è risultato positivo? quale probabilità ha di essere sano un soggetto cui il test è risultato negativo?

E abbiamo visto come un modo semplice per farlo si basi sul numero di casi osservati, organizzati come in questa tabella

	Malattia +	Malattia -
Test +	VP	FP
Test -	FN	VN

nella quale sono definiti come:

- **veri positivi** (VP) i soggetti malati con il test positivo;
- **falsi positivi** (FP) i soggetti sani con il test positivo;
- **falsi negativi** (FN) i soggetti malati con il test negativo;
- **veri negativi** (VN) i soggetti sani con il test negativo.

Nel post [Curve ROC e valore soglia](#) abbiamo visto, dati i risultati di un test per la diagnosi di una malattia X, come impiegare il pacchetto **pROC** per tracciare la curva ROC [1] e ricavare il **valore soglia** (Fig. 1d) che consente di classificare correttamente il maggior numero possibile di soggetti sani (VN) e di classificare correttamente il maggior numero possibile di soggetti malati (VP), minimizzando sia la possibilità di sbagliare classificando dei soggetti malati come sani (FN) sia la possibilità di sbagliare classificando dei soggetti sani come malati (FP). Fissato il valore soglia, risultano determinate la **sensibilità** e la **specificità** del test.

Nel post [Sensibilità, specificità e valore predittivo](#) abbiamo impiegato il pacchetto **epiR** per calcolare le probabilità che rispondono alle due domande:

- il **valore predittivo di un test positivo**, ovvero la probabilità di essere malato per un soggetto che presenta un test positivo, che risponde alla prima domanda;
- il **valore predittivo di un test negativo**, ovvero la probabilità di essere sano per un soggetto che presenta un test negativo, che risponde alla seconda domanda.

In questo post, che conclude la saga bayesiana, impieghiamo **R** per completare quanto visto finora con una analisi numerica e una analisi grafica dettagliate [2] dei dati del file `bayes.csv` [3]. Nel primo passaggio, impiegando il pacchetto **ROCR**, sono calcolati, per ciascuno dei possibili valori soglia compresi tra il valore minimo e il valore massimo osservati, il numero di VP, FP, FN e VN. Nel secondo passaggio, impiegando semplicemente le funzioni base di **R**, sono calcolati e rappresentati graficamente, per ciascuno dei possibili valori soglia compresi tra il valore minimo e il valore massimo osservati, sensibilità, specificità, efficienza diagnostica, valore predittivo del test positivo, valore predittivo del test negativo e accuratezza diagnostica.

Per proseguire è necessario:

- effettuare il download del file `bayes.csv`
- salvare il file nella cartella `C:\Rdati\`

Trovate il file, con le istruzioni per scaricare questo e gli altri file di dati impiegati nei post, alla [pagina Dati](#).

Il file contiene la variabile `classe` che indica la classe di appartenenza dell'osservazione/riga (qui vengono impiegati i valori previsti di default nel pacchetto e cioè 0 per indicare un soggetto

sano/controllo e 1 per indicare un soggetto malato/caso) e la variabile quantitativa `valore`, che riporta il risultato del test, come illustrato in questo esempio che include le prime cinque e le ultime cinque osservazioni/righe del file:

```
classe;valore
0;19
0;22
0;26
0;28
0;29
.....
1;235
1;237
1;237
1;242
1;242
```

Inoltre il pacchetto aggiuntivo **ROCR** [4] deve essere scaricato dal **CRAN**. Copiate questo script, incollatelo nella Console di R e premete ↵ Invio:

```
# EFFICIENZA E ACCURATEZZA DIAGNOSTICA
#
library(ROCR) # carica il pacchetto
mydata <- read.table("c:/Rdati/bayes.csv", header=TRUE, sep=";") # importa i dati
attach(mydata) # consente di impiegare direttamente i nomi delle variabili
#
# calcola sensibilità, specificità, valore predittivo
#
pred <- prediction(valore, classe) # genera mediante la funzione prediction() un oggetto che
# contiene una pre-elaborazione dei dati
#
cut <- sort(unlist(pred@cutoffs), decreasing=FALSE) # calcola i valori soglia
vp <- sort(unlist(pred@tp), decreasing=TRUE) # calcola i veri positivi
fp <- sort(unlist(pred@fp), decreasing=TRUE) # calcola i falsi positivi
fn <- sort(unlist(pred@fn), decreasing=FALSE) # calcola i falsi negativi
vn <- sort(unlist(pred@tn), decreasing=FALSE) # calcola i veri negativi
#
tabpred <- data.frame(cut, vp, fp, fn, vn) # genera la tabella con i valori calcolati
names(tabpred) <- c("cutoff", "VP", "FP", "FN", "VN") # assegna i nomi alle variabili/colonne
tabpred # mostra la tabella
#
sens <- vp/(vp+fn) # calcola la sensibilità per ciascun valore soglia
spec <- vn/(vn+fp) # calcola la specificità per ciascun valore soglia
effi <- sens*spec # calcola la efficienza diagnostica per ciascun valore soglia
vptp <- vp/(vp+fp) # calcola il valore predittivo del test positivo per ciascun valore soglia
vptn <- vn/(vn+fn) # calcola il valore predittivo del test negativo per ciascun valore soglia
accu <- (vp+vn)/(vp+fp+fn+vn) # calcola la accuratezza diagnostica per ciascun valore soglia
#
tabprob <- data.frame(cut, sens, spec, effi, vptp, vptn, accu) # genera la tabella con i valori
# calcolati
names(tabprob) <- c("cutoff", "sensibilità", "specificità", "efficienza", "vptp", "vptn",
"accuratezza") # assegna i nomi alle variabili/colonne
tabprob # mostra la tabella
#
paste("Massima efficienza diagnostica ", round(max(effi), digits=3), " per un valore soglia
di ", cut[which.max(effi)], sep="") # riporta la massima efficienza diagnostica e il corrispondente
```

valore soglia

```
paste("Massima accuratezza diagnostica ", round(max(accur), digits=3), " per un valore  
soglia di ", cut[which.max(accur)], sep="") # riporta la massima accuratezza diagnostica e il  
corrispondente valore soglia  
#  
# traccia istogrammi con curve di sensibilità, specificità ed efficienza diagnostica  
#  
sani <- subset(valore, classe==0) # sottoinsieme con i valori dei soggetti sani per tracciare gli  
istogrammi  
malati <- subset(valore, classe==1) # sottoinsieme con i valori dei soggetti malati per tracciare  
gli istogrammi  
#  
windows() # apre una nuova finestra  
par(mar=c(5,4,4,5)+.1) # margini per fare spazio alla scala dell'asse delle y sulla destra  
#  
hist(malati, xlim=c(0,250), ylim=c(0,150), xaxp = c(0, 250, 5), yaxp = c(0, 150, 3),  
breaks=seq(from=0, to=250, by=5), border="red", col="red", density = 20, angle = 45,  
main="Sensibilità, specificità, efficienza diagnostica", xlab="Risultato del test",  
ylab="Frequenza", freq=TRUE, plot=TRUE) # traccia istogramma malati  
hist(sani, xlim=c(0,250), breaks=seq(from=0, to=250, by=5), border="green4",  
col="lightgreen", density = 20, angle = -45, freq=TRUE, add=TRUE, plot=TRUE) #  
sovrappone istogramma sani  
#  
par(new=TRUE) # sovrappone curva sensibilità  
plot(cut, sens, xlim=c(0,250), ylim=c(0,1), yaxp=c(0,1,5), type="l", lty=1, lwd=2, pch=  
20, cex=0.5, col="blue", xaxt="n", yaxt="n", xlab="", ylab="") # traccia la curva  
axis(4) # riporta un secondo asse delle y sulla destra per i valori di probabilità  
mtext("Probabilità p", side=4, line=3) # aggiunge la legenda all'asse delle y di destra  
#  
par(new=TRUE) # sovrappone curva specificità  
plot(cut, spec, xlim=c(0,250), ylim=c(0,1), yaxp=c(0,1,5), type="l", lty=1, lwd=2, pch=20,  
cex=0.5, col="mediumorchid", xaxt="n", yaxt="n", xlab="", ylab="") # traccia la  
curva  
#  
par(new=TRUE) # sovrappone curva efficienza diagnostica  
plot(cut, effi, xlim=c(0,250), ylim=c(0,1), yaxp=c(0,1,5), type="l", lty=3, lwd=2, pch=20,  
cex=0.5, col="orange", xaxt="n", yaxt="n", xlab="", ylab="") # traccia la curva  
#  
legend(140, 0.97, legend=c("Sani", "Malati", "Sensibilità", "Specificità", "Efficienza  
diagnostica"), col=c("green", "red", "blue", "mediumorchid", "orange"), lty=c(1,1,1,1,3),  
lwd=c(1,1,2,2,2), cex=0.7) # aggiunge al grafico la legenda  
#  
# traccia istogrammi con curve di valore predittivo ed accuratezza diagnostica  
#  
windows() # apre una nuova finestra  
par(mar=c(5,4,4,5)+.1) # margini per fare spazio alla scala dell'asse delle y sulla destra  
#  
hist(malati, xlim=c(0,250), ylim=c(0,150), xaxp = c(0, 250, 5), yaxp = c(0, 150, 3),  
breaks=seq(from=0, to=250, by=5), border="red", col="red", density = 20, angle = 45,  
main="Valore predittivo del test, accuratezza diagnostica", xlab="Risultato del test",  
ylab="Frequenza", freq=TRUE, plot=TRUE) # traccia istogramma malati  
hist(sani, xlim=c(0,250), breaks=seq(from=0, to=250, by=5), border="green4",  
col="lightgreen", density = 20, angle = -45, freq=TRUE, add=TRUE, plot=TRUE) #  
sovrappone istogramma sani  
#  
par(new=TRUE) # sovrappone curva valore predittivo del test positivo
```

```

plot(cut, vptp, xlim=c(0,250), ylim=c(0,1), yaxp=c(0,1,5), type="l", lty=1, lwd=2, pch=
20, cex=0.5, col="blue", xaxt="n", yaxt="n", xlab="", ylab="") # traccia la curva
axis(4) # riporta l'asse delle y sulla destra
mtext("Probabilità p", side=4, line=3) # aggiunge legenda asse y
#
par(new=TRUE) # sovrappone curva valore predittivo del test negativo
plot(cut, vptn, xlim=c(0,250), ylim=c(0,1), yaxp=c(0,1,5), type="l", lty=1, lwd=2,
pch=20, cex=0.5, col="mediumorchid", xaxt="n", yaxt="n", xlab="", ylab="") # traccia la
curva
#
par(new=TRUE) # sovrappone curva accuratezza diagnostica
plot(cut, accu, xlim=c(0,250), ylim=c(0,1), yaxp=c(0,1,5), type="l", lty=3, lwd=2,
pch=20, cex=0.5, col="orange", xaxt="n", yaxt="n", xlab="", ylab="") # traccia la curva
#
legend(135, 0.98, legend=c("Sani", "Malati", "Valore predittivo del test +", "Valore
predittivo del test -", "Accuratezza diagnostica"), col=c("green", "red", "blue",
"mediumorchid", "orange"), lty=c(1,1,1,1,3), lwd=c(1,1,2,2,2), cex=0.7) # aggiunge al
grafico la legenda
#

```

Importare ed elaborare i vostri dati con questo script risulterà semplicissimo: dovete solamente strutturare i dati come nel file `bayes.csv` [5] quindi modificare opportunamente il nome e la posizione del file nella prima riga di codice.

Con le prime tre righe di codice viene caricato il pacchetto, sono importati i dati, e viene reso possibile con la funzione `attach()` impiegare direttamente i nomi delle variabili.

La riga di codice cruciale è la quarta, che salva nell'oggetto `pred` i dati generati dalla funzione `prediction()` del pacchetto `ROCR` e precisamente il vettore che contiene tutti i possibili valori soglia (`pred@cutoffs`) e i vettori che riportano per ciascun valore soglia:

→ i veri positivi (`pred@tp`)
→ i falsi positivi (`pred@fp`)
→ i falsi negativi (`pred@fn`)
→ i veri negativi (`pred@tn`).

Questi cinque vettori sono quindi combinati nella tabella `tabpred` che così vi apparirà:

	cutoff	VP	FP	FN	VN
1	19	843	853	0	0
2	22	843	852	0	1
3	26	843	851	0	2
4	28	843	850	0	3
.....					
49	73	771	55	72	798
50	74	766	48	77	805
51	75	763	44	80	809
52	76	760	42	83	811
53	77	755	39	88	814
.....					
200	235	6	0	837	853
201	237	4	0	839	853
202	242	2	0	841	853
203	Inf	0	0	843	853

Pertanto fissando ad esempio il valore soglia (cutoff) tra sani e malati a `75` avremo `763 VP`, `44 FP`, `80 FN` e `809 VN`, e così via.

Nelle righe successive a partire dai vettori **vp**, **fp**, **fn** e **vn** sono calcolati per ciascuno dei valori soglia (cutoff) individuati:

→ sensibilità = $VP/(VP+FN)$

→ specificità = $VN/(VN+FP)$

→ efficienza diagnostica = sensibilità · specificità

→ valore predittivo del test positivo = $VP/(VP+FP)$

→ valore predittivo del test negativo = $VN/(VN+FN)$

→ accuratezza diagnostica = $(VP+VN)/(VP+FP+FN+VN)$

quindi i vettori **sens**, **spec**, **effi**, **vptp**, **vptn**, **accu** che contengono i dati calcolati sono combinati nella tabella **tabprob**:

	cutoff	sensibilità	specificità	efficienza	vptp	vptn	accuratezza
1	19	1.000000000	0.000000000	0.000000000	0.4970519	NaN	0.4970519
2	22	1.000000000	0.001172333	0.001172333	0.4973451	1.0000000	0.4976415
3	26	1.000000000	0.002344666	0.002344666	0.4976387	1.0000000	0.4982311
4	28	1.000000000	0.003516999	0.003516999	0.4979327	1.0000000	0.4988208
.....							
49	73	0.914590747	0.935521688	0.855619480	0.9334140	0.9172414	0.9251179
50	74	0.908659549	0.943728019	0.857527476	0.9410319	0.9126984	0.9262972
51	75	0.905100830	0.948417351	0.858413331	0.9454771	0.9100112	0.9268868
52	76	0.901542112	0.950762016	0.857151996	0.9476309	0.9071588	0.9262972
53	77	0.895610913	0.954279015	0.854662700	0.9508816	0.9024390	0.9251179
.....							
200	235	0.007117438	1.000000000	0.007117438	1.0000000	0.5047337	0.5064858
201	237	0.004744958	1.000000000	0.004744958	1.0000000	0.5041371	0.5053066
202	242	0.002372479	1.000000000	0.002372479	1.0000000	0.5035419	0.5041274
203	Inf	0.000000000	1.000000000	0.000000000	NaN	0.5029481	0.5029481

Da questa tabella sono ricavati il valore soglia che corrisponde alla massima efficienza diagnostica

[1] "Massima efficienza diagnostica 0.858 per un valore soglia di 75"

il valore soglia, identico al precedente, che corrisponde alla massima accuratezza diagnostica

[1] "Massima accuratezza diagnostica 0.927 per un valore soglia di 75"

e i valori delle grandezze (sensibilità, specificità, valori predittivi) corrispondenti al valore soglia 75 così individuato.

Da notare nelle funzioni **paste()** che generano le due righe gli argomenti **cut[which.max(effi)]** e **cut[which.max(accu)]** nei quali la funzione **which.max()** restituisce la posizione, all'interno del rispettivo vettore, del valore massimo di efficienza o di accuratezza, posizione che viene impiegata per trovare nel vettore **cut** il valore soglia corrispondente. Scorrendo i dati della tabella è facile confermare che sia nel caso dell'efficienza diagnostica sia nel caso della accuratezza diagnostica il valore soglia "ottimale" tra sani e malati è quello che corrisponde al massimo valore trovato di efficienza o di accuratezza.


Dalla tabella sono infine generati i grafici che riportano le sei grandezze calcolate in funzione del valore soglia (cutoff). In questa parte l'unica cosa un po' particolare è la funzione **subset()** [6] che viene impiegata per generare, dai dati importati, due sottoinsiemi separati, uno contenente solamente i valori dei soggetti sani e l'altro contenente solamente i valori dei soggetti malati, impiegando come argomenti:

→ il nome della variabile (**valore**) dalla quale si desidera estrarre il sottoinsieme di valori;


→ il criterio di selezione dei casi da estrarre, laddove **classe==0** indica di estrarre i valori per i quali nella variabile **classe** è riportato 0 (sano) e laddove **classe==1** indica di estrarre i valori per i quali

nella variabile **classe** è riportato 1 (malato).

Le funzioni e gli argomenti impiegati per costruire gli istogrammi con le distribuzioni dei risultati nel test nei sani e nei malati, e per sovrapporre ad essi le curve che rappresentano, in funzione dei valori soglia riportati in ascisse, la sensibilità, la specificità e l'efficienza diagnostica, sono illustrati sia nella documentazione di R delle funzioni **hist()** e **plot()** sia nei vari post dedicati alla rappresentazione grafica dei dati [7], ai quali si rimanda. Questo è il grafico risultante



Questo invece è il grafico che sovrappone agli istogrammi delle distribuzioni dei risultati nel test nei sani e nei malati le curve che rappresentano, in funzione dei valori soglia riportati in ascisse, il valore predittivo del test positivo, il valore predittivo del test negativo e l'accuratezza diagnostica



La conclusione è che un'analisi completa e dettagliata, sia numerica sia grafica, delle caratteristiche di un test per la diagnosi di una malattia, esempio paradigmatico di applicazione del teorema di Bayes, può essere realizzata a partire semplicemente dai conteggi di VP, FP, FN e VN effettuati per una serie opportuna di valori soglia, come magistralmente illustrato da Gerhardt e da Keller oltre trent'anni fa [2].

Per una versione che impiega per i calcoli le sole funzioni base di **R** e che impiega al posto degli istogrammi i kernel density plot, vedere il post [Efficienza e accuratezza diagnostica](#) [2].

Se strutturate i vostri dati seguendo le semplici indicazioni riportate sopra, per riutilizzare lo script dovete solamente, nella prima riga di codice, sostituire **c:/Rdati/bayes.csv** con posizione e nome del vostro file di dati.

[1] Abbiamo anche visto in un altro post come realizzare due [Curve ROC sovrapposte](#).

[2] Gerhardt W, Keller H. *Evaluation of test data from clinical studies*. Scand J Clin Lab Invest, 46, 1986 (supplement 181).
<https://www.tandfonline.com/doi/pdf/10.1080/00365518709168461>

[3] L'esempio qui impiegato rappresenta la situazione più frequente, quella nella quale la malattia determina un aumento del risultato dei test, ma ovviamente è sufficiente ribaltare dati e conclusioni per riadattare il tutto a un caso nel quale la malattia determina una diminuzione del risultato del test.

[4] *Package 'ROCR'*.
<https://cran.r-project.org/web/packages/ROCR/ROCR.pdf>

[5] Vedere il post [Curve Roc e valore soglia](#).

[6] Digitate **help(subset)** nella Console di R per la documentazione della funzione **subset()**.

[7] Per la funzione **legend()** consultare anche il post [Aggiungere la legenda a un grafico](#).
